# Más datos no siempre es mejor

Daniela Rodriguez
UBA- CONICET

30/9 - SENASA

# Por qué reducir dimensión?

- identificar y eliminar variables irrelevantes
- mejorar el rendimiento computacional
- facilitar la comprensión del modelo y sus resultados
- No siempre el mejor modelo es el que más variables tiene

Un mayor número de observaciones mejora un modelo, pero un mayor número de variables no necesariamente lo hace.

## Efectos negativos derivados del aumento del número de variables

- sobre ajuste

## Efectos negativos derivados del aumento del número de variables

- sobre ajuste
- colinezlidad

## Efectos negativos derivados del aumento del número de variables

- sobre ajuste
- colinezlidad
  - problemas de convergenciz de los algoritmos
  - estabilidad de soluciones

## Un enfoque para resolver el problema:

Transformar el conjunto de variables iniciales en un conjunto de menor dimensión pero que retenga la mayor parte de información

## Un enfoque para resolver el problema:

Transformar el conjunto de variables iniciales en un conjunto de menor dimensión pero que retenga la mayor parte de información

Métodos de extracción

## Un enfoque para resolver el problema:

Transformar el conjunto de variables iniciales en un conjunto de menor dimensión pero que retenga la mayor parte de información

Métodos de extracción

- PCA
- tSNE
- K means

**Regresión :** $Y \in \mathbb{R}$ $X \in \mathbb{R}^p$

$p=1$ un gráfico nos dice todo

**Regresión :** $Y \in \mathbb{R}$ $X \in \mathbb{R}^p$

$p=1$ un gráfico nos dice todo

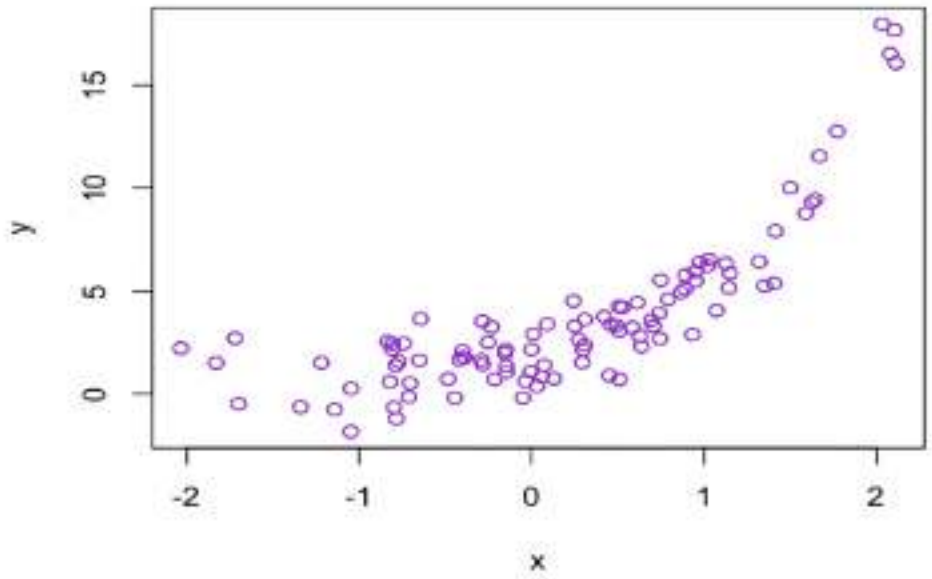

Regresión : $y \in \mathbb{R}$ $X \in \mathbb{R}^2$

$p=2$ Dos gráficos nos dice todo?

Regresión : $Y \in \mathbb{R}$ $X \in \mathbb{R}^2$

$p=2$ Dos gráficos nos dice todo?

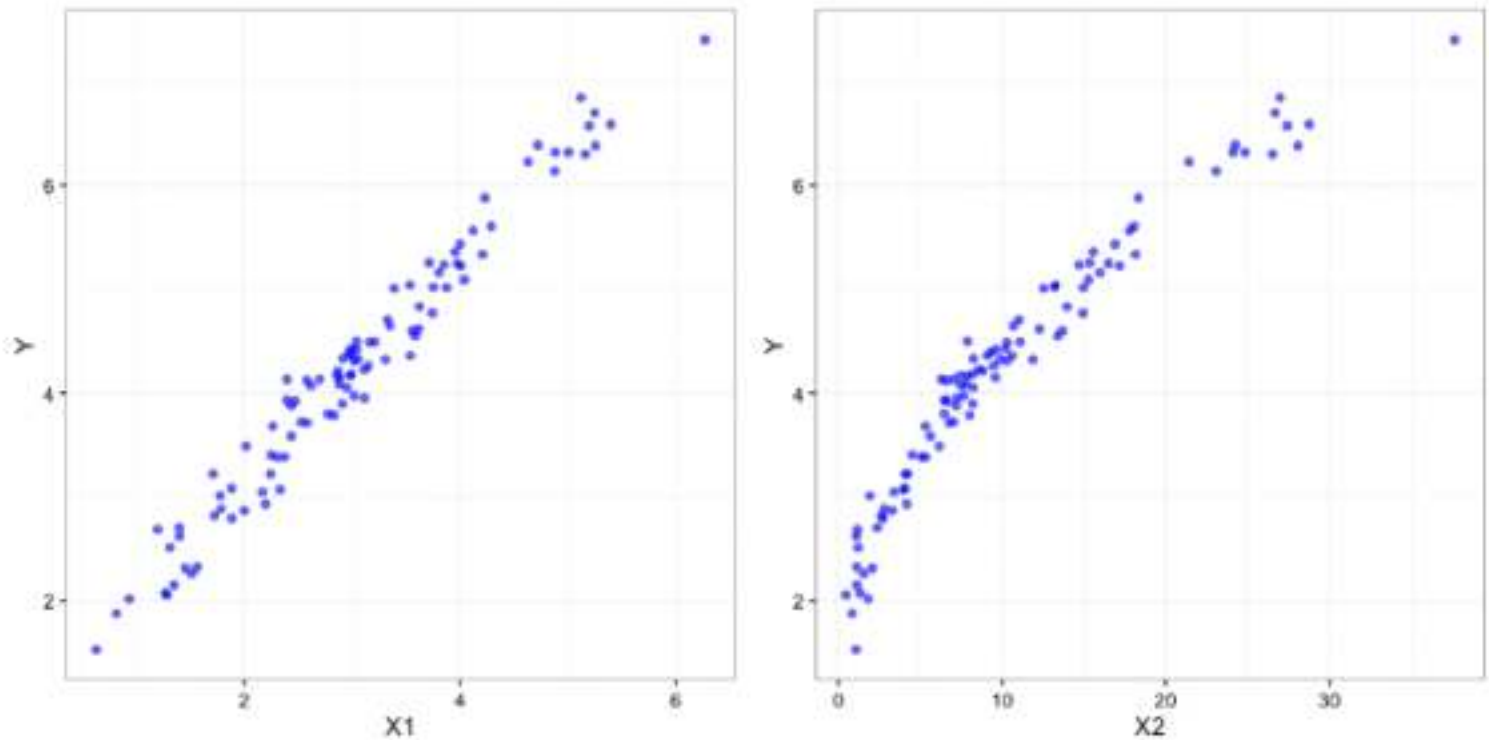

**Regresión:** $Y \in \mathbb{R}$ $\quad X = (X_1, X_2) \in \mathbb{R}^p$ $\quad p = 2$

Deberíamos graficar $Y$ vs $(X_1, X_2)$

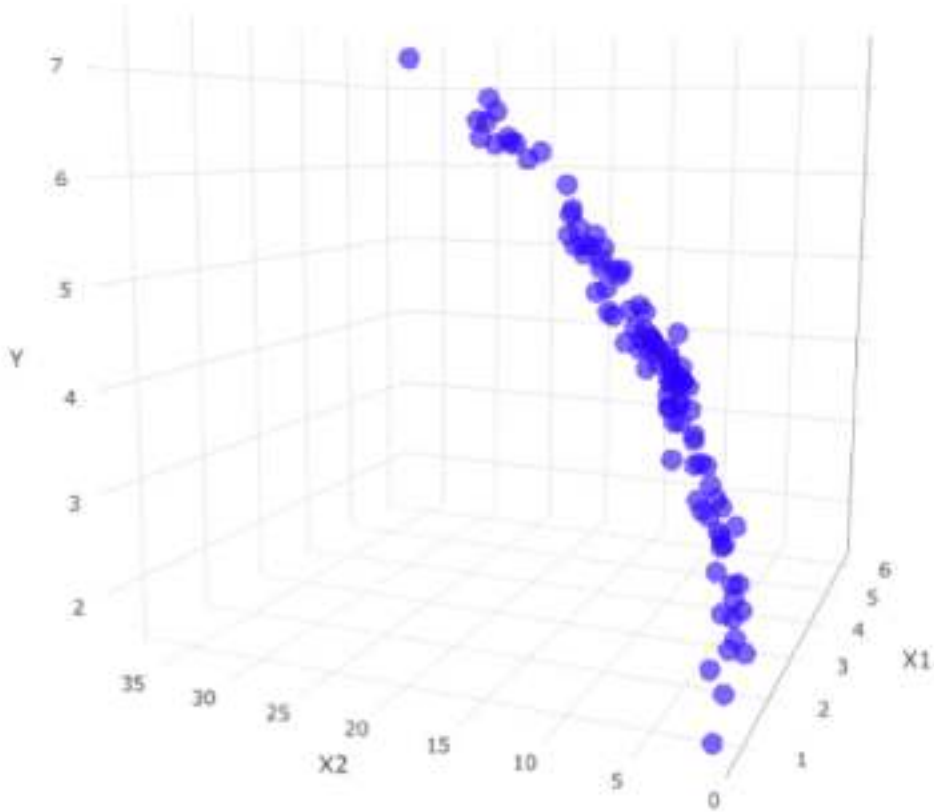

**Regresión:** $Y \in \mathbb{R}$ $\quad X = (X_1, X_2) \in \mathbb{R}^p$ $\quad p = 2$

Deberíamos graficar $Y$ vs $(X_1, X_2)$

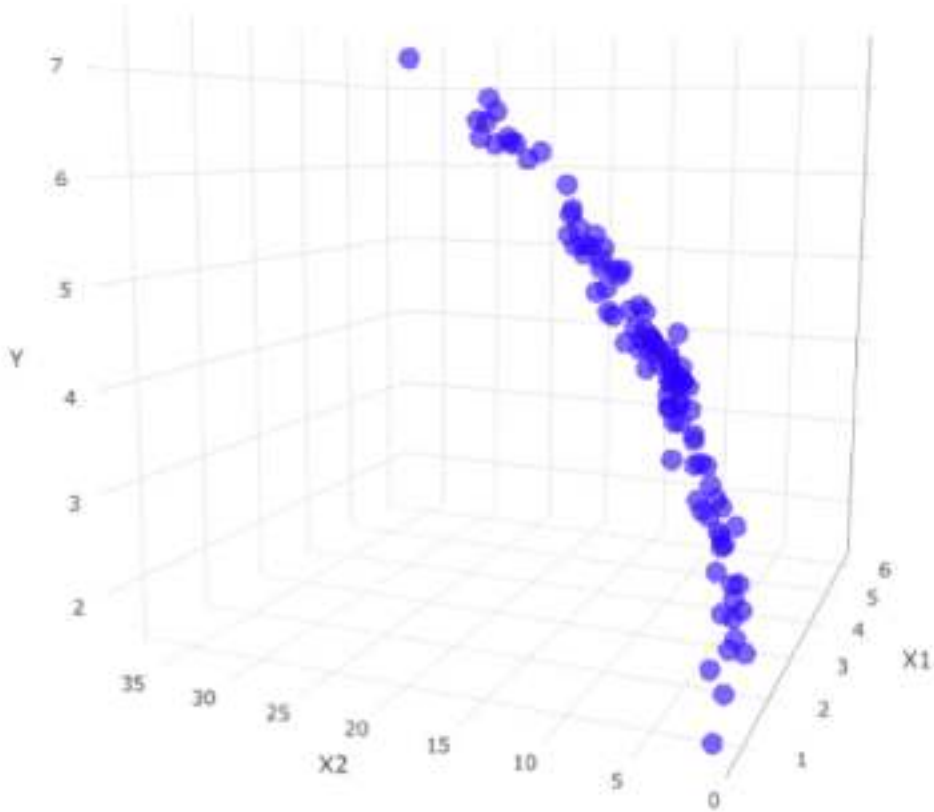


$$Y = f(a X_1 + b X_2) + \varepsilon$$

Si tengo $a$ y $b$

vuelvo al caso $p = 1$

Regresión: $p=2$ Si conozco $a$ y $b$ vuelvo al caso $p=1$

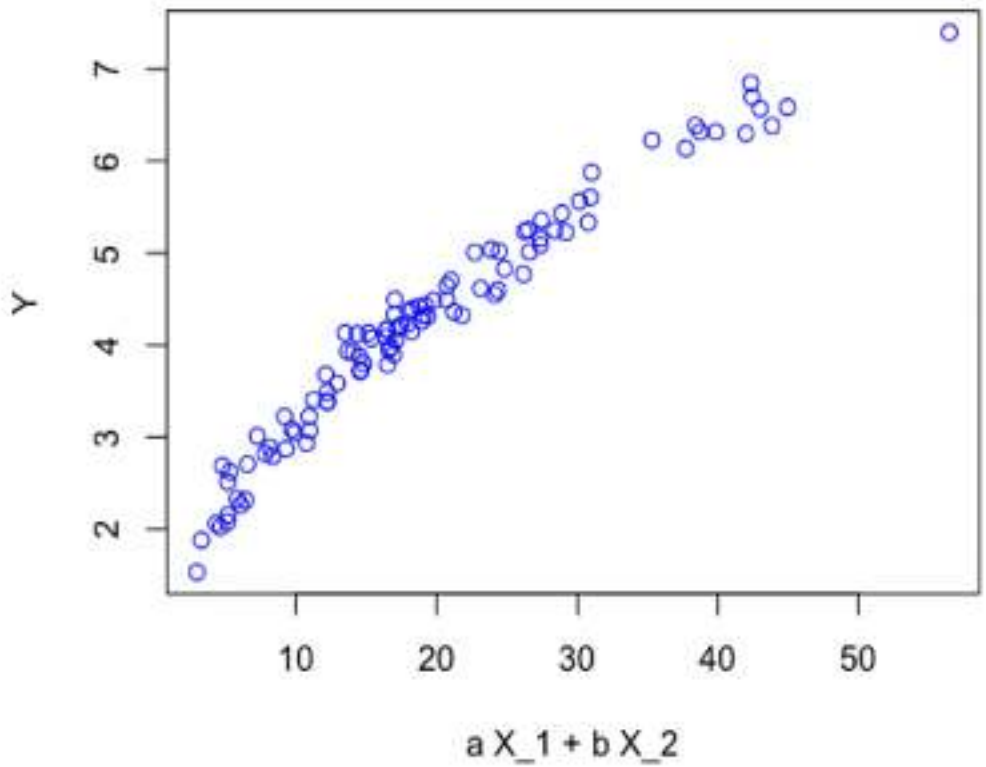

En este ejemplo

$$Y\Big|_{(x_1,x_2)} \overset{d}{\sim} Y\Big|_{\sqrt{3x_1+x_2}} \overset{d}{\sim} Y\Big|_{f(3x_1+x_2)}$$

En este ejemplo

$$Y\Big|_{(x_1,x_2)} \overset{d}{\sim} Y\Big|_{\sqrt{3x_1+x_2}} \overset{d}{\sim} Y\Big|_{f(3x_1+x_2)}$$

Si $a = (3,1)$ $\quad X = (x_1, x_2)$

$$Y\Big|_{(x_1,x_2)} \overset{d}{\sim} Y\Big|_{f(a'x)}$$

$3X_1 + X_2$ NO tiene la misma información que el par $(X_1, X_2)$

$3X_1 + X_2$ NO tiene la misma información que el par $(X_1, X_2)$

Pero $3X_1 + X_2$ tiene la misma información que $(X_1, X_2)$ para explicar a $Y$

## Objetivo

Transformar el problema en uno más simple

# Objetivo

Transformar el problema en uno más simple

Encontrar $a$ tal que $a'X$ y $X$ tengan

la misma información sobre $Y$

Luego estudiamos la regresión de $Y$ en $a'X$

En general, $X = (X_1, X_2, \ldots, X_p)$

buscamos $k$ combinaciones lineales de $X$

$(k < p)$, $a_1' X$, $a_2' X$, ..., $a_k' X$

Sea $a = (a_1, \ldots, a_k)$, basaremos la

regresión para explicar a $Y$ en $a' X$

# Componentes Principales (PCA)

170.000.000 de resultados en google

Mientras que "Linear regression"

119.000.000 resultados

## Como hace esto PCA ?

- Calculamos $\mathrm{cov}(X) = \Sigma$
- Obtenemos los $k$ autovectores de $\Sigma$ de autovalor más grande $a_1, a_2, \ldots, a_k$
- Consideremos $a = (a_1, a_2, \ldots a_k)$

# Como hace esto PCA ?

- Calculamos $\mathrm{cov}(X) = \Sigma$
- Obtenemos los $k$ autovectores de $\Sigma$ de autovalor más grande $a_1, a_2, \ldots, a_k$
- Consideremos $a = (a_1, a_2, \ldots a_k)$

$$\underbrace{X = (X_1, X_2, \ldots, X_p)}_{\text{dim } p} \longrightarrow \underbrace{a' X = (a_1' X, a_2' X, \ldots, a_k' X)}_{\text{dim } k}$$

Veamos un ejemplo de juguete

Veamos un ejemplo de juguete

Sea $X = (X_1, X_2)$

$Y = f(X_1, X_2) + \varepsilon$

$X$ independiente de $\varepsilon$

$E(\varepsilon) = 0$

Calculemos PCA

Calculamos $a_1$

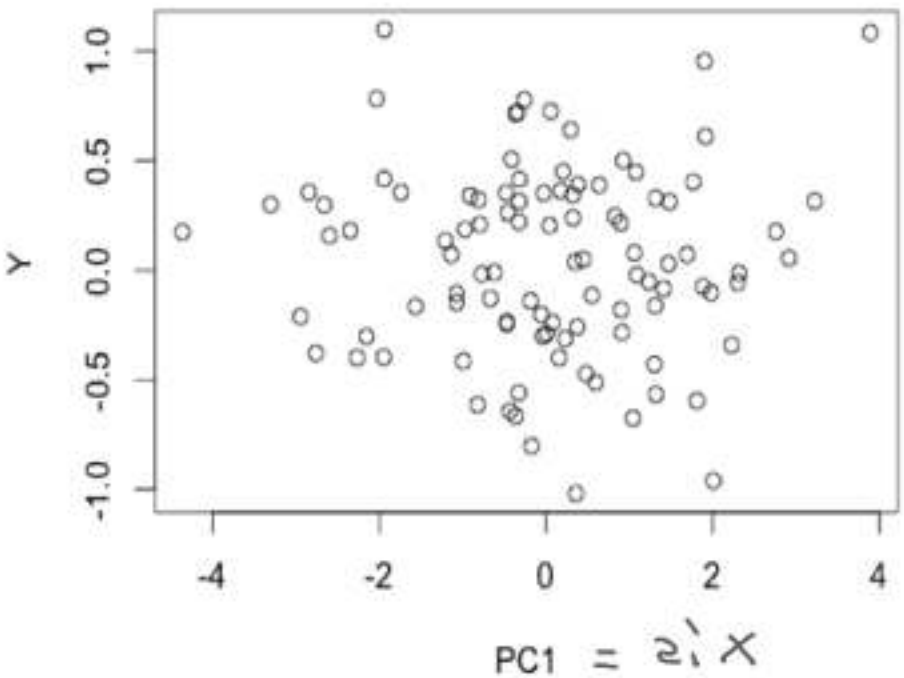

Calculamos $a_1$

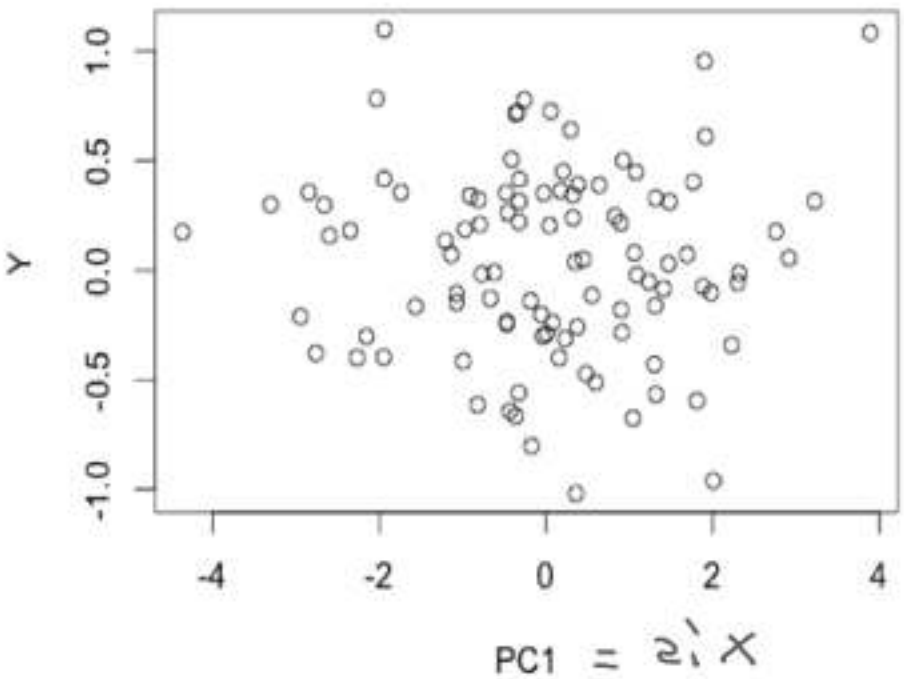


Parece que Y no se relaciona con PC1

Calculemos $a_2$

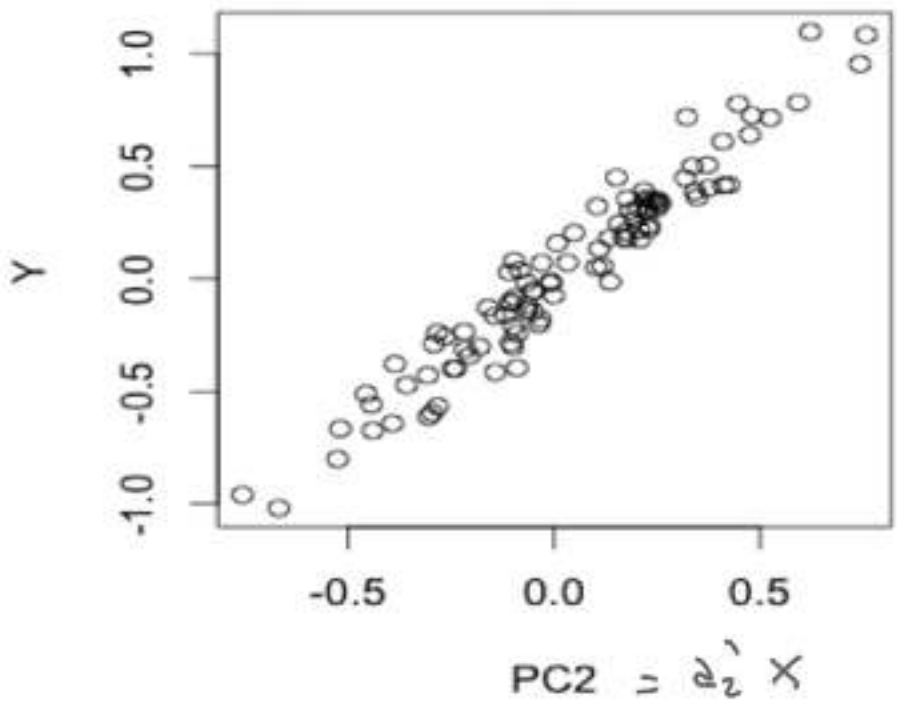

Calculemos $a_2$

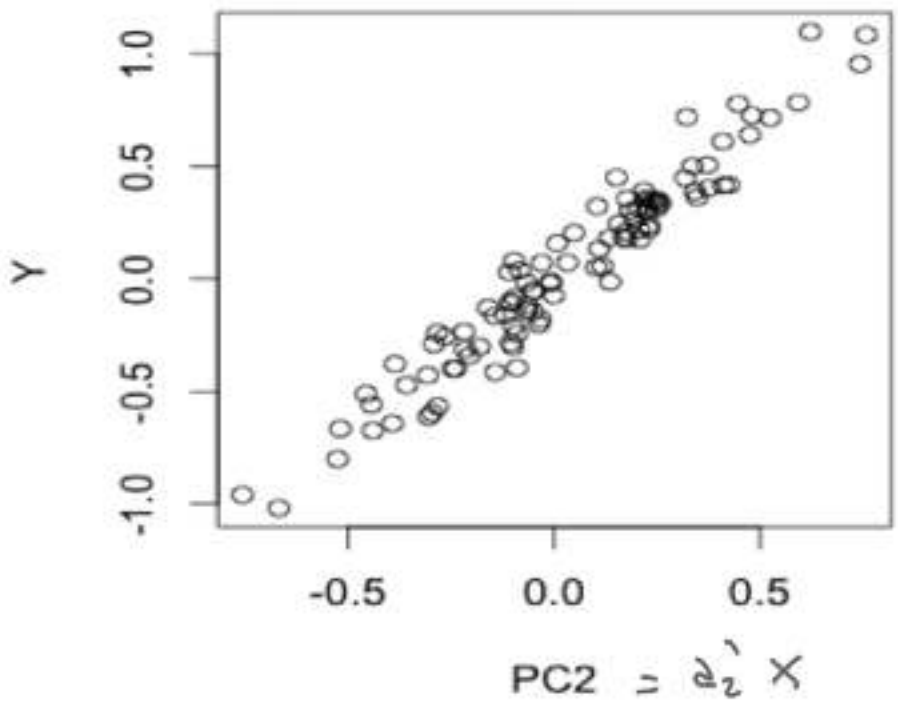


En $a_2$ parece estar toda la información relevante para explicar a Y

Calculemos $a_2$

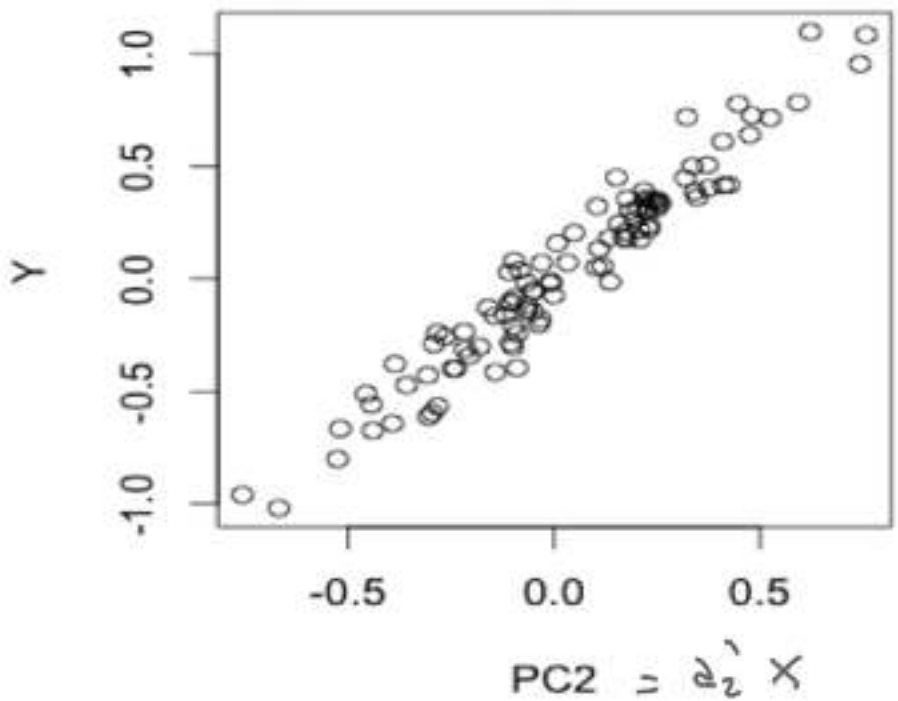


En $a_2$ parece estar toda la información relevante para explicar a Y

Sin embargo

95 % variabilidad de X lo explica $a_1$

5 % lo explica $a_2$

En este caso los datos fueron generados bajo el modelo

$$Y = X_1 - X_2 + \varepsilon$$

En este caso los datos fueron generados bajo el modelo

$$Y = X_1 - X_2 + \varepsilon$$

entonces si calculamos las componentes principales

$a_1 = (1,1)$ $\qquad PC_1 = a_1' X = X_1 + X_2$

$a_2 = (1,-1)$ $\qquad PC_2 = a_2' X = X_1 - X_2$

En este caso los datos fueron generados bajo el modelo

$$Y = X_1 - X_2 + \varepsilon$$

entonces si calculamos las componentes principales

$a_1 = (1,1)$ $\qquad PC_1 = a_1' X = X_1 + X_2$

$a_2 = (1,-1)$ $\qquad PC_2 = a_2' X = X_1 - X_2$

# Problema de PCA

Las componentes principales NO tienen relación con la respuesta Y

# Problema de PCA

Las componentes principales NO tienen relación con la respuesta Y

Están ordenadas respecto a la relación de variabilidad que tienen las variables X pero no la respuesta Y

# Reducción suficiente de la dimensión

Una reducción $R: \mathbb{R}^p \longrightarrow \mathbb{R}^k$ es suficiente para la regresión de $Y$ en $X$ si

$$\boxed{Y\big|_{X} \sim Y\big|_{R(X)}}$$

# Reducción suficiente de la dimensión

Una reducción $R: \mathbb{R}^p \longrightarrow \mathbb{R}^k$ es suficiente para la regresión de $Y$ en $X$ si

$$\boxed{Y\big|_{X} \sim Y\big|_{R(X)}}$$

La distribución de $Y$ condicional a $X$ es la misma que la distribución de $Y$ condicional a $R(X)$

## El ejemplo más sencillo: Regresion Lineal

Si $Y = \beta' X + \varepsilon$

con $X$ e $\varepsilon$ independientes

Entonces

$$Y|_X \overset{d}{\sim} Y|_{\beta' X}$$

## El ejemplo más sencillo: Regresion Lineal

Si $Y = \beta' X + \varepsilon$

con $X$ e $\varepsilon$ independientes

Entonces

$$Y|_X \overset{d}{\sim} Y|_{\beta' X}$$

Reducción Suficiente

## Como obtener y estimar $R(X)$?

- Reducción inversa basada en momentos

  SIR - SAVE - MAVE - PHD - PIR

- Reducción inversa basada en modelos

Como obtener y estimar $R(X)$?

## Como obtener y estimar $R(X)$?

Si asumimos un modelo bastante general para $X|_{Y=y}$ es posible obtener $R(X)$

## Como obtener y estimar $R(x)$?

Si asumimos un modelo bastante general para $X|_{Y=y}$ es posible obtener $R(x)$

Luego $R(x)$ dependerá del modelo que supusimos para $X|_{Y=y}$ y se obtendrá un estimador $\hat{R}(x)$

Cuán difícil es modelar $X|_{Y=y}$ ?

Cuán difícil es modelar $X|_{Y=y}$ ?

Es decir la distribución $f_{X|_{Y=y}}$

No Mucho.

Cuán difícil es modelar $X|_{Y=y}$ ?

Es decir la distribución $f_{X|_{Y=y}}$

No Mucho. Para estudiar la relacion $X|_{Y=y}$

$X = (X_1, X_2, X_3)$

podemos graficar

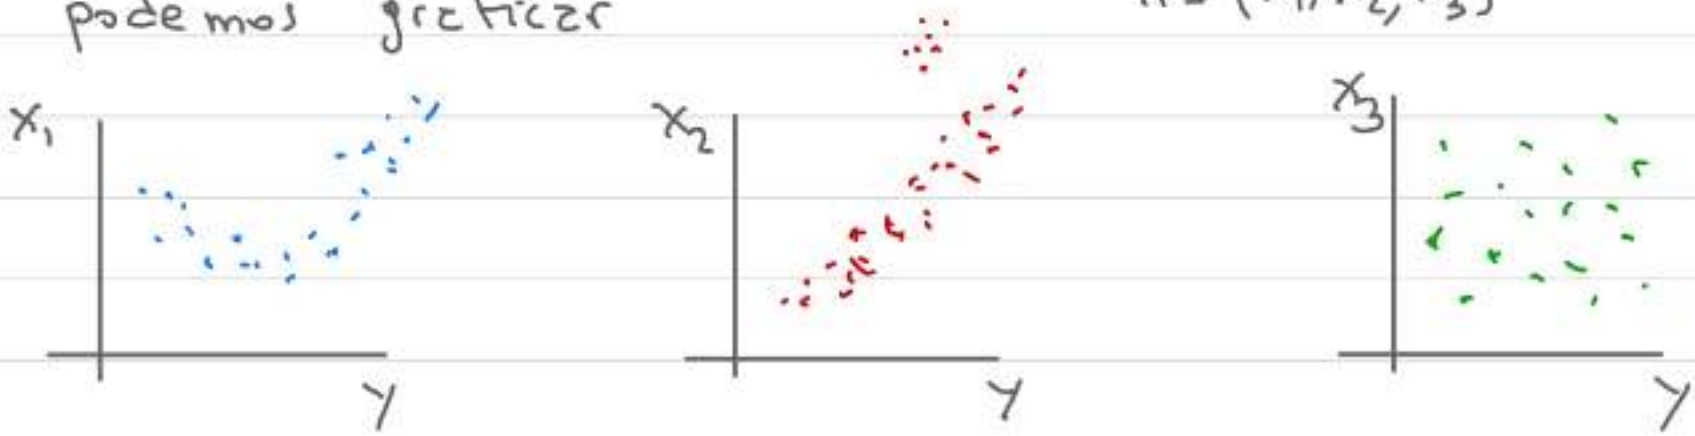

## Nuestro aporte en este tema

Estamos interesados en obtener estimadores y hacer inferencia para $\eta(x) = E(Y \mid X = x)$

## Nuestro aporte en este tema

Estamos interesados en obtener estimadores y hacer inferencia para $\eta(x) = E(Y \mid X = x)$

Como nos ayudaría tener una reducción suficiente $R(X)$?

## Nuestro aporte en este tema

Recordemos, si $R(x)$ es una reducción suficiente

$$Y\Big|_{X=x} \overset{d}{\sim} Y\Big|_{R(X)=R(x)}$$

## Nuestro aporte en este tema

Recordemos, si $R(X)$ es una reducción suficiente

$$Y\Big|_{X=x} \overset{d}{\sim} Y\Big|_{R(X)=R(x)}$$

Entonces

$$\eta(x) = E(Y \mid X=x) = E(Y \mid R(X)=R(x))$$

Nuestro aporte en este tema

## Nuestro aporte en este tema

Ingredientes

# Nuestro aporte en este tema

Ingredientes

$\Rightarrow$ modelo para $X|_{Y=y}$ $\left( f_{X|_{Y=y}} \; ? \right)$

# Nuestro aporte en este tema

Ingredientes

$\Rightarrow$ modelo para $X|_{Y=y}$ $\left( f_{X|_{Y=y}} \; ? \right)$

$\Rightarrow$ obtener $R(X)$

# Nuestro aporte en este tema

Ingredientes

$\Rightarrow$ modelo para $X|_{Y=y}$ $\left( f_{X|_{Y=y}} \; ? \right)$

$\Rightarrow$ obtener $R(X)$

$\Downarrow$

Estimar $\widehat{R(X)}$

# Nuestro aporte en este tema

Ingredientes

$\Rightarrow$ modelo para $X|_{Y=y}$ $\left( f_{X|_{Y=y}} \; ? \right)$

$\Rightarrow$ obtener $R(X)$

$\Downarrow$ usando $\eta(x) = E(Y|X=x)$

$= E(Y|R(x)=R(x))$

Estimar $\widehat{R(X)}$ $\Rightarrow$

# Nuestro aporte en este tema

Ingredientes

$\Rightarrow$ modelo para $X|_{Y=y}$ $\left( f_{X|_{Y=y}} \; ? \right)$

$\Rightarrow$ obtener $R(X)$

$\Downarrow$

Estimar $\widehat{R(X)}$ $\Rightarrow$ usando $\eta(x) = E(Y|X=x)$

$= E(Y|R(X)=R(x))$

$\Downarrow$

$$\boxed{\hat{\eta}(x)}$$

# Resultados:

Probamos propiedades teóricas de la estimación de la predicción $\hat{\eta}(x)$.

Esto nos permite hacer inferencia, como intervalos de confianza, intervalos de predicción, etc

En acción: 202 atletas del (IAD)

Se quiere predecir el Lean Body Mass (LBM)

Usando Género
Peso
Altura
Recuento de glóbulos blancos
Recuento de glóbulos rojos
Hemoglobina.

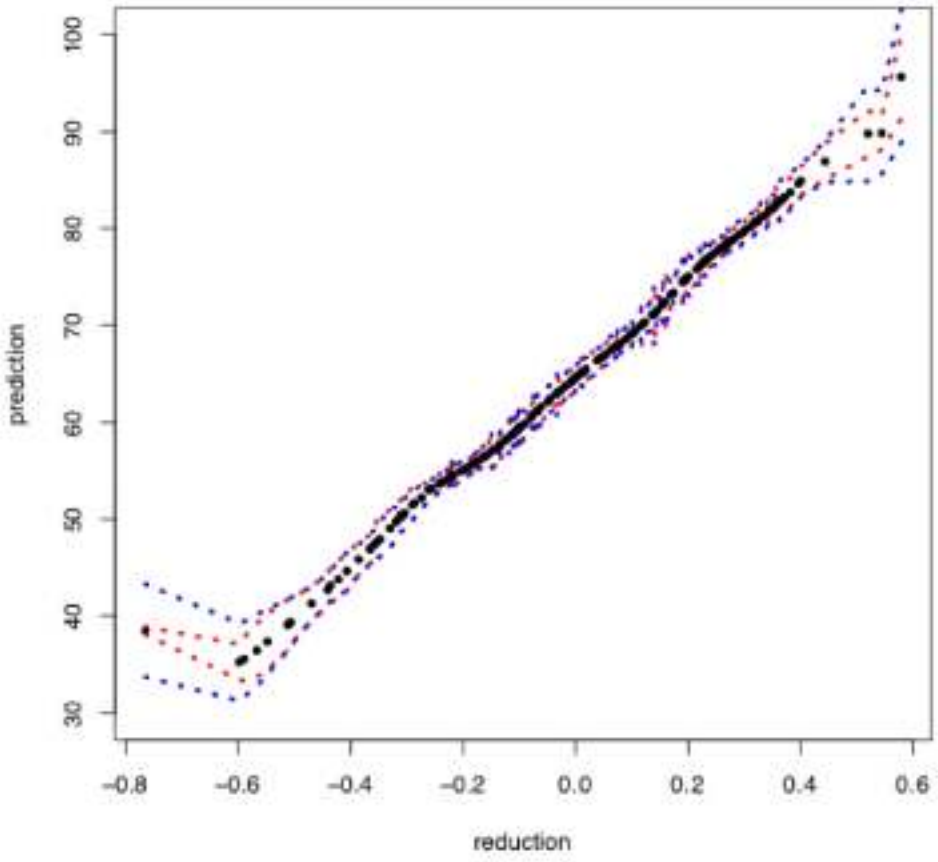


Intervalos basados en resultados asintóticos

Intervalos basados en bootstrap.

Para cada $X_i$ $1 \leq i \leq 202$, obtenemos la predicción de $Y_i \rightsquigarrow \hat{Y}_i$

Calculamos un intervalo de confianza para $Y_i$ del 95 %

En 95.05 % de los intervalos obtenemos que $Y_i$ se encuentra dentro

Muchas Gracias !!

drodrig@dm.uba.ar