Aplicaciones de la teoría de procesos empíricos

Daniela Rodriguez
Departamento de Matemática y Instituto de Cálculo, FCEyN,
Universidad de Buenos Aires y CONICET.

1 Preliminares **1**

2 Ejemplos **3**

2.1 Desviación respecto de la media. 3

2.2 k-medias. 3

2.3 M-estimadores y Z-estimadores 4

2.4 Estimación de densidad 5

3 Desigualdades exponenciales **5**

4 Simetrización **6**

5 Ley Uniforme de los Grandes Números **6**

5.1 Clases Vapnik - Chervonenkis de conjuntos 9

5.2 Clases Vapnik - Chervonenkis de funciones 12

6 Aplicaciones I **13**

6.1 Desviación respecto de la media. 13

6.1.1 L^1 en $I\!R$ 13

6.1.2 L^p en $I\!R$ 14

6.1.3 L^q en $I\!R^d$ 14

6.2 k-medias. 14

6.3 M-estimadores y Z-estimadores 16

6.4 Estimador noparamétrico de Máxima verosimilitud 17

7 Otras clase útiles **18**

8 Clases de funciones que dependen de n **20**

8.1 Aplicaciones a estimación de densidad 20

9 Teorema Central del Limite Uniforme **22**

10 Aplicaciones II **27**

10.1 Desviación L^p respecto de la media. 27

10.2 M-estimadores 28

10.3 Modelo parcialmente lineal 28

11 Posibles Extensiones **32**

1 Preliminares

Comencemos recordando algunas definiciones de convergencias.

Sean (T_n, T) variables aleatorias reales, luego T_n converge en probabilidad a T ($T_n \xrightarrow{p} T$) si para todo $\varepsilon > 0$ tenemos que

$$\lim_{n\to\infty} P(|T_n - T| > \varepsilon) = 0$$

Se dice que T_n converge a T ($T_n \xrightarrow{a.s.} T$)en casi todo punto si

$$P(\lim_{n\to\infty} T_n = T) = 1$$

Sea F_n y F las funciones de distribución de T_n y T respectivamente, se dice que T_n converge a T en distribución ($T_n \xrightarrow{\mathcal{D}} T$) si para todo x punto de continuidad de F

$$F_n(x) \to F(x).$$

Sean $X_1, \ldots, X_n$ variables aleatorias con distribución F y correspondiente medida de probabilidad P en $I\!R$

Ley de los Grandes Números. Supongamos que $\mu = E(X)$ existe, luego

$$\bar{X}_n \xrightarrow{a.s.} \mu$$

Teorema Central del Límite. Supongamos que $\mu = E(X)$ y $Var(X) = \sigma^2$ existen, luego

$$P\left(\sqrt{n}\left(\frac{\bar{X}_n - \mu}{\sigma}\right) \leq z\right) \to \Phi(z)$$

es decir $\sqrt{n}\left(\frac{\bar{X}_n - \mu}{\sigma}\right) \xrightarrow{\mathcal{D}} Z$ con Z una variables $N(0,1)$.

Entonces, si $X_1, \ldots, X_n$ son variables reales i.i.d con distribución F y correspondiente medida de probabilidad P en $I\!R$, consideramos la función de distribución empírica

$$F_n(x) = \frac{1}{n}\sum_{i=1}^{n} 1_{(-\infty,x]}(X_i) \qquad \text{con} \quad x \in I\!R$$

por la Ley de los Grandes Números tenemos que para cada x fijo $F_n(x) \xrightarrow{a.s.} F(x)$ y por el teorema central del límite $Z_n(x) = \sqrt{n}(F_n(x) - F(x)) \xrightarrow{\mathcal{D}} Z \sim N(0,1)$

La teoría de procesos empíricos a comenzado en los años 30 con el estudio de la función de distribución empírica F_n y el correspondiente proceso empírico. Es decir, si $X_1, \ldots, X_n$ son variables reales i.i.d con distribución F con función de distribución empírica $F_n(x)$ el proceso empírico correspondiente se define como

$$Z_n(x) = \sqrt{n}(F_n(x) - F(x)).$$

Los primeros resultados básicos que involucran a F_n y Z_n más generales son:

Teorema 1.1: (Glivenko - Cantelli (1933)).

$$\|F_n - F\|_\infty = \sup_x |F_n(x) - F(x)| \xrightarrow{a.s.} 0$$

Teorema 1.2: (Donsker (1952)).

$$Z_n \xrightarrow{w} Z = U(F) \quad \text{en} \quad l^\infty(I\!R)$$

donde U es un proceso gaussiano con media 0 y función de covarianza $E(U(s)U(t)) = \min\{s,t\} - st$ con $s,t \in [0,1]$.

Que quiere decir que $Z_n \xrightarrow{w} Z$ en $l^\infty(I\!R)$?

$E(g(Z_n)) \to E(g(Z))$ para toda función $g : l^\infty(I\!R) \to I\!R$ continua y acotada.

En los años 50 y 60 se vio la necesidad de generalizar estos resultados en particular a otros espacios muestrales $\mathcal{X}$ tales como $I\!R^d$, espacios de funciones, variedades Riemannianas, etc. En este sentido la definición de función de distribución empírica no tiene una extensión natural ya que requiere de por ejemplo la noción de orden. Por este motivo se define la medida empírica P_n, indexada en alguna clase de subconjuntos $\mathcal{C}$ del espacio $\mathcal{X}$ o mas generalmente en una clase de funciones $\mathcal{F}$ a valores reales definida sobre $\mathcal{X}$.

Sean $X_1, \ldots, X_n$ variables i.i.d. y sea P una medidad de probabilidad sobre $\mathcal{X}$. Definimos la medida empírica P_n como

$$P_n(A) = \frac{1}{n}\sum_{i=1}^n 1_A(X_i) = \frac{\#\{i \le n : X_i \in A\}}{n}$$

donde $A \subset \mathcal{X}$. Y sea f una función real sobre $\mathcal{X}$ tenemos que

$$P_n f = \frac{1}{n}\sum_{i=1}^n f(X_i).$$

Si $\mathcal{C}$ es una clase de subconjuntos de $\mathcal{X}$ entonces $\{P_n(C) : C \in \mathcal{C}\}$ es la medida empírica indexada por $\mathcal{C}$ equivalentemente si $\mathcal{F}$ es una clase de funciones.

El proceso empiríco G_n esta definido por $G_n = \sqrt{n}(P_n - P)$ donde, $G_n : l^\infty(\mathcal{F}) \to I\!R$ con $l^\infty(\mathcal{F}) = \{h : \mathcal{F} \to I\!R \ \sup_{f\in\mathcal{F}} \|h(f)\| < \infty\}$.

Y de la misma forma que para la medida empírica podemos considerar el proceso empírico indexado en $\mathcal{C}$ o en $\mathcal{F}$.

Notemos que la función de distribución empírira se corresponde con tomar $\mathcal{C} = \{(-\infty, t] : t \in I\!R\}$.

Preguntas que nos pueden surgir hasta acá:

Para que clases de funciones es posible generalizar los Teoremas 1 y 2?

Por que sería interesante generalizarlos?

Respuestas a estas preguntas comenzaron a darse en los años 70 especialmente en los trabajos de Vapnik y Chervonenkis, Dudley, y en los 80 por Pollard, Gine, Zinn. En este

curso intentaremos contar algunas generalizaciones de Los Teoremas 1 y 2 y estudiaremos como aplicar estos teoremas en procedimientos estadísticos.

Definición 1.1: $\mathcal{F}$ se dice una clase de funciones Glivenko-Cantelli o P-Glivenko-Cantelli si $\|P_n - P\|_{\mathcal{F}} = \sup_{f\in\mathcal{F}} |P_n f - Pf| \xrightarrow{a.s.} 0$

Definición 1.2: $\mathcal{F}$ se dice una clase de funciones Donsker o P-Donsker si $G_n \xrightarrow{w} G$ en $l^\infty(\mathcal{F})$ donde G es un proceso gaussiano con media 0 y función de covarianza $E(G(f)G(g)) = P(fg) - PfPg$. Es decir, si $h : l^\infty(\mathcal{F}) \to I\!R$ es continua y acotada entonces $\int h\ o\ G_n\ dP \to \int h\ o\ G\ dP$.

2 Ejemplos

2.1 Desviación respecto de la media.

Supongamos que tenemos $X_1, \ldots, X_n$ variables i.i.d con distribución F y correspondiente medida de probabilidad P. Supongamos que $E|X_1| < \infty$. Definamos

$$V_n = \frac{1}{n}\sum_{i=1}^{n} |X_i - \overline{X}_n|$$

es decir la distancia L^1 repecto de la media. La pregunta es $V_n \xrightarrow{a.s.} v$ para alguna constante v? se puede identificar v?. Se puede hallar la distribución asintótica de V_n?

Si en lugar de tener V_n tenemos $V_n(p) = \frac{1}{n}\sum_{i=1}^{n} |X_i - \overline{X}_n|^p$, es lo mismo?

Ahora si tenemos que $X_1, \ldots, X_n$ i.i.d. con distribución P en $I\!R^d$ y consideramos $V_n(p,q) = \frac{1}{n}\sum_{i=1}^{n} \|X_i - \overline{X}_n\|_q^p$ podemos ver a donde converge $V_n(p,q)$?

2.2 k-medias.

El método de k-medias sirve para particionar el espacio en clusters. Dados $x_1, \ldots, x_n \in I\!R^d$ realizaciones de n variables $\{X_i\}_{1\le i\le n} \sim P$ la idea es dar una partición de $I\!R^d$ para estos vamos a elegir los k mejores (en algun sentido) puntos $a_{1n}, \ldots, a_{kn}$ y particionar el espacio de acuerdo a la cercanía a ellos.

El método consiste en elegir los puntos de manera que minimicen la suma de los cuadrados en cada grupo, es decir, $a_{1n}, \ldots, a_{kn}$ de forma tal que minimicen, $\sum_{i=1}^{n} \min\{|X_i - a_1|^2, \ldots, |X_i - a_k|^2\}$ sobre todas las k- uplas $a_1, \ldots, a_k$ con $a_i \in I\!R^d$.

Podemos pensar el método también de la siguiente manera supongamos que tenemos una densidad φ que tiene k modas desconocidas $a_1^*, \ldots, a_k^*$,, lo que quisieramos es estimar esas modas.

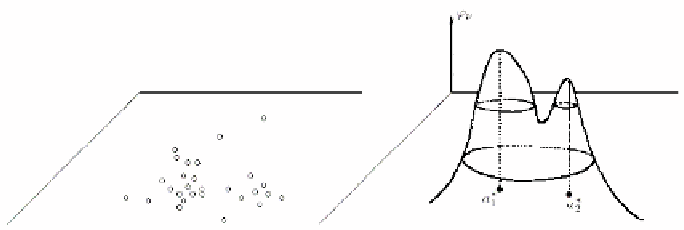

La pregunta que nos hacemos entonces es si la estimación de los k-puntos $a_{1n}, \ldots, a_{kn}$ convergen a los verdaderos paramétros $a_1^*, \ldots, a_k^*$, cuando n converge a ∞.

2.3 M-estimadores y Z-estimadores

Los principales métodos de estimación paramétricos como el método de los momentos, el método de máxima verosimilitud o el de mínimos cuadrados pueden pensarse a partir de minimizar en θ,

$$\sum_{i=1}^{n} m_\theta(X_i)$$

para funciones m_θ adecuadas. Por ejemplo,

- ⋆ estimación de la media $m_\theta = (x-\theta)^2$
- ⋆ estimación de la mediana $m_\theta = |x-\theta|$
- ⋆ estimadores de máxima verosímilitud $m_\theta = -\log p_\theta$
- ⋆ estimadores de posición robustos como los M-estimadores de Huber con $m_\theta(x) = \rho_k^H(x-\theta)$ donde

$$\rho_k^H(u) = \begin{cases} -ku - k^2/2 & \text{si} \quad u < -k \\ u^2/2 & \text{si} \quad |u| \leq k \\ ku - k^2/2 & \text{si} \quad u > k \end{cases}.$$

Sea $X_1, \ldots, X_n$ variables i.i.d con medida de probabilidad P. Sea Θ un espacio métrico de parámetros, para todo $\theta \in \Theta$ consideremos $m_\theta : \chi \to I\!R$. Nosotros queremos estimar el párametro θ_0 donde

$$\theta_0 = arg \max_{\theta \in \Theta} E m_\theta(X) = arg \max_{\theta \in \Theta} P m_\theta,$$

La idea es estimar θ_0, entonces en forma general definamos los M-estimadores, como

$$\theta_n = arg \max_{\theta \in \Theta} \frac{1}{n} \sum_{i=1}^{n} m_\theta(X_i) = arg \max_{\theta \in \Theta} P_n m_\theta.$$

Paralelamente a los M-estimadores se definen los Z-estimadores que basicamente es pensar el problema anterior pero a partir de las ecuaciones derivadas. Es decir, en este caso θ_n resulve la ecuación

$$\frac{1}{n} \sum_{i=1}^{n} m'_\theta(X_i) = P_n m'_\theta = 0$$

donde m'_θ es la derivada de m_θ respecto de θ.

Nuestro objetivo será probar que estos estimadores son consistentes y hallar su distribución asintótica.

2.4 Estimación de densidad

El estimador de densidad basado en núcleos es un proceso indexado en la ventana h. Dados $X_1, \ldots, X_n$ variables i.i.d con medida de probabilidad P con función de densidad acotada p. Una forma de estimar p es a traves del estimador

$$p_n(x,h) = \frac{1}{nh^d} \sum_{i=1}^{n} K\left(\frac{X_i - x}{h}\right) = P_n \frac{1}{h^d} K_{x,h}$$

donde $K_{x,h}(y) = K\left(\frac{y-x}{h}\right)$ para alguna función de densidad K en $I\!R^d$ y h una sucesión que converge a 0 cuando n converge a ∞. Lo que nos interesa es probar que el estimador de densidad converge uniformente a p.

En este caso el detalle en el que tenemos que tener cuidado es que la función $K_{x,h}$ depende de n a traves de h.

3 Desigualdades exponenciales

Las desigualdades exponenciales nos dicen algo así como que la probabilidad de que la desviación respecto de la media sea grande es exponencialmente pequeña. Estas desigualdades son útiles cuando uno quiere demostrar que con probabilidad grande una colección de eventos ocurre simultáneamente. Para esto, bastará demostrar que la suma de las probabilidades (que son chicas) de cada uno de esos eventos, da algo chico.

Desigualdad de Chebyshev: Sea $X \in I\!R$ con probabilidad P, y sea ϕ creciente, entonces para todo a con $\phi(a) > 0$ tenemos

$$P(X \geq a) \leq \frac{E\phi(X)}{\phi(a)}$$

Si $X \sim N(0,1)$ entonces, $P(X \geq a) \leq \exp[-a^2/2] \quad \forall a > 0$. Esto tomando $\phi(t) = \exp(at)$.
Si $X_1, \ldots, X_n$ independientes y $X_i \sim N(\mu_i, \sigma_i^2)$, sea $b^2 = \sum_{i=1}^n \sigma_i^2$ Entonces para todo $a > 0$, tenemos $P(\sum_{i=1}^n X_i \geq a) \leq \exp[-\frac{a^2}{2b^2}]$.

Desigualdad de Bernstein: Sean $X_1, \ldots, X_n$ independientes con esperanza 0. Supongamos que para todo i, $E|X_i|^m \leq \frac{m}{2} K^{m-2} \sigma_i^2, \quad m = 2, 3, \ldots$. Definamos $b^2 = \sum_{i=1}^n \sigma_i^2$ entonces para todo $a > 0$ tenemos que

$$P(\sum_{i=1}^{n} X_i \geq a) \leq \exp\left[-\frac{a^2}{2(aK + b^2)}\right].$$

Desigualdad de Hoeffding: Sean $X_1, \ldots, X_n$ independientes con esperanza 0. Supongamos que para todo i, $|X_i| \leq c_i$ entonces para todo $a > 0$ tenemos que

$$P(\sum_{i=1}^{n} X_i \geq a) \leq \exp\left[-\frac{a^2}{2\sum_{i=1}^n c_i^2}\right].$$

4 Simetrización

La simetrización es una técnica basada en la siguiente idea. Supongamos que tenemos algún método de estimación, y queremos saber cuán bueno es. Y tenemos una muestra de tamaño n, llamada de entrenamiento, y una segunda muestra, también de tamaño n, llamada de prueba. Entonces podemos usar la muestra de entrenamiento para calcular el estimador, y la muestra de prueba para verificar su performance. Por ejemplo en el caso que queremos saber cuán grande es el máximo desvío de ciertos promedios o esperanzas, pero no podemos calcularlos directamente porque por ejemplo las esperanzas son desconocidas. Entonces, podemos calcular el máximo desvío entre los promedios de las dos muestras. La simetrización relaciona estas dos cantidades.

Sea $X \in \chi$ un variables con distribución P, y consideremos dos muestras independientes $X_1, \ldots, X_n$ y $X'_1, \ldots, X'_n$. Sea $\mathcal{G}$ una clase de funciones y tenemos las dos medidas empíricas asociadas a ambas muestar P_n y P'_n. Definamos

$$\begin{aligned} \|P_n - P\|_{\mathcal{G}} &= \sup_{f \in \mathcal{G}} |P_n g - Pg| \\ \|P'_n - P\|_{\mathcal{G}} &= \sup_{f \in \mathcal{G}} |P'_n g - Pg| \\ \|P_n - P_n\|_{\mathcal{G}} &= \sup_{f \in \mathcal{G}} |P_n g - P'_n g| \end{aligned}$$

Simetrización en medias

Lema 4.1: $E\|P_n - P\|_{\mathcal{G}} \leq E\|P_n - P'_n\|_{\mathcal{G}}$

Sucesión de Rademacher: σ_i una sucesión independientes de variables con distribución $P(\sigma_i = 1) = P(\sigma_i = -1) = \frac{1}{2}$. Y $P_n^\sigma = \frac{1}{n}\sum_{i=1}^n \sigma_i X_i$

Lema 4.2 :$E\|P_n - P\|_{\mathcal{G}} \leq 2E\|P_n^\sigma\|_{\mathcal{G}}$

Simetrización en probabilidades

Lema 4.3: Sea $\delta > 0$ tal que para toda $g \in \mathcal{G}$, $P(|P_n(g) - P(g)| > \frac{\delta}{2}) \leq \frac{1}{2}$ entonces $P(\|P_n - P\|_{\mathcal{G}} > \delta) \leq 2P(\|P_n - P'_n\|_{\mathcal{G}} > \frac{\delta}{2})$

Lema 4.4 :Sea $\delta > 0$ tal que para toda $g \in \mathcal{G}$, $P(|P_n(g) - P(g)| > \frac{\delta}{2}) \leq \frac{1}{2}$ entonces $P(\|P_n - P\|_{\mathcal{G}} > \delta) \leq 4P(\|P_n^\sigma\|_{\mathcal{G}} > \frac{\delta}{4})$

5 Ley Uniforme de los Grandes Números

En esta sección veremos la ley fuerte de los grandes números uniforme cuando g varía sobre una clase $\mathcal{G}$ de funciones. Primero, veremos el caso donde la clase es finita. Si $\mathcal{G}$ no es finito, la idea es aproximar por un conjunto finito.

Notemos que para cada $g \in \mathcal{G}$, $P_n g - Pg \xrightarrow{a.s.} 0$ por la ley de los grandes números para todo $w \in \Omega_g$. Entonces si $\mathcal{G}$ es una clase finita tenemos que si consideramos $\Omega = \cap_{g \in \mathcal{G}} \Omega_g$ entonces $\sup_{\mathcal{G}} |P_n g - Pg| \xrightarrow{a.s.} 0$. Pero de todos modos veamos esto usando otro argumento.

Una observación: Sea $\{A_k\}_{k=1}^N$ una colleción finita de eventos, entonces

$$P(\cup_{i=1}^N A_i) \leq \sum_{i=1}^N P(A_i) \leq N \max_{1\leq i\leq N} P(A_i)$$

Lema 5.1 : Sea $\mathcal{G}$ una clase finita con cardinal N, supongamos que $\max_{\mathcal{G}} |g| \leq K$ entonces para todo $\delta \geq 2K\sqrt{\frac{\log N}{n}}$ tenemos que

$$P(\|P_n - P\|_{\mathcal{G}} > \frac{\delta}{2}) \leq 8 \exp\left[-\frac{n\delta^2}{4K^2}\right]$$

demostración:

Por la desigualdad de Hoeffding para cada $g \in \mathcal{G}$ se tiene que

$$P(|P_n^\sigma(g)| > \delta) \leq 2 \exp\left[-\frac{n\delta^2}{2K^2}\right]$$

Por la obsevación anterior

$$P(\|P_n^\sigma\|_{\mathcal{G}} > \delta) \leq 2N \exp\left[-\frac{n\delta^2}{2K^2}\right] \leq 2 \exp\left[-\frac{n\delta^2}{4K^2}\right]$$

Ahora por Chebyshev tenemos que para cada $g \in \mathcal{G}$ entonces

$$P(|P_n(g) - P(g| > \delta) \leq \frac{\mathrm{var}(g(X))}{n\delta^2} \leq \frac{K^2}{n\delta^2} \leq \frac{1}{4\log N} \leq \frac{1}{2}$$

Entonces usando la simetrización para probabilidades tenemos que

$$P(\|P_n - P\|_{\mathcal{G}} > 4\delta) < 8 \exp\left[-\frac{n\delta^2}{4K^2}\right]$$

□

Como hacemos si tenemos una clase que no es finita?

Supongamos que si bien $\mathcal{G}$ no es finita tenemos un cubirmiento finito, que la cubre. Es decir, sea $\varepsilon > 0$ y sean $f_1, \ldots, f_N$ tales que $\mathcal{G} = \cup_{1\leq j\leq N}\{f : P_n|f - f_j| \leq \varepsilon\}$. Notemos que estamos tomando como norma $\|f\| = \int f dP_n$ es decir la norma L^1 respecto de la medida empírica, luego N dependerá de P_n. Por otro lado tenemos que

$$|P_n^\sigma f| \leq |P_n^\sigma f_j| + P_n|f - f_j| \leq |P_n^\sigma(f_j)| + \varepsilon$$

entonces

$$\|P_n^\sigma\|_{\mathcal{F}} \leq \max_{1\leq j\leq N} |P_n^\sigma f_j| + \varepsilon$$

Por la desigualdad de Hoeffding tenemos que

$$P(\max_{1\leq j\leq N} |P_n^\sigma f_j| > \varepsilon) \leq 2 \exp\left[-\frac{n\varepsilon^2}{4K^2}\right]$$

si $\varepsilon \geq 2K\sqrt{\frac{\log N}{n}}$. Entonces si $\varepsilon \geq 2K\sqrt{\frac{\log N}{n}}$

$$P(\|P_n^\sigma\|_{\mathcal{G}} > 2\varepsilon) \leq 2\exp\left[-\frac{n\varepsilon^2}{4K^2}\right]$$

Luego,

$$P(\|P_n^\sigma\|_{\mathcal{G}} > 2\varepsilon) \leq 2\exp\left[-\frac{n\varepsilon^2}{4K^2}\right] + P(2K\sqrt{\frac{\log N}{n}} > \varepsilon)$$

Y usando la simetrización para probabilidades tenemos que

$$P(\|P_n - P\|_{\mathcal{G}} > 4\varepsilon) \leq 4\exp\left[-\frac{n\varepsilon^2}{4K^2}\right] + 2P(2K\sqrt{\frac{\log N}{n}} > \varepsilon)$$

Entonces el primer sumando converge a 0 y si tenemos que $P(2K\sqrt{\frac{\log N}{n}} > \varepsilon)$ es decir si $\frac{\log N}{n} \xrightarrow{p} 0$ tendríamos que $\|P_n - P\|_{\mathcal{G}} \xrightarrow{p} 0$.

Definición 5.1: G se dice una cápsula o envelope de una clase $\mathcal{G}$, si $G(x) = \sup_{g\in\mathcal{G}} |g(x)|$ para $x \in \chi$

Definición 5.2 : El número de cubrimiento $N(\varepsilon, \mathcal{G}, \|\cdot\|)$ es el mínimo número de bolas de radio ε necesarias para cubrir $\mathcal{G}$. No hace falta que los centros de las bolas pertenezcan a $\mathcal{G}$, al $\log N(\varepsilon, \mathcal{G}, \|\cdot\|)$ se lo llama entropía de $\mathcal{G}$.

Notación 5.1 : Llamanos $\|f\|_{r,Q} = \int f^r \, dQ$.

Teorema 5.2: Sean $X_1, \ldots, X_n$ i.i.d $X_i \sim P$ y P_n la medida empírica asociada. Sea $\mathcal{F}$ una clase de funciones con cápsula F, $\|F\|_\infty < \infty$. Si para todo $\varepsilon > 0$ tenemos que $\log N(\varepsilon, \mathcal{F}, \|\cdot\|_{1,P_n}) = o_p(n)$ entonces

$$\|P_n - P\|_{\mathcal{F}} \xrightarrow{a.s.} 0$$

Demostración: Antes probamos la convergencia en probabilidad, $\|P_n - P\|_{\mathcal{F}} \xrightarrow{p} 0$, la demostración completa puede verse en Pollard (1986).□

Observación : Se puede relajar la hipótesis de $\|F\|_\infty < \infty$ por $PF < \infty$.

Notar que para obtener el teorema anterior necesitamos que $\log N(\varepsilon, \mathcal{F}, \|\cdot\|_{1,P_n}) = o_p(n)$ es decir, $\frac{1}{n}\log N(\varepsilon, \mathcal{F}, \|\cdot\|_{1,P_n}) \xrightarrow{p} 0$. Entonces de alguna manera bastára ver que

$$N(\varepsilon, \mathcal{F}, \|\cdot\|_{1,P_n}) \leq e^{-n\,K}.$$

Teorema 5.3: Sean $X_1, \ldots, X_n$ i.i.d $X_i \sim P$. Si $\sup_Q N(\varepsilon\|\cdot\|_{1,Q}, \mathcal{F}, \|\cdot\|_{1,Q}) < \infty$ y $PF < \infty$ donde F es la cápsula de $\mathcal{F}$ entonces $\mathcal{F}$ es P-Glivenko-Cantelli.

5.1 Clases Vapnik - Chervonenkis de conjuntos

Una forma de obtener cotas para el número de cubrimiento, es a través de argumentos combinatorios, conocidos como métodos VC. Para entender mejor el porque podría ser útil usar estos argumentos veamos como desmostrar el Teorma de Glivenko- Cantelli en su versión más sencilla. Es decir, veamos

$$\|F_n - F\|_\infty = \sup_x |F_n(x) - F(x)| \xrightarrow{a.s.} 0$$

en el contexto de clase deberíamos probar que si $\mathcal{F} = \{(-\infty, t] : t \in I\!R\}$ entonces tenemos que $\sup_{f\in\mathcal{F}} |P_n f - Pf| \xrightarrow{a.s.} 0$. Probemos esto en varias etapas.

1/ En primer lugar sea $Y_i = I_{(-\infty,t]}(X_i)$ entonces $E(Y_i) = P(-\infty, t]$ y $V(Y_i) = P(-\infty, t] - P^2(-\infty, t]$ entonces usando la desigualdad de Chebyshev tenemos que

$$P(|P_n(-\infty, t] - P(-\infty, t]| \leq \frac{\varepsilon}{2}) \geq \frac{1}{2}$$

si $n \geq 8\varepsilon^{-2}$. Luego podemos usar la simetrización para probabilidades. Es decir,

$$P(\sup_{t\in I\!R} |P_n(-\infty, t] - P(-\infty, t]| > \varepsilon) \leq 2P(\sup_{t\in I\!R} |P_n(-\infty, t] - P'_n(-\infty, t]| > \frac{\varepsilon}{2})$$

si $n \geq 8\varepsilon^{-2}$.

2/ Entonces tenemos las $X_i,\ 1 \leq i \leq n$ y $X_i,\ 1 \leq i \leq n$ y $P_n(-\infty, t] - P'_n(-\infty, t]$ dependen de $I_{(-\infty,t]}(X_i) - I_{(-\infty,t]}(X'_i)$ Ahora recurrimos al otro lema de simetrización, entonces sean σ_i variables de Rademacher es decir, $P(\sigma_i = 1) = P(\sigma_i = -1) = \frac{1}{2}$ independientes. Consideremos las variables $\sigma_i[I_{(-\infty,t]}(X_i) - I_{(-\infty,t]}(X'_i)]$ estas variables son simétricas y tiene la misma distribución que $I_{(-\infty,t]}(X_i) - I_{(-\infty,t]}(X'_i)$ entonces

$$\begin{aligned}
P(\sup_{t\in I\!R} |P_n(-\infty, t] - P'_n(-\infty, t]| > \frac{\varepsilon}{2}) &= P(\sup_{t\in I\!R} |n^{-1}\sum_{i=1}^n \sigma_i[I_{(-\infty,t]}(X_i) - I_{(-\infty,t]}(X'_i)]| > \frac{\varepsilon}{2}) \\
&\leq P(\sup_{t\in I\!R} |n^{-1}\sum_{i=1}^n \sigma_i I_{(-\infty,t]}(X_i)| > \frac{\varepsilon}{4}) \\
&+ P(\sup_{t\in I\!R} |n^{-1}\sum_{i=1}^n \sigma_i I_{(-\infty,t]}(X'_i)| > \frac{\varepsilon}{4}) \\
&\leq 2P(\sup_{t\in I\!R} |n^{-1}\sum_{i=1}^n \sigma_i I_{(-\infty,t]}(X_i)| > \frac{\varepsilon}{4})
\end{aligned}$$

Luego si P_n^σ es la medida empírica de las variables $\sigma_i I_{(-\infty,t]}(X_i)$ entonces tenemos que

$$P(\sup_{t\in I\!R} |P_n(-\infty, t] - P(-\infty, t]| > \varepsilon) \leq 4P(\sup_{t\in I\!R} |P_n^\sigma(-\infty, t]| > \frac{\varepsilon}{4})$$

si $n \geq 8\varepsilon^{-2}$.

3/ Ahora viene la gracia de todo esto. Lo importante ahora es ver que es el $\sup_{t\in I\!R} |P_n^\sigma(-\infty, t]|$. El chiste esta en pensar la probabilidad condicionada a las X_i entonces el supremo en t toma distintos valores solo para unos pocos t's, basta tomar t_j con $0 \leq j \leq n$, donde t_j este entre

cada par de observaciones X's adyacentes. Es decir si tomamos los intervalos $I_j = (-\infty, t_j]$ para $0, \ldots, n$ donde cada t_j esta entre dos X's entonces $P_n^\sigma(-\infty, t]$ solo toma a lo sumo $n+1$ valores distintos. Entonces,

$$P(\sup_{t\in I\!R} |P_n^\sigma(-\infty,t]| > \frac{\varepsilon}{4}|X) \leq \sum_{j=0}^{n} P(|P_n^\sigma(-\infty,t_j]| > \frac{\varepsilon}{4}|X) \leq (n+1) \max_{0\leq j\leq n} P(|P_n^\sigma(-\infty,t_j]| > \frac{\varepsilon}{4}|X)$$

y lo importante es que esta probabilidad decrese exponencialmente usando la desigualdad de Hoeffding.

$$\begin{aligned} P(|P_n^\sigma(-\infty,t_j]| > \frac{\varepsilon}{4}|X) &\leq 2\exp\left[-2\frac{(n\varepsilon/4)^2}{\sum_{i=1}^n 4I_{(-\infty,t_j]}(X_i)}\right] \\ &\leq 2\exp(-n\varepsilon^2/32) \end{aligned}$$

entonces

$$P(\sup_{t\in I\!R} |P_n^\sigma(-\infty,t]| > \frac{\varepsilon}{4}|X) \leq 2(n+1)\exp(-n\varepsilon^2/32)$$

que no depende de X y luego tenemos que

$$P(\sup_{t\in I\!R} |P_n(-\infty,t] - P(-\infty,t]| > \varepsilon) \leq 8(n+1)\exp(-n\varepsilon^2/32)$$

y por Borel-Cantelli tenemos que $\sum_{i=1}^n P(\sup_{t\in I\!R} |P_n(-\infty,t] - P(-\infty,t]| > \varepsilon) < \infty \square$

Lo importante en esta demostración fue el hecho de que finalmente el supremo no tomaba muchos valores, es decir la clase de funciones en definitiva no distinguio muchos conjuntos. Motivados por esto entonces tenemos las siguientes definiciones.

Sea $\mathcal{C}$ una familia de conjuntos en χ y supongamos que tenemos un conjunto finito $F = \{x_1, \cdots, x_n\} \subset \chi$. Consideremos la clase $F_\mathcal{C} = \{C \cap F \ : C \in \mathcal{C}\}$. Si $F_\mathcal{C} = \mathcal{P}(\mathcal{F})$ entonces se dice que $\mathcal{C}$ shattea F. Llamemos $\Delta(\mathcal{C}; F)$ el número de subconjuntos distintos obtenidos como intersección de F con subconjuntos $\mathcal{C}$, es decir $\Delta(\mathcal{C}; F) = \#F_\mathcal{C}$. Entonces $\Delta(\mathcal{C}; F) \leq 2^n$. Y si $\mathcal{C}$ shattea F se tiene que $\Delta(\mathcal{C}; F) = 2^n$. Llamemos $m^\mathcal{C}(n) = \sup_{F\subset\chi\ \#F=n} \Delta(\mathcal{C}; F)$.

Para lo que nosotros necesitamos solo alcanza con saber acotar $\Delta(\mathcal{C}; F)$. Ejemplo fácil, si $\chi = I\!R$ y $\mathcal{C} = \{(-\infty, t] : t \in I\!R\}$ entonces $\Delta(\mathcal{C}; \{x_1, \ldots, x_n\}) \leq n+1$.

Teorema 5.1.1: (Vapnik-Chervonenkis (1971)). $\mathcal{C}$ una clase de conjuntos,

$$\frac{1}{n}\log\Delta(\mathcal{C}; \{X_1, \ldots, X_n\}) \xrightarrow{p} 0$$

si y solo si

$$\|P_n - P\|_\mathcal{C} \xrightarrow{a.s.} 0$$

demostración : (veamos solo una implicación)

Sea $\mathcal{F} = \{1_C : C \in \mathcal{C}\}$, estas funciones están uniformemente acotadas. Por otro lado, si $\|g - g'\|_{\infty,P_n} = \max_{1\leq i\leq n} |g(X_i) - g'(X_i)|$ como, $\|g - g\|_{1,P_n} \leq \|g - g'\|_{\infty,P_n}$ entonces

tenemos que $N(\varepsilon, \mathcal{F}, \|\cdot\|_{1,P_n}) \leq N(\varepsilon, \mathcal{F}, \|\cdot\|_{\infty,P_n})$. Pero si $0 < \varepsilon < 1$, $N(\varepsilon, \mathcal{F}, \|\cdot\|_{\infty,P_n}) = \Delta(\mathcal{C}, \{X_1, \ldots, X_n\})$, es decir puedo cubrir a $\mathcal{F}$ con tantos subconjuntos distintos hay en $F_{\mathcal{C}}$, pues si $F \cap C \neq F \cap C_j$ entonces $\|I_{\mathcal{C}} - I_{\mathcal{C}_j}\| = 1$.

Entonces $\frac{1}{n} \log N(\varepsilon, \mathcal{F}, \|\cdot\|_{1,P_n}) \leq \frac{1}{n} \log \Delta(\mathcal{C}; \{X_1, \ldots, X_n\}) \xrightarrow{p} 0$. $\square$

Definición 5.1.1: Decimos que una clase $\mathcal{D}$ es Vapnik-Chervonenkis (VC) si existen constantes c y V tales que para todo n, $m^{\mathcal{D}}(n) \leq c\, n^V$. Es decir si $m^{\mathcal{D}}(n)$ crece no más rápido que polinomialmente en n; por eso se le dice una clase de discriminación polinomial.

Ejemplos:

- $\star$ $\chi = I\!R$ y $\mathcal{C} = \{(-\infty, t] : t \in I\!R\}$, $m^{\mathcal{C}}(n) \leq (n+1)$
- $\star$ $\chi = I\!R^d$ y $\mathcal{C} = \{(-\infty, t] : t \in I\!R^d\}$, $m^{\mathcal{C}}(n) \leq (n+1)^d$
- $\star$ $\chi = I\!R$ y $\mathcal{C} = \{\{x : \theta^T x > t\} : t \in I\!R, \theta \in I\!R^d\}$, $m^{\mathcal{C}}(n) \leq 2^d \binom{n}{d}$

Las clases de conjuntos VC son cerradas bajo ciertas operaciones. Por ejemplo, si $\mathcal{C}$ y $\mathcal{D}$ son clases VC de conjuntos entonces las siguientes operaciones se preservan:

- $\star$ Si $\mathcal{C}' \subset \mathcal{C}$ entonces $\mathcal{C}'$ es VC.
- $\star$ $\mathcal{C}^c = \{C^c : \ C \in \mathcal{C}\}$ es VC.
- $\star$ $\mathcal{C} \cap \mathcal{D} = \{C \cap D : \ C \in \mathcal{C} \ D \in \mathcal{D}\}$ es VC.
- $\star$ $\mathcal{C} \cup \mathcal{D} = \{C \cup D : \ C \in \mathcal{C} \ D \in \mathcal{D}\}$ es VC.
- $\star$ $\phi(\mathcal{C})$ con ϕ biyectiva es VC.
- $\star$ $\Psi^{-1}(\mathcal{C})$ es VC.
- $\star$ $\overline{\{I_C(x) C \in \mathcal{C}\}}$ es VC.
- $\star$ $\mathcal{C} \times \mathcal{D}$ es VC.

Algunos ejemplos de clases VC son la clase de intersección de dos semiespacios, los elipsoides, los medio elipsoides, en $I\!R$ la clase $\{\{x : \theta_1 x + \ldots + \theta_r x^r\} : t \in I\!R, \theta \in I\!R^d\}$, etc. Hay clases que si bien no son VC si son Glivenko-Cantelli, por ejemplo si $\chi = [0,1]^2$ y $\mathcal{D}$ es la collección de todos los subconjuntos convexos de χ, $\mathcal{D}$ no es VC pero si es Glivenko-Cantelli.

Definición 5.1.2: El VC-index o la dimensión VC ($V(\mathcal{C})$), es el menor n para el cual existe un conjunto $F = \{x_1, \cdots, x_n\}$ tal que $\mathcal{C}$ no shattea a F es decir,

$$V(C) = \begin{cases} \inf \left\{ n : m^{\mathcal{C}}(n) < 2^n \right\} \\ \infty \qquad \text{en caso de no existir tal n.} \end{cases}$$

En algunos lados se dice que una clase $\mathcal{C}$ es una clase VC si $V(\mathcal{C}) < \infty$, es decir si existe $k < \infty$ tal que $\mathcal{C}$ no es shatteado por ningún subconjunto de $\mathcal{C}$ de cardinal k. Se puede probar que las dos definiciones coinciden. Más aún, $m^{\mathcal{C}}(n) \leq \sum_{i=1}^{V(\mathcal{C})} \binom{n}{i}$.

En alguna bibliografía se define la dimensión VC como $\max\Big\{n : \sup_{F\subset\chi\ \#F=n} \Delta(\mathcal{C};F) = 2^n\Big\}$ que es uno menos la definición la anterior.

Teorema 5.1.2 : Sea $\mathcal{C}$ una clase VC de conjuntos con dimensión $V(\mathcal{C})$, $r \geq 1$ y $0 < \varepsilon < 1$ entonces

$$N(\varepsilon, \mathcal{C}, \|\cdot\|_{r,Q}) \leq KV(\mathcal{C})(4e)^{V(\mathcal{C})}\left(\frac{1}{\varepsilon}\right)^{r(V(\mathcal{C})-1)}$$

Demostración: van der Vaart y Wellner (1996), página 136.

5.2 Clases Vapnik - Chervonenkis de funciones

Sea $\mathcal{F}$ una familia de funciones $f : \chi \to I\!R$ llamamos subgráficos de $f \in \mathcal{F}$ al conjunto $sub(f) = \{(x,t) : t < f(x)\}$. $\mathcal{F}$ se dice una clase VC de funciones si la familia de subgráficos $\mathcal{C} = \{sub(f) : \ f \in \mathcal{F}\}$ de $\mathcal{F}$ es VC de conjuntos. Y la dimensión VC de $\mathcal{F}$, $(V(\mathcal{F}))$, es la dimensión VC de $\mathcal{C}$.

Ejemplos: $\chi = I\!R^d$

- ⋆ $\{g(x) = \theta_0 + \theta_1 x_1 + \ldots + \theta_r x_r : \theta \in I\!R^{d+1}\}$
- ⋆ $\{g(x) = |\theta_0 + \theta_1 x_1 + \ldots + \theta_r x_r| : \theta \in I\!R^{d+1}\}$
- ⋆ $d = 1$, $\{g(x) = (\theta_0 + \theta_1 x) * (x \leq \theta_4) + (\theta_2 + \theta_3 x) * (x > \theta_4) : \theta \in I\!R^5\}$
- ⋆ $d = 1$, $\{g(x) = \exp(\theta x) : \theta \in I\!R\}$
- ⋆ $\mathcal{F} = \{\sum_{i=1}^p a_i f_i \ \ a_i \in I\!R\}$ tiene dimensión VC $\leq p + 2$

Lo mismo que para clases VC de conjuntos, si $\mathcal{F}$ y $\mathcal{G}$ son clases VC de funciones entonces las siguientes operaciones se preservan:

- ⋆ $\mathcal{F} \vee \mathcal{G} = \{f \vee g : \ f \in \mathcal{F}\ g \in \mathcal{G}\}$ es VC
- ⋆ $\mathcal{F} \wedge \mathcal{G} = \{f \wedge g : \ f \in \mathcal{F}\ g \in \mathcal{G}\}$ es VC
- ⋆ $\mathcal{F} > 0 = \{f > 0 : \ f \in \mathcal{F}\}$ es VC
- ⋆ $-\mathcal{F}$ es VC
- ⋆ $\mathcal{F} + g = \{f + g : \ f \in \mathcal{F}\}$ es VC
- ⋆ $\mathcal{F}g = \{fg : \ f \in \mathcal{F}\}$ es VC
- ⋆ $\mathcal{F} \circ g = \{f \circ g : \ f \in \mathcal{F}\}$ es VC
- ⋆ $g \circ \mathcal{F} = \{g \circ f : \ f \in \mathcal{F}\}$ con g monótona es VC
- ⋆ $\Psi : I\!R \to I\!R$ monótona entonces el conjunto $\{\Psi(x - h) : \ h \in I\!R\}$, el índice VC$= 2$

Teorema 5.2.1: Sea $\mathcal{F}$ una clase VC de funciones con cápsula F si $r \geq 1$ $\|F\|_{Q,r} > 0$ y $0 < \varepsilon < 1$ entonces

$$N(\varepsilon\|F\|_{Q,r}, \mathcal{F}, \|\cdot\|_{r,Q}) \leq KV(\mathcal{F})(16e)^{V(\mathcal{F})}\left(\frac{1}{\varepsilon}\right)^{r(V(\mathcal{F})-1)}$$

Demostración: van der Vaart y Wellner (1996), página 141.

Otra propiedad útil

Si $\mathcal{F}_1, \ldots, \mathcal{F}_k$ son clases GC de funciones con $f_i : \chi \to I\!R$, y $\varphi : I\!R^k \to I\!R$ es una función continua entonces la clase de funciones $\mathcal{H}$ donde

$$\mathcal{H} = \varphi(\mathcal{F}_1, \ldots \mathcal{F}_k) = \{\varphi(f_1, \ldots, f_k) : f_i \in \mathcal{F}_i \; 1 \leq i \leq k\}$$

resulta también GC. Ver van der Vaart y Wellner(2000) página 117-120.

6 Aplicaciones I

6.1 Desviación respecto de la media.

6.1.1 L^1 en $I\!R$

Supongamos que tenemos $X_1, \ldots, X_n$ variables i.i.d con distribución F y correspondiente medida de probabilidad P. Supongamos que $E|X_1| < \infty$. Y sea

$$V_n = \frac{1}{n}\sum_{i=1}^{n} |X_i - \overline{X_n}|$$

La pregunta es $V_n \xrightarrow{a.s.} v$ para alguna constante v? se puede identificar v?. La ley fuerte de los grandes números en principio no es inmediatamente aplicable pues $|X_1 - \overline{X_n}|, \ldots, |X_n - \overline{X_n}|$ son dependientes y V_m tiene un doble limite . Pero intentemos adivinar cual debería ser el limite. Por la ley de los grandes números tenemos que

$$\frac{1}{n}\sum_{i=1}^{n} |X_i - \mu| \xrightarrow{a.s.} E(|X - \mu|)$$

y $\overline{X}_n \xrightarrow{a.s.} \mu$ entonces sería natural preguntarse si $V_n \xrightarrow{a.s.} v = E(|X - \mu|)$

Sean $f_t(x) = |x - t|$, $H_n(t) = P_n f_t$ y $H(t) = Pf_t = \int |x - t| dP$; entonces $V_n = H_n(\overline{X}_n)$ y $v = H(\mu)$. Notar que si probamos que $\sup_t |H_n(t) - H(t)| \xrightarrow{a.s.} 0$, como H es continua y $\overline{X}_n \xrightarrow{a.s.} \mu$ entonces ya estaría pues;

$$\begin{aligned} |V_n - v| &= |H_n(\overline{X}_n) - H(\overline{X}_n) + H(\overline{X}_n) - H(\mu)| \\ &\leq |H_n(\overline{X}_n) - H(\overline{X}_n)| + |H(\overline{X}_n) - H(\mu)| \\ &\leq \sup_{f_t \in \mathcal{F}} |P_n f_t - Pf_t| + |H(\overline{X}_n) - H(\mu)| \xrightarrow{a.s.} 0 \end{aligned} \tag{1}$$

Entonces, si $\mathcal{F} = \{f_t : |t - \mu| \leq 1\}$, la cápsula de $\mathcal{F}$ es $F(x) = |x - \mu| + 1$ y $E(F) < \infty$. Ademas, veamos que $\mathcal{F}$ es VC.

Quién es $sub(f_t)$?

$sub(f_t) = \{(x,k) : k < |x-t|\} = \{\{k < x-t\} \cap \{x > t\}\} \cup \{\{x-t < -k\} \cap \{x < t\}\} = \{x > k+t\} \cup \{x < t-k\}$ entonces como las semirectas son VC, usando que los complementos de VC son VC y las uniones tambien se preservan. Tenemos que $sub(f_t)$ es VC, luego la clase $\{f_t : t \in I\!R\}$ es VC y $\mathcal{F} \subset \{f_t : t \in I\!R\}$ entonces $\mathcal{F}$ es VC y por lo tanto GC, entonces

$$\sup_{f_t \in \mathcal{F}} |P_n f_t - P f_t| \xrightarrow{a.s.} 0.$$

6.1.2 L^p en $I\!R$

Si en lugar de tener V_n tenemos $V_n(p) = \frac{1}{n}\sum_{i=1}^n |X_i - \overline{X_n}|^p$, todo sería igual, tenemos que considerar otra clase $\mathcal{G} = \{f_{t,p} = |x-t|^p : |t-\mu| \leq 1\}$ de funciones que resulta $\mathcal{G} = \phi(\mathcal{F})$ donde $\phi(x) = |x|^p$. Esta clase también resultará VC, por ser compocisión con un función biyectiva y tendrá cápsula con esperanza finita. Ahora en (1), se tiene igual que antes que

$$|V_n(p) - V(p)| \leq \sup_{f_t \in \mathcal{F}} |P_n f_{t,p} - P f_{t,p}| + P(||X - \overline{X}_n|^p - |X-\mu|^p|) \xrightarrow{a.s.} 0$$

Acá hay que usar para el segundo sumando el Teorema de convergencia dominada. ($\overline{X}_n \xrightarrow{a.s.} \mu$ y $E|X|^p < \infty$)

6.1.3 L^q en $I\!R^d$

Y en el caso de tener $V_n(p,q) = \frac{1}{n}\sum_{i=1}^n \|X_i - \overline{X_n}\|_q^p$, tomemos la clase de funciones $\mathcal{G} = \{\|x-t\|_q^p : \|t-\mu\|_q \leq 1\}$ esta clase resulta también GC ya que si consideramos

$$\varphi(y_1, \ldots, y_d) = \{y_1^q + \ldots + y_2^q\}^{p/q}$$

esta función es continua y sea la clase $\mathcal{G} = \varphi(\mathcal{F}_1, \ldots, \mathcal{F}_d)$ donde $\mathcal{F}_i = \{(x,t) \to x_i - t_i : \|t-\mu\|_q \leq 1\}$. Ahora estas clase $\mathcal{F}_i$ resultan VC ya que si consideremos una clase de funciones en $I\!R$, $\mathcal{F}$ una clase VC y tomamos la clase $\pi_i\mathcal{F} = \{x \to f \circ \pi_i(x) = f(x_i) : \text{ con } f \in \mathcal{F} \text{ y } x \in I\!R\}$ pues $sub(\pi_i\mathcal{F}) = sub(f) \times I\!R^{k-1}$, entonces como $sub(f)$ es VC y la clase que tiene un solo conjunto también es VC tenemos que $\pi_i\mathcal{F}$ es VC.

Finalmente $\mathcal{G}$ resulta GC.

6.2 k-medias.

El método de k-medias es un método que sirve para particionar el espacio en clusters. Por ejemplo, dados $x_1, \ldots, x_n \in I\!R^d$ realizaciones de n variables $\{X_i\}_{1 \leq i \leq n} \sim P$. La idea es elegir los k mejores puntos $a_{1n}, \ldots, a_{kn}$ estos k puntos nos van dar una partición de $I\!R^d$ de acuerdo a la cercanía a ellos. El método consiste en elegir los puntos de manera que minimicen la suma de los cuadrados en cada grupo, es decir, $a_{1n}, \ldots, a_{kn}$ de forma tal que minimicen, $\sum_{i=1}^n \min\{|X_i - a_1|^2|, \ldots, |X_i - a_k|^2\}$ sobre todas las k- uplas $a_1, \ldots, a_k$ con $a_i \in I\!R^d$.

Sea P_n la medida empírica basada en $\{X_i\}_{1\leq i\leq n}$ y sea $a_i \in I\!R^d$ con $1 \leq i \leq k$ entonces si consideramos

$$W(a_1, \ldots, a_k; P) = P \min\{|x - a_1|^2|, \ldots, |x - a_k|^2\}$$

luego

$$(a_{1n}, \ldots, a_{kn}) = \arg \min_{a_1,\ldots,a_k} W(a_1, \ldots, a_k; P_n).$$

Supongamos que $P|X|^2 < \infty$ y exite un único mínimo (a^*, b^*). La idea es la siguiente, como para cada $(a, b) \in I\!R^2$

$$W(a, b; P_n) = P_n(f_{a,b}) = \frac{1}{n}\sum_{i=1}^{n} f_{a,b}(X_i) \xrightarrow{a.s.} P(f_{a,b}) = W(a, b; P) \tag{2}$$

y tenemos que

$$(a^*, b^*) = arg \min_{a,b} W(a, b; P) \tag{3}$$

y

$$(a_n, b_n) = arg \min_{a,b} W(a, b; P_n). \tag{4}$$

Entonces de (2) a (4) uno esperaría que $(a_n, b_n) \xrightarrow{a.s.} (a^*, b^*)$

En lo que sigue solo consideraremos el caso en el que $d = 1$ y $k = 2$. Ahora tomemos la clase de funciones $\mathcal{F} := \{f_{a,b} : (a, b) \in C_M\}$ donde $f_{a,b}(x) := \min\{|x - a|^2, |x - b|^2\}$, $x \in I\!R$, y $C_M := ([-M, M] \times I\!R) \cup (I\!R \times [-M, M])$, con $M > 0$ elegido de manera tal que me garantize que a partir de un momento $(a_n, b_n) \in C_M$. La idea es tomar a M de la siguiente manera. Como

$$W(a_n, b_n; P_n) \leq W(0, 0; P_n) \to W(0, 0; P) = P|X|^2.$$

Por otro lado si $(a, b) \in C_M^c$ entonces

$$\begin{aligned} W(a_n, b_n; P_n) &\geq P(\min\{|X - a_n|^2|, |X - b_n|^2\} I_{[-M/2,M/2]}(X)) \\ &\geq \left(\frac{M}{2}\right)^2 P_n\left[-\frac{M}{2}, \frac{M}{2}\right] \to \left(\frac{M}{2}\right)^2 P\left[-\frac{M}{2}, \frac{M}{2}\right] \end{aligned}$$

Elijamos M tal que

$$\left(\frac{M}{2}\right)^2 P\left[-\frac{M}{2}, \frac{M}{2}\right] > P|X|^2 = W(0, 0, P).$$

Por otro lado notemos que

$$Pf_{a,b}(X) \leq F(x) = (x - M)^2 + (x + M)^2$$

si a y b están en C_M. Sdemás la clase de funciones $\mathcal{F}$ es VC, esto se puede ver porque la clase $|x - a|^2$ es VC y $\mathcal{F}$ es mínimos de dos de estas clases. Por lo tanto tenemos que

$$\sup_{\mathcal{F}} |P_n f_{a,b} - Pf_{a,b}| = \sup_{(a,b)\in C_M} |W(a, b; P_n) - W(a, b; P)| \xrightarrow{a.s.} 0.$$

Veamos primero que $(a_n, b_n) \in C_M$ entonces $W(a_n, b_n; P) \xrightarrow{a.s.} W(a^*, b^*; P)$ para esto; primero tenemos que $W(a^*, b^*; P) \leq W(a_n, b_n; P)$ luego $W(a^*, b^*; P) \leq \lim_{n\to\infty} W(a_n, b_n; P)$. Por otro lado

$$\begin{aligned}
W(a_n, b_n; P) &= W(a_n, b_n; P) - W(a_n, b_n; P_n) + W(a_n, b_n; P_n) \\
&\leq \sup_{C_M} |W(a, b; P) - W(a, b; P_n)| + W(a^*, b^*; P_n) \\
&\leq \sup_{C_M} |W(a, b; P) - W(a, b; P_n)| + W(a^*, b^*; P_n) - W(a^*, b^*; P) + W(a^*, b^*; P) \\
&\leq 2 \sup_{C_M} |W(a, b; P) - W(a, b; P_n)| + W(a^*, b^*; P)
\end{aligned}$$

entonces

$$\lim_{n\to\infty} W(a_n, b_n; P) \leq \lim_{n\to\infty} W(a^*, b^*; P).$$

Ahora por otro lado obsevemos que dado U un compacto alrededeor de (a^*, b^*) tenemos que

$$\inf_{C_M \setminus U} W(a, b; P) > W(a^*, b^*; P)$$

Entonces podemos suponer que $(a_n, b_n) \in U \subset C_M$ y supongamos que $(a_n, b_n) \xrightarrow{a.s.} (a', b')$ tenememos que como

$$W(a_n, b_n; P_n) - W(a_n, b_n; P) \xrightarrow{a.s.} 0$$

y

$$W(a_n, b_n; P) - W(a', b'; P) \xrightarrow{a.s.} 0$$

tenemos que $W(a_n, b_n; P_n) - W(a', b'; P) \xrightarrow{a.s.} 0$, pero además $W(a_n, b_n; P_n) \leq W(a_n, b_n; P)$ y habíamos supuesto que W tenía un solo mínimo. Entonces $(a^*, b^*) = (a', b')$

6.3 M-estimadores y Z-estimadores

Un ejemplo clásico de M-estimadores o Z- estimadores puede ser hallar un estimador robusto para el parámetro de posición es decir, si tenemos un modelo dado por $X_i = \mu + \varepsilon_i$ con ε_i variables i.i.d con esperanza 0 como hacemos si queremos estimar μ. La idea seía entonces que como μ satisface $\mu = \arg\max_a E(\rho_k^H(X-a)) = \arg\max_a P(\rho_k^H(X-a))$ es dedir tenemos lo que se conoce como Fisher consistencia donde

$$\rho_k^H(u) = \begin{cases} -ku - k^2/2 & \text{si} \quad u < -k \\ u^2/2 & \text{si} \quad |u| \leq k \\ ku - k^2/2 & \text{si} \quad u > k \end{cases}.$$

Una propuesta sería proponer como estimador $\widehat{\mu} = \arg\max_{a\in I\!R} \sum_{i=1}^n \rho_k^H(x-a)$. O lo que es lo mismo $\widehat{\mu}$ tal que $\sum_{i=1}^n \Psi_k^H(x - \widehat{\mu}) = 0$ donde

$$\Psi_k^H(x-a) = 2kI\{x - a \leq k\} - 2(x-a)I(|x-a| \leq k) - 2kI(x - a > k).$$

Supongamos que tenemos $X_1, \ldots, X_n$ variables i.i.d con medida de probabilidad P. Sea Θ un espacio métrico de parámetros, para todo $\theta \in \Theta$ consideremos $m_\theta : \chi \to I\!R$ una función medible. Sea θ_0 el punto máximo de Pm_θ, la idea es estimar θ_0 a partir de un M-estimador es decir

$$\theta_n = arg \max P_n m_\theta.$$

Nosotros supondremos que θ_0 existe y es único y que θ_n existe.

Teorema 6.3.1: Supongamos que la clase de funciones $\{m_\theta : \theta \in \Theta\}$ es Glivenko - Cantelli y que existe $\theta_0 \in \Theta$ tal que $\inf_{\{\theta: d(\theta_0,\theta)>\delta\}} Pm_\theta < Pm_{\theta_0}$ para todo $\delta > 0$. Luego $P_n m_{\theta_n} > P_n m_{\theta_0}$ implica que $d(\theta_n;\theta_0) \xrightarrow{a.s.} 0$.

Demostración: Veamos primero que $Pm_{\theta_n} - Pm_{\theta_0} \xrightarrow{a.s.} 0$

$$\begin{aligned} 0 &\leq Pm_{\theta_0} - Pm_{\theta_n} = [Pm_{\theta_0} - Pm_{\theta_n}] - [P_n m_{\theta_0} - P_n m_{\theta_n}] + [P_n m_{\theta_0} - P_n m_{\theta_n}] \\ &\leq [Pm_{\theta_0} - P_n m_{\theta_0}] - [Pm_{\theta_n} - P_n m_{\theta_n}] + [P_n m_{\theta_0} - P_n m_{\theta_n}] \\ &\leq 2\sup_{\theta\in\Theta} |Pm_\theta - P_n m_\theta| \xrightarrow{a.s.} 0 \end{aligned}$$

Entonces por hipótesis dado $\delta > 0$ existe $\eta > 0$ tal que $Pm_\theta < Pm_{\theta_0} - \eta$ para todo $d(\theta_0,\theta) > \delta$ entonces $\{d(\theta_n;\theta_0) > \delta\} \subset \{Pm_{\theta_n} < Pm_{\theta_0} - \eta\}$. Y esta última sucesión converge a 0, luego $d(\theta_n;\theta_0) \xrightarrow{a.s.} 0$. $\square$

Supongamos que tenemos $X_1, \ldots, X_n$ variables i.i.d con medida de probabilidad P. Para cada $\theta \in \Theta \in I\!R^k$ consideremos $\Phi_\theta : \chi \to I\!R^k$ una función medible. Un Z-estimador θ_n es un cero de $P_n\Psi_\theta$. El objetivo es mostrar que θ_n converge en probabilidad al θ_0 el cero de $P\Psi_\theta$.

Teorema 6.3.2: Supongamos que la clase de funciones $\{\Psi_\theta : \theta \in \Theta\}$ es P-Glivenko - Cantelli y que existe un punto $\theta_0 \in \Theta$ tal que $\inf_{\theta: d(\theta;\theta_0)>\delta} P\Psi_\theta > 0 = P\Psi_{\theta_0}$ para cada $\delta > 0$. Entonces $P_n\Psi_{\theta_n} = 0$ implica que $d(\theta_n;\theta_0) \xrightarrow{a.s.} 0$

Demostración: Notar que el problema es igual que antes pensando que se maximice $-\|P\Psi_{\theta_n}\|$.

Notar que la segunda hipótesis en ambos teoremas no involucra aleatoridad simplemente propiedades de la función m_θ en su punto máximo θ_0. La dificultad de aplicar el teorema reside en el hecho que el supremo es sobre todo $\theta \in \Theta$. Acá es donde entrara en juegos las clases VC.

Por ejemplo en el caso de la función de Huber $\Psi_k^H(x-a) = 2kI\{x-a \leq k\} - 2(x-a)I(|x-a| \leq k) - 2kI(x-a > k)$ para $x \in I\!R$. Se puede probar que esta clase de funciones es VC más aún tiene índice VC igual a 2 y la cápsula $\leq 2k$

6.4 Estimador noparamétrico de Máxima verosimilitud

Sea $\mathcal{P}$ un clase de densidadescon respecto a una medida μ, en un espacio $(\chi, \mathcal{A})$, y sean $X_1, \ldots, X_n \sim P_0$ con respecto a una densidad $p_0 \in \mathcal{P}$. Consideremos el estimador, $\widehat{p}_n = \arg\max P_n \log p$. Sea la distancia de Hellinger

$$h^2(p,q) = \frac{1}{2}\int \{\sqrt{p} - \sqrt{q}\}^2 d\mu = 1 - \int \sqrt{pq}\, d\mu$$

entonces notemos que

$$\begin{aligned} 0 &\leq \frac{1}{2}\int \log\left(\frac{\widehat{p}_n}{p_0}\right) dP_n \\ &\leq \int \left(\sqrt{\frac{\widehat{p}_n}{p_0}} - 1\right) dP_n \quad \text{tomando } \log(x+1) \leq x \end{aligned}$$

$$
\begin{aligned}
&\leq \int \left(\sqrt{\frac{\widehat{p}_n}{p_0}} - 1\right) d(P_n - P_0) + \int \left(\sqrt{\frac{\widehat{p}_n}{p_0}} - 1\right) dP_0 \\
&\leq \int \left(\sqrt{\frac{\widehat{p}_n}{p_0}} - 1\right) d(P_n - P_0) - h^2(\widehat{p}_n, p_0).
\end{aligned}
$$

Entonces

$$
h^2(\widehat{p}_n, p_0) \leq (P_n - P_0)\left(\sqrt{\frac{\widehat{p}_n}{p_0}} - 1\right)
$$

si $\mathcal{F} = \{\left(\sqrt{\frac{p}{p_0}} - 1\right) : \ p \in \mathcal{P}\}$ es P_0-Glivenko-Cantelli, tenemos que el estimador es consistente respecto a la distancia de Hellinger.

7 Otras clase útiles

Hay otras clases de funciones que si bien no son VC, se les puede calcular el número de cubrimiento a continuación veremos algunos ejemplos. Y también daremos algunas definiciones de otras formas de "medir"que son similares al número de cubrimiento, que se relacionan con estos y que a veces suelen ser más faciles de calcular.

Algunas definiciones:

Definición 7.1 : Un ε-brackets $[l, u]$ es un conjunto $\{f \in \mathcal{F}$ tq $l \leq f \leq u\}$ y $\|l - u\| < \varepsilon$.

Definición 7.2 : EL número de brackets $N_{[\,]}(\varepsilon, \mathcal{F}, \|\cdot\|)$ es el mínimo número de ε-brackets necesarios para cubrir $\mathcal{F}$.

Definición 7.3 : Una colección de puntos se dice ε-separados si la distancia entre cada par de puntos es mayor que ε.

Definición 7.4 : Notamos por $D(\varepsilon, \mathcal{F}, \|\cdot\|)$ al máximo número de puntos ε-separados de $\mathcal{F}$.

Como se relacionan estos definiciones

$$
N(\varepsilon, \mathcal{F}, \|\cdot\|) \leq N_{[\,]}(2\varepsilon, \mathcal{F}, \|\cdot\|)
$$

$$
N(\varepsilon, \mathcal{F}, \|\cdot\|) \leq D(\varepsilon, \mathcal{F}, \|\cdot\|) \leq N(\frac{1}{2}\varepsilon, \mathcal{F}, \|\cdot\|)
$$

Clases VC-hull

La cápsula convexa simétrica $sconv(\mathcal{G})$ de una clase de funciones $\mathcal{G}$ es el conjunto de funciones $\sum_{i=1}^m \alpha_i f_i$ con $f_i \in \mathcal{G}$ y $\sum_{i=1}^m |\alpha_i| \leq 1$. Una clase de funciones $\mathcal{F}$ se dice VC-hull si existe una clase $\mathcal{G}$, VC tal que $\forall f \in \mathcal{F} \ \ \exists\, f_m \in sconv(\mathcal{G})$ tq $f_m \to f$ puntualmente. Es decir, $\mathcal{F} \subset \overline{sconv(\mathcal{G})}$ para $\mathcal{G}$ una clase VC.

Para esta clase de funciones también podemos acotar el número de entropía.

$$
\log\ N(\varepsilon \|F\|_{Q,2}, \mathcal{F}, L_2(Q)) \leq K\left(\frac{1}{\varepsilon}\right)^{2-2V(\mathcal{F})}
$$

Clases VC-Major

$\mathcal{F}$ se dice VC-Major si $\mathcal{C} = \{\{x : f(x) > t\}\ t \in I\!R\ \ f \in \mathcal{F}\}$ es una clase VC de conjuntos.

- ⋆ Si $\mathcal{F}$ es VC-Major acotada ($f : \chi \to [0,1]$) entonces $\mathcal{F}$ es VC-hull.
- ⋆ $\mathcal{F}$ es VC- major y h monótona entonces $h \circ \mathcal{F}$ es VC-major
- ⋆ $\mathcal{F}$ y $\mathcal{G}$ es VC- hull entonces $\mathcal{F}\ \mathcal{G}$ es VC- hull

Funciones suaves

Sea $\alpha > 0$, $C_M^\alpha(\chi) = \{f : \chi \to I\!R\ \ \|f\|_\alpha \leq M\}$ con $\chi \subset I\!R^d$ donde

$$\|f\|_\alpha = \max_{\bar{k} \leq \bar{\alpha}} \sup_x |D^k f(x)| + \max_{\bar{k} = \bar{\alpha}} \sup_{x,y} \frac{|D^k f(x) - D^k f(x)|}{\|x-y\|^{\alpha - \bar{\alpha}}}$$

con $\alpha > 0$ $k = (k_1, \ldots, k_d)$, $\bar{k} = \sum k_i$ y $\bar{\alpha}$ el entero más grande menor que α.

Si χ es convexo y acotado entonces para esta clase de funciones podemos acotar el número de brackets,

$$\log\ (N[\,](\varepsilon, C_M^\alpha(\chi), \|\cdot\|_{r,Q}) \leq K \left(\frac{1}{\varepsilon}\right)^{\frac{d}{\alpha}}$$

Funciones monótonas:

Si $\mathcal{F} = \{f : I\!R \to [0,1]\ \text{ monótonas}\}$ vale que

$$\log\ N_{[\,]}(\varepsilon, \mathcal{F}, \|\cdot\|_{r,Q}) \leq \frac{K}{\varepsilon}$$

para $r \geq 1$.

Funciones convexas:

Si $\mathcal{F} = \{f : C \to [0,1]\ \text{ convexas}\}$ con $C \subset I\!R^d$ convexo y acotado tal que $|f(x) - f(y)| \leq L\|x-y\| \quad \forall x, y$ entonces

$$\log\ N_{[\,]}(\varepsilon, \mathcal{F}, \|\cdot\|_\infty) \leq K(1+L)^{d/2} \frac{1}{\varepsilon^{d/2}}$$

Funciones Lipchitz en un parámetro:

Si $\mathcal{F} = \{f_t : \quad t \in T\}$ tal que

$$|f_s(x) - f_t(x)| \leq F(x) d(s,t) \quad \forall x$$

se tiene que

$$\log\ N_{[\,]}(2\varepsilon\|F\|, \mathcal{F}, \|\cdot\|) \leq \log\ N(\varepsilon, T, d)$$

8 Clases de funciones que dependen de n

En el Teorema 5.1 tenemos una condición $\log N(\varepsilon, \mathcal{F}, \|\cdot\|_{1,P_n}) = o_p(n)$ sobre el crecimiento del número de entropía. Y vimos que hay muchas clases donde esta condición puede ser satisfecha, por ejemplo en las clases con discriminación polinomial donde vimos que el número de cubrimiento puede acotarse por un polinomio en ε^{-1}. En este teorema la clase de funciones está fija, pero el método puede extenderse clases que dependen de n, siempre y cuando los números de cubrimientos no crezcan demasiado rápido.

Teorema 8.1: Si para cada n, el número de cubrimiento de la clase $\mathcal{F}_n$ satisface

$$\sup_Q N(\varepsilon, \mathcal{F}_n, \|\cdot\|_{1,Q}) \leq A\varepsilon^{-W}$$

para $0 < \varepsilon < 1$ donde W y A son constantes que no dependen de n. Sea α_n una suceción decreciente de números positivos tales que $\frac{n\delta_n^2\alpha_n^2}{\log n} \to \infty$. Si $|f| \leq 1$ y $Pf^2 \leq \delta_n^2$ para cada $f \in \mathcal{F}_n$ entonces,

$$\frac{1}{\delta_n^2\alpha_n} \sup_{\mathcal{F}_n} |P_n f - Pf| \xrightarrow{a.s.} 0$$

Demostración: ver página 34 de Pollard (1984)

8.1 Aplicaciones a estimación de densidad

Sea P una medida de probabilidad sobre $I\!R^d$ con función de densidad acotada p. Una forma de estimar p es a través de un estimador basado en núcleos convolucionando la media empírica P_n con una función núcleo. Luego el estimador es

$$p_n(x,h) = P_n \frac{1}{h^d} K_{x,h}$$

donde $K_{x,h}(y) = K\left(\frac{y-x}{h}\right)$ para alguna función de densidad K en $I\!R^d$ y h una sucesión que converge a 0 cuando n converge a ∞. Lo que buscamos es probar que

$$\sup_x |p_n(x,h) - p(x)| \xrightarrow{a.s.} 0$$

Como probaríamos esta convergencia sin usar argumentos de procesos empíricos?

Vamos a probar solo que $\sup_{x\in M} |p_n(x,h) - p(x)| \xrightarrow{a.s.} 0$ con M un conjunto compacto. Llamaremos $f_n(x) = p_n(x,h)$ y $f(x) = p(x)$.

En primer lugar tendríamos que ver que $\sup\limits_{x\in M} |E(f_n(x)) - f(x)| \to 0$, pero este término es determínistico, con lo que habrá que pedir las condiciones necesarias a f para garantizarlo. Veamos entonces que $\sup\limits_{x\in M} |f_n(x) - E(f_n(x))| \xrightarrow{a.s.} 0$. Sea $x \in M$, sea

$$V_i(x) = K\left(\frac{x - X_i}{h}\right) - E\left(K\left(\frac{x - X_i}{h}\right)\right),$$

y sea $S_n(x) = \sum_{i=1}^n V_i(x)$. Como $E(V_j) = 0$, el núcleo K es acotado entonces para $x, y \in M$, tenemos que $|V_i(x)| < A_1$. Luego usando la desigualdad de Bernstein tenemos que para $n > n_0$, para alguna constante positiva α y $\varepsilon > 0$, tenemos

$$\sup_{x\in M} P\left(\frac{1}{nh^d}|S_n(x)| > \varepsilon\right) \leq 2\exp\left(-nh^d\alpha\right). \tag{5}$$

Por otro lado como M es compacto, podemos considerar una colección finita de bolas $(B_i = B_{h^\gamma}(x_i))$ con centros $x_i \in M$ y radio h^γ con $\gamma > 2 + d$, tal que $M \subset \cup_{i=1}^l B_i$. Luego, $l = O(h^{-\gamma})$ y

$$\sup_{x\in M} |S_n(x)| \leq \max_{1\leq j\leq l} \sup_{x\in B_j} |S_n(x) - S_n(x_j)| + \max_{1\leq j\leq l} |S_n(x_j)|. \tag{6}$$

Usando que K es una función Lipschitz con constante $\|K\|_L$, tenemos que

$$\frac{1}{nh^d}|S_n(x) - S_n(x_j)| < 2\|K\|_L \frac{1}{nh^d} nh^{\gamma-1} = Ch^{\gamma-(d+1)}$$

para todo $x \in B_j$, luego si $n > n_1$, tenemos que

$$\max_{1\leq j\leq l} \sup_{x\in B_j} \frac{1}{nh^d}|S_n(x) - S_n(x_j)| < \varepsilon \tag{7}$$

Finalmente, (5), (6) y (7) implican que, para $n > \max\{n_0, n_1\}$

$$P\left(\sup_{x\in M} \frac{1}{nh^d}|S_n(x)| > 2\varepsilon\right) \leq P\left(\max_{1\leq j\leq l} |S_n(x_j)| > \varepsilon\right) \leq 2\ l\ n^{-\alpha\delta_n}$$

con $\delta_n = \frac{nh^d}{\log n}$. Si $\frac{nh^d}{\log n} \to \infty$ tenemos que para $n \geq n_2$, $nh^d > 1$ por lo tanto $l\ n^{-\alpha\delta_n} < Cl\ n^{\gamma/d-\alpha\delta_n}$ para $n \geq n_3$. Y $\delta_n \to \infty$, para $n \geq n_4$ $\gamma/d - \delta_n\alpha < -2$. Con lo cuál para $n \geq \max\{n_0, n_1, n_2, n_3, n_4\}$ y C' una constante tenemos que

$$P\left(\sup_{x\in M} \frac{1}{nh^d}|S_n(x)| > 2\varepsilon\right) \leq C'n^{-2}$$

que muestra que $\displaystyle\sum_{n=1}^{\infty} P\left(\sup_{x\in M} \frac{1}{nh^d}|S_n(x)| > 2\varepsilon\right) < \infty$. Es decir probamos la convergencia completa.

Como probaríamos esta convergencia usando argumentos de procesos empíricos?

Notemos que si buscamos que

$$\sup_x |p_n(x,h) - p(x)| \xrightarrow{a.s.} 0$$

bastará con ver que $\sup_x |p_n(x,h) - \bar{p}(x)| \xrightarrow{a.s.} 0$ y $\sup_x |\bar{p}(x) - p(x)| \to 0$ donde $\bar{p}(x) = Pp_n(x,h) = P\frac{1}{h^d}K_{x,h}$. Es decir hay un término aleatorio y un término de sesgo determinístico igual que antes. Y la convergencia del término determinístico se puede argumentar con hipótesis sobre la suavidad de p por ejemplo si p es uniformemente continua. Para ver la

convergencia del otro término consideremos la clase $\mathcal{F}_n = \left\{ K\left(\frac{y-\cdot}{h}\right) : y \in I\!R^d \right\}$, la idea es elegir la función K de modo que $\mathcal{F}_n$ sea Glivenko - Cantelli. Por ejemplo si $K(x) = \rho(|x|)$ con ρ una función de variación acotada, entonces la clase $\mathcal{F}$ será GC, por ser ρ diferencia de dos funciones monótonas.

Y supongamos que $0 \leq p \leq 1$ entonces tenemos que

$$PK_{x,h}^2 \leq C\ PK_{x,h} = C \int K\left(\frac{y-x}{h}\right) p(y)dy = C\ h^d \int K(t)p(x+ht)dt \leq C\ h^d.$$

Luego aplicando el teorema anterior con $\alpha_n = 1$ y $\delta_n^2 = h^d$ tenemos que si $\frac{nh^d}{\log n} \to \infty$ entonces $\frac{1}{h^d} \sup_x |P_n K_{x,h} - PK_{x,h}| = \sup_x |p_n(x,h) - \bar{p}(x)| \xrightarrow{a.s.} 0$

9 Teorema Central del Limite Uniforme

Comencemos pensando que necesitaríamos si quisieramos demostrar la distribución asintótica de un $Z-$estimador. Entonces tenemos θ_n un estimador de θ_0 donde θ_0 es tal que $P\Psi_{\theta_0} = 0$, θ_n satisface $P_n\Psi_{\theta_n} = 0$. Luego

$$\begin{aligned} 0 &= P_n\Psi_{\theta_n} \\ &= P_n(\Psi_{\theta_n} - \Psi_{\theta_0}) + P_n\Psi_{\theta_0} \\ &= (P_n - P)(\Psi_{\theta_n} - \Psi_{\theta_0}) + P\Psi_{\theta_n} + P_n\Psi_{\theta_0} \end{aligned}$$

ahora si aplicamos Taylor a $P\Psi_{\theta_n} = P\Psi_{\theta_0} + \frac{\partial}{\partial\theta}P\Psi_\theta|_{\theta=\xi_n}(\theta_n - \theta_0) = \frac{\partial}{\partial\theta}P\Psi_\theta|_{\theta=\xi_n}(\theta_n - \theta_0)$ entonces

$$0 = \sqrt{n}(P_n - P)(\Psi_{\theta_n} - \Psi_{\theta_0}) + \frac{\partial}{\partial\theta}P\Psi_\theta|_{\theta=\xi_n}\sqrt{n}(\theta_n - \theta_0) + \sqrt{n}P_n\Psi_{\theta_0}$$

y así ,

$$\sqrt{n}(\theta_n - \theta_0) = [\frac{\partial}{\partial\theta}P\Psi_\theta|_{\theta=\xi_n}]^{-1}\sqrt{n}P_n\Psi_{\theta_0} + \sqrt{n}(P_n - P)(\Psi_{\theta_n} - \Psi_{\theta_0})$$

entonces como por el Teorema central del limite $\sqrt{n}P_n\Psi_{\theta_0} \xrightarrow{\mathcal{D}} N(0, P\Psi_{\theta_0}^2)$ si conseguimos que

1. $\frac{\partial}{\partial\theta}P\Psi_\theta|_{\theta=\xi_n} \xrightarrow{p} \frac{\partial}{\partial\theta}P\Psi_\theta|_{\theta=\theta_0}$
2. $\sqrt{n}(P_n - P)(\Psi_{\theta_n} - \Psi_{\theta_0}) \xrightarrow{p} 0$

tendríamos probado que $\sqrt{n}(\theta_n - \theta_0) \xrightarrow{\mathcal{D}} N(0, P\Psi_{\theta_0}^2/[\frac{\partial}{\partial\theta}P\Psi_\theta|_{\theta=\theta_0}]^2)$. El punto 1 no debería traer demasiada dificultad, debería salir con algo así como convergencia mayorada. El problema surge al tratar de controlar el punto 2. Y acá es donde entran en juego las Clases Donsker.

Recordemos entonces las nociones de convergencias que introdujimos en la primer Sección.

T_n en $I\!R$ converge en distribución a T si para todo x punto de continuidad de F tenemos que $F_n(x) \to F(x)$.

El proceso empírico, $G_n : l^\infty(\mathcal{F}) \to I\!R$ con $l^\infty(\mathcal{F}) = \{H : \mathcal{F} \to I\!R \ \sup_{f\in\mathcal{F}} \|H(f)\| < \infty\}$ está definido como $G_n = \sqrt{n}(P_n - P)$.

Recordemos la definición de Donsker, una clase $\mathcal{F}$ tal que $\sup_{f\in\mathcal{F}} |f(x) - Pf| < \infty \ \forall x$ se dice P-Donsker si

$$G_n \xrightarrow{w} G \text{ en } l^\infty(\mathcal{F})$$

Esto es que si para toda $H : l^\infty(\mathcal{F}) \to I\!R$ contínua y acotada entonces

$$\int H \ o \ G_n \ dP \to \int H \ o \ G \ dP.$$

El siguiente Teorema afirma que estas dos definiciones de convergencia débil y convergencia en distribución en $I\!R^k$ coinciden. Para una prueba de este teorema en $I\!R$ ver las notas de Varadhan.

Teorema 9.1: (Lévy-Cramér) Las siguientes proposiciones son equivalentes.

a. $F_n(x) \to F(x)$ para todo punto de continuidad.

b. Para toda $f(x)$ en $I\!R$ continua y acotada $\int_{I\!R} f(x)dF_n \to \int_{I\!R} f(x)dF$

c. Las respectivas funciones caracteristicas convergen.

En el ejemplo anterior de Z-estimadores, notemos que en realidad no necesitamos la convergencia débil del proceso G_n. Es decir, en el punto 2., lo que queremos es que

$$\sqrt{n}(P_n - P)(\Psi_{\theta_n} - \Psi_{\theta_0}) = G_n(\Psi_{\theta_n}) - G_n(\Psi_{\theta_0}) \xrightarrow{p} 0$$

es decir necesitamos una especie de continuidad del proceso G_n. Esto es lo que suele necesitarse en la mayoría de los probemas estadísticos y es lo que se conoce como asintótica equicontinuidad.

Más formalmente diremos que $\{G_n(f) : f \in \mathcal{F}\}$ es asintóticamente equicontinuo si para cada sucesión (aleatoria), $f_n \subset \mathcal{F}$ con $\|f_n - f_0\| \xrightarrow{p} 0$ tenemos que $|G_n(f_n) - G_n(f_0)| \xrightarrow{p} 0$. Notar que si G_n es equicontinuo luego $G_n(f_n)$ tiene la misma distribución asintótica que $G_n(f_0)$.

El siguiente Teorema establece ciertas equivalencias que caracterizan la propiedad de Donsker. Sea G_n indexada en una clase de funciones $\mathcal{F}$, sobre un espacio de probabilidad $(\chi, \mathcal{A}, P)$ y definamos la pseudo-métrica,

$$\rho_P(f, g) = Var_P(f(X) - g(X)) = P(f - g)^2 - [P(f - g)]^2.$$

Decimos que $(\mathcal{F}, d)$ es totalmente acotado si se puede cubrir con un número finito de bolas.

Teorema 9.2: Sea $\mathcal{F}$ en $(\chi, \mathcal{A})$ una clase de funciones, luego las siguientes condiciones son equivalentes;

a. $\mathcal{F}$ es P-Donsker.

b. $(\mathcal{F}, \rho_P)$ es totalmente acotada y G_n es asintóticamente equicontínuo uniforme en probabilidad con respecto a ρ_P es decir, para todo $\varepsilon > 0$

$$\lim_{\delta\to 0} \lim \sup_{n\to\infty} P\left(\sup_{f,g\in\mathcal{F} \ \rho_P(f,g)<\delta} |G_n(f) - G_n(g)| > \varepsilon \right) = 0$$

c. $(\mathcal{F}, \rho_P)$ es totalmente acotada y G_n es asintóticamente equicontínuo uniforme en media con respecto a ρ_P es decir, para todo $\delta_n \to 0$

$$\lim_{n\to\infty} \sup E\left(\sup_{f,g\in\mathcal{F}\ \rho_P(f,g)<\delta} |G_n(f) - G_n(g)|\right) = 0$$

Típicamente para demostrar que una clase es Donsker, la propiedad que se demuestra es la b o la c. Pero es importante en las aplicaciones tener presente todas las implicaciones. Notar que c implica b por la desigualdad de Markov, pero el hecho que b implique c envuelve argumentos de simetrización y algún tipo de desigualdades. La demostración de este teorema se encuentra en Van der Vaart y Wellner (pag 115).

Entonces volviendo al ejemplo anterior de Z-estimadores si nosotros probamos que la clase $\mathcal{F} = \{\Psi_\theta\}$ es P-Donsker y si probamos previamente que θ_n es un estimador consistente de θ_0 entonces por el Teorema anterior tendríamos que $\sqrt{n}(P_n - P)(\Psi_{\theta_n} - \Psi_{\theta_0}) \xrightarrow{p} 0$.

Entonces lo que necesitamos es encontrar condiciones para garantizar cuando una clase de funciones es Donsker y acá es donde nuevamente entra en juego el número de cubrimiento.

Condición uniforme de entropía: Una clase de funciones $\mathcal{F}$ con cápsula F tal que $PF^2 < \infty$ satisface la condición de entropía uniforme si

$$\int_0^\infty \sup_Q \sqrt{log(N(\varepsilon\|F\|_{2,Q}, \mathcal{F}, \|\cdot\|_{2,Q}))}d\varepsilon < \infty$$

donde este supremo se toma sobre las medidas de probabilidad Q discretas

Teorema 9.3: (Pollard) Sea $\mathcal{F}$ una clase de funciones con cápsula F, $PF^2 < \infty$. Si $\mathcal{F}$ satisface la condición de entropía uniforme, entonces $\mathcal{F}$ es P-Donsker

Alguna idea de la demostración 9.3.

La prueba se basa en ver que la clase $(\mathcal{F}, \rho_P)$ es totalmente acotada y que se satisface la condición de asintótica equicontinuidad uniforme. Para esto se usan las desigualdades de simetrización y las siguientes cosas,

Definición de sub-gaussianidad con respecto a $\|\cdot\|$

$$P\left(|Z_f - Z_g| \leq x\right) \leq 2e^{-\frac{1}{2}x^2/\|f-g\|}$$

para todo $f, g \in \mathcal{F}, \quad x > 0$

Desigualdad para procesos sub-gaussianos Sea Z_f sub-gaussiano entonces

$$E(\sup_f |Z_f|) \leq \int_0^\infty \sqrt{\log N(\varepsilon, \mathcal{F}, \|\cdot\|)}d\varepsilon$$

La demostración puede verse en Van der Vaart y Wellner (pagina 128).

Demostración 9.3.
Sea $\mathcal{F}_\delta = \{f - g : f, g \in \mathcal{F}\ \|f - g\| < \delta\}$. Veamos primero la equicontinuiad.

Sea $\delta_n \to 0$, por la desigualdad de Markov y los lemas de simetrización tenemos que

$$P(\|G_n\|_{\mathcal{F}_{\delta_n}} > x) \leq \frac{2}{x} E(\|\frac{1}{\sqrt{n}} \sum_{i=1}^{n} \varepsilon_i f(X_i)\|_{\mathcal{F}_{\delta_n}})$$

Por otro lado se puede ver que $Z_n(f) = \frac{1}{\sqrt{n}} \sum_{i=1}^{n} \varepsilon_i f(X_i)$ es sub-gaussiano en $L^2(P_n)$, usando la desigualdad de Hoeffding. Entonces por la desigualdad para procesos subgaussianos tenemos que

$$P(\|G_n\|_{\mathcal{F}_{\delta_n}} > x) \leq \frac{2}{x} \int_0^\infty \sqrt{\log N(\varepsilon, \mathcal{F}_{\delta_n}, \|\cdot\|_{2,P_n})} d\varepsilon.$$

Ahora si ε es grande $\mathcal{F}_{\delta_n}$ se cubre solo con una bola y la integral da 0. Sea entonces

$$\theta_n^2 = \sup_{f \in \mathcal{F}_{\delta_n}} \|f\|_n^2 = \|\frac{1}{n} \sum_{i=1}^{n} f^2(X_i)\|_{\mathcal{F}_{\delta_n}}$$

entonces si $\varepsilon > \theta_n$ la integral es 0. Entonces,

$$\begin{aligned}
\int_0^\infty \sqrt{\log N(\varepsilon, \mathcal{F}_{\delta_n}, \|\cdot\|_{2,P_n})} d\varepsilon &= \int_0^{\theta_n} \sqrt{\log N(\varepsilon, \mathcal{F}_{\delta_n}, \|\cdot\|_{2,P_n})} d\varepsilon \\
&\leq \int_0^{\theta_n} \sup_Q \sqrt{\log N(\varepsilon, \mathcal{F}, \|\cdot\|_{2,Q})} d\varepsilon \\
&\leq \int_0^{\theta_n/\|F\|_{2,P_n}} \sup_Q \sqrt{\log N(\varepsilon \, \|F\|_{2,P_n}, \mathcal{F}, \|\cdot\|_{2,Q})} d\varepsilon \, \|F\|_{2,P_n}.
\end{aligned}$$

$\mathcal{F}_{\delta_n} \subset \mathcal{F}_\infty = \{f - g : f, g \in \mathcal{F}\}$, $(N(\varepsilon, \mathcal{F}_{\delta_n}, \|\cdot\|_{2,Q}) \leq N(\varepsilon, \mathcal{F}_\infty, \|\cdot\|_{2,Q}) \leq N^2(\varepsilon/2, \mathcal{F}, \|\cdot\|_{2,Q}))$ El supremo es sobre todas las medidadas de probabilidad discretas. Como $\|F\|_{2,P_n} \xrightarrow{p} PF^2 < \infty$. Si vemos entonces que $\theta_n \xrightarrow{p} 0$ tenemos la equicontinuidad. Es decir debemos ver que $\frac{1}{n} \sum f^2(X_i) \xrightarrow{p} 0$, ahora como $\sup_{\mathcal{F}_{\delta_n}} \{Pf^2\} \to 0$ y $\mathcal{F}_{\delta_n} \subset \mathcal{F}_\infty$, entonces bastará ver que $\|P_n f^2 - Pf^2\|_{\mathcal{F}_\infty} \xrightarrow{p} 0$.

Esta clase $\mathcal{F}_\infty$ tiene envelope $(2F)^2$ y además

$$P_n|f^2 - g^2| \leq P_n|f - g|4F \leq \|f - g\|_{2,P_n} \|4F\|_{2,P_n}$$

entonces

$$N(\varepsilon \|2F\|_{2,P_n}, \mathcal{F}_\infty^2, \|\cdot\|_{2,P_n}) \leq N(\varepsilon \|F\|_{2,P_n}, \mathcal{F}_\infty, \|\cdot\|_{2,P_n})$$

donde $\mathcal{F}_\infty^2 = \{f^2 - g^2 : f, g \in \mathcal{F}\}$y $N(\varepsilon \|F\|_{2,P_n}, \mathcal{F}_\infty, \|\cdot\|_{2,P_n}) \leq N^2(\varepsilon/2 \|F\|_{2,P_n}, \mathcal{F}, \|\cdot\|_{2,P_n}) < K$ luego $\log N(\varepsilon \|F\|_{2,P_n}, \mathcal{F}_\infty, \|\cdot\|_{2,P_n}) \xrightarrow{p} 0$ entonces la clase $\mathcal{F}_\infty^2$ es Glivenko -Cantelli, entonces $\|P_n f^2 - Pf^2\|_{\mathcal{F}_\infty} \xrightarrow{p} 0$.

Veamos ahora que $\mathcal{F}$ es totalmente acotada, es decir que dado ε puedo cubrir a $\mathcal{F}$ por finitas bolas de radio ε. Anteriormente vimos que $\|P_n f^2 - Pf^2\|_{\mathcal{F}_\infty} \xrightarrow{p} 0$ entonces existe n_0 tal que para $n > n_0$ tenemos que $\|P_n f^2 - Pf^2\|_{\mathcal{F}_\infty} < \varepsilon^2$ ahora $N(\varepsilon, \mathcal{F}, \|\cdot\|_{2,P_n}) < \infty$. Entonces si tenemos un cubrimiento de radio ε de $\mathcal{F}$ en $L^2(P_n)$ tambien podemos cubir a $\mathcal{F}$ con un cubrimiento de radio $\sqrt{2\varepsilon}$ en $L^2(P)$□

Observación: Si $\mathcal{F}$ es una clase de funciones VC entonces satisface la condición de entropía uniforme. Si trabajamos con el número bracketing en lugar del número de cubrimiento la

condición de entropía uniforme puede reemplasarse por

$$\int_0^1 \sqrt{log(N_{[\,]}(\varepsilon, \mathcal{F}, \|\cdot\|_{2,P}))}d\varepsilon < \infty.$$

Este teorema se puede encontrar en la sección 2.5.2 de Van der Vaart y Wellner.

El teorema siguiente da una condición para el caso particular de la clase de las funciones continuas $\mathcal{F} = C(T)$.

Teorema 9.4: (Jain-Marcus) Sea (T, d) un espacio métrico compacto y sea $C(T)$ el espacio de las funciones continuas a valores reales sobre T con la norma del supremo. Sea $X_1, \ldots, X_n$ elementos aleatorios i.i.d en $C(T)$. Y Supongamos que $EX_i(t) = 0$ y $EX_i^2(t) < \infty$ para todo $t \in T$. Supongamos además que que existe una variable M con $EM^2 < \infty$ tal que

$$|X(t) - X(s)| < M\ d(s,t) \qquad p.p \quad \forall s,t \in T$$

y

$$\int_0^1 \sqrt{log(N(\varepsilon, T, d)}d\varepsilon < \infty,$$

entonces $C(T)$ es P-Donsker

Operaciones que preservan la propiedad de Donsker.

- ⋆ Si $\mathcal{F}$ es Donsker y $\mathcal{G} \subset \mathcal{F}$ entonces $\mathcal{G}$ es Donsker.
- ⋆ Si $\mathcal{F}$ es Donsker, entonces $\bar{\mathcal{F}}$ es Donsker.
- ⋆ Si $\mathcal{F}$ es Donsker luego la cápsula convexa simétrica $sconv(\mathcal{F})$ es Donsker.
- ⋆ Si $\mathcal{F}$ y $\mathcal{G}$ son Donsker entonces, $\mathcal{F} + \mathcal{G}$, $\mathcal{F} \vee \mathcal{G}$, $\mathcal{F} \wedge \mathcal{G}$, $\mathcal{F} \cup \mathcal{G}$ y $\mathcal{F} \cdot \mathcal{G}$
- ⋆ Si $\mathcal{F}_1, \ldots, \mathcal{F}_k$ son clases Donsker de funciones con $f_i : \chi \to I\!R$, y $\varphi : I\!R^k \to I\!R$ es una función continua y sea la clase de funciones $\mathcal{H} = \varphi(\mathcal{F}_1, \ldots \mathcal{F}_k) = \{\varphi(f_1, \ldots, f_k) : f_i \in \mathcal{F}_i\ 1 \leq i \leq k\}$ tal que

  $$|\varphi(f_1(x), \ldots, f_k(x)) - \varphi(g_1(x), \ldots, g_k(x))| \leq \sum_{i=1}^{k} |f_i(x) - g_i(x)|^2$$

  entonces $\mathcal{H}$ es Donsker.

Finalmente antes de pasar a las aplicaciones un último teorema muy útil.

Teorema 9.5: Sea $\mathcal{F}$ una clase de funciones luego

$$E(\|G_n\|_{\mathcal{F}}) \leq E(J(\theta_n, \mathcal{F})\|F\|_{P_n,2})$$

donde $\theta_n = \|\|f\|_{P_n,2}\|_{\mathcal{F}}/\|F\|_{P_n}$ y

$$J(\delta, \mathcal{F}) = \sup_Q \int_0^\delta \sqrt{1 + log(N(\varepsilon\|F\|_{2,Q}, \mathcal{F}, \|\cdot\|_{2,Q}))}d\varepsilon$$

Que esta diciendo esto?

$$E(\|G_n\|_{\mathcal{F}}) = E\left(\sup_{f\in\mathcal{F}}|G_n(f)|\right) \leq E\left(J(\theta_n,\mathcal{F})\left(\frac{1}{n}\sum_{i=1}^{n}F^2(X_i)\right)^{1/2}\right)$$

donde $\theta_n = \sup_{f\in\mathcal{F}}\left|\frac{1}{n}\sum_{i=1}^{n}f^2(X_i)\right|^{1/2}\left[\frac{1}{n}\sum_{i=1}^{n}F^2(X_i)\right]^{-1/2}$.

Respecto a $J(\cdot,\mathcal{F})$, notemos que es una función creciente en δ, que $J(0,\mathcal{F}) = 0$. Mas aún $J(1,\mathcal{F}) < \infty$ y $J(\delta,\mathcal{F}) \to 0$ si $\delta \to 0$ para clase de funciones que satisfacen la condición de entropía uniforme. Pues,

$$\begin{aligned}
J(\delta,\mathcal{F}) &= \sup_Q \int_0^\delta \sqrt{1 + log(N(\varepsilon\|F\|_{2,Q},\mathcal{F},\|\cdot\|_{2,Q}))}d\varepsilon \\
&\leq \sup_Q \int_0^\delta \sqrt{2}(1 + \sqrt{log(N(\varepsilon\|F\|_{2,Q},\mathcal{F},\|\cdot\|_{2,Q}))}d\varepsilon \\
&\leq \sqrt{2}(\delta + \int_0^\delta \sup_Q \sqrt{log(N(\varepsilon\|F\|_{2,Q},\mathcal{F},\|\cdot\|_{2,Q}))}d\varepsilon)
\end{aligned}$$

Finalmente si tenemos que $\theta_n \to 0$, luego para n suficientemente grande $\theta_n < \delta$ y si la cápsula F esta acotado por B tenemos que

$$E(\|G_n\|_{\mathcal{F}}) \leq J(\delta,\mathcal{F})B$$

10 Aplicaciones II

10.1 Desviación L^p respecto de la media.

Si queremos contestar la segunda pregunta es decir que $V_n(p) = \frac{1}{n}\sum_{i=1}^{n}|X_i - \overline{X_n}|^p$ es asintoticamente normal. Primero notemos que la clase $\mathcal{G} = \{f_{t,p} = |x-t|^p : |t-\mu| \leq 1\}$ es Donsker si suponemos adicionalmente que $E|X|^{2p} < \infty$. Esto se sigue del hecho que $\mathcal{G}$ es una clase VC de funciones con cápsula de cuadrado integrable. Ademas notar que si $\phi(x) = |x|^p$ tenemos que

$$|\phi(x-t) - \phi(x-s)|^2 \leq L^2(x)\,|s-t|^2$$

para todo $s,t \in [\mu-\delta,\mu+\delta]$ y para todo $x \in I\!R$ donde

$$L(x) = \sup_{t:\,|t=\mu|\leq\delta} p|x-t|^{p-1} = \max\{p|x-(\mu-\delta)|^{p-1}, p|x-(\mu+\delta)|^{p-1}\}$$

que satisface $PL^2(X) < \infty$. Entonces también la condición de ser P-Donsker se sigue del Teorema de Jain y Marcus. Luego

$$\begin{aligned}
\sqrt{n}(V_n(p) - V(p)) &= \sqrt{n}(P_n f_{\bar{X}_n,p} - Pf_{\mu,p}) \\
&= \sqrt{n}(P_n f_{\bar{X}_n,p} - Pf_{\bar{X}_n,p}) - \sqrt{n}(P_n f_{\mu,p} - Pf_{\mu,p}) \\
&+ \sqrt{n}(P_n f_{\mu,p} - Pf_{\mu,p}) + \sqrt{n}(Pf_{\bar{X}_n,p} - Pf_{\mu,p})
\end{aligned}$$

Sea $H(t) = Pf_{t,p}$, si H es diferenciable tenemos entonces que

$$\begin{aligned}\sqrt{n}(V_n(p) - V(p)) &= G_n(f_{\bar{X}_n,p}) - G_n(f_{\mu,p}) + G_n(f_{\mu,p}) + H'(\mu)\sqrt{n}(\bar{X}_n - \mu) + o_P(1) \\ &= G_n(f_{\bar{X}_n,p}) - G_n(f_{\mu,p}) + G_n(f_{\mu,p} + H'(\mu)(X - \mu)) + o_P(1)\end{aligned}$$

Y ahora como $\mathcal{G}$ es Donsker tenemos por un lado que si $\delta_n \to 0$ con probabilidad alta

$$|G_n(f_{\bar{X}_n,p}) - G_n(f_{\mu,p})| \leq \sup_{|t-\mu|<\delta_n} |G_n(f_{t,p}) - G_n(f_{\mu,p})| \xrightarrow{p} 0$$

y por otro lado que

$$G_n(f_{\mu,p} + H'(\mu)(X - \mu)) \xrightarrow{\mathcal{D}} G(f_{\mu,p} + H'(\mu)(X - \mu)) \sim N(0, A_p)$$

con $A_p = \mathrm{var}(f_{\mu,p}(X) + H'(\mu)(X - \mu))$.

10.2 M-estimadores

Veamos el caso particular del M-estimador de posición con función de pérdida la de Huber, es decir μ satisface $\mu = \arg\max_a P(\rho_k^H(X - a))$ con

$$\rho_k^H(u) = \begin{cases} -ku - k^2/2 & \text{si} \quad u < -k \\ u^2/2 & \text{si} \quad |u| \leq k \\ ku - k^2/2 & \text{si} \quad u > k \end{cases}$$

y el estimador $\widehat{\mu}$ es tal que $\sum_{i=1}^n \Psi_k^H(x - \widehat{\mu}) = 0$ donde

$$\Psi_k^H(x - a) = 2kI\{x - a \leq k\} - 2(x - a)I(|x - a| \leq k) - 2kI(x - a > k).$$

Ahora se puede ver $P\Psi_k^H(x - \mu) = 2(F(\mu + k) - F(\mu - k))$, ademas esta clase de funciones habíamos visto que es una clase VC de funciones y tiene cápsula de cuadrado integrable ya que $\Psi \leq 2k$. Luego es Donker.

10.3 Modelo parcialmente lineal

$\{(y_i, \mathbf{X}_i{}^{\mathrm{T}}, t_i)^{\mathrm{T}}\}_{i=1}^n$ es conjunto de observaciones de acuerdo al modelo

$$\begin{cases} y_i &= \mathbf{X}_i{}^{\mathrm{T}}\boldsymbol{\beta} + g(t_i) + \varepsilon_i & 1 \leq i \leq n, \\ x_{ij} &= \boldsymbol{\phi}_j(t_i) + \eta_{ij} & 1 \leq j \leq p, \end{cases}$$

con $\boldsymbol{\eta}_i = (\eta_{i1}, \ldots, \eta_{ip})^{\mathrm{T}}$ y ε_i con media 0 y matriz de covarianza $\boldsymbol{\Sigma}_{\boldsymbol{\eta}}$ y σ_ε^2 respectivamente.

Como estimar en este modelo.

Tomando esperanza condicional respecto a t obtenemos

$$\phi_j(t_i) = E(x_{ij}|t_i) \qquad 1 \leq j \leq p.$$

Sea $\boldsymbol{\phi}(t) = (\phi_1(t), \ldots, \phi_p(t))^{\mathrm{T}}$ y $\phi_0(t_i) = E(y_i|t_i)$ entonces

$$\phi_0(t_i) = \boldsymbol{\phi}^{\mathrm{T}}(t_i)\boldsymbol{\beta} + g(t_i).$$

Restando $\phi_0(t_i)$, tenemos que

$$y_i - \phi_0(t_i) = (\mathbf{X}_i - \boldsymbol{\phi}(t_i))^{\mathrm{T}}\boldsymbol{\beta} + \varepsilon_i.$$

Esto nos sugiere que si estimamos ϕ_0 y $\boldsymbol{\phi}$ podemos obtener un estimador de $\boldsymbol{\beta}$. Por ejemplo, el estimador de mínimos cuadrados para $\boldsymbol{\beta}$,

$$\widehat{\boldsymbol{\beta}}_{LS} = \arg\min_{\boldsymbol{\beta}} \sum_{i=1}^{n} [(y_i - \widehat{\phi}_0(t_i)) - (\mathbf{X}_i - \widehat{\boldsymbol{\phi}}(t_i))^{\mathrm{T}}\boldsymbol{\beta}]^2.$$

Finalmente podemos estimar $g(t)$ de la siguiente forma, $\widehat{g}(t) = \widehat{\phi}_0(t) - \widehat{\boldsymbol{\phi}}^{\mathrm{T}}(t)\widehat{\boldsymbol{\beta}}$. Bianco y Boente 2002 propusieron el siguiente procedimiento de estimación robusto.

Paso 1: Estimar $\phi_0(t)$ y $\phi_j(t)$, $\quad 1 \leq j \leq p$ por estimadores robustos. Sean $\widehat{\phi}_0$ y $\widehat{\phi}_j$ los estimadores y llamemos $\widehat{\boldsymbol{\phi}}(t) = (\widehat{\phi}_1(t), \ldots, \widehat{\phi}_p(t))^{\mathrm{T}}$.

Paso 2: Estimar $\boldsymbol{\beta}$, utilizando un estimador de regresión robusto sobre los residuos $\widehat{z}_i = y_i - \widehat{\phi}_0$ y $\widehat{r}_i = \mathbf{X}_i - \widehat{\boldsymbol{\phi}}$. Sea $\widehat{\boldsymbol{\beta}}$ el estimador.

Paso 3: $\widehat{g}(t) = \widehat{\phi}_0(t) - \widehat{\boldsymbol{\beta}}^{\mathrm{T}}\widehat{\boldsymbol{\phi}}(t)$.

En el paso 2, $\boldsymbol{\beta}$ es tal que minimiza $\dfrac{1}{n}\sum_{i=1} \rho\left(\dfrac{\widehat{r}_i - \widehat{z}'\beta}{s_n}\right) w(\widehat{z}_i)$. Vamos a dar un esquema de la demostración de la distribución asintótica de $\widehat{\boldsymbol{\beta}}$ para esto vamos a asumir la consistencia del estimador, y a medida de las necesidas de la demostración veremos cuales son las hipótesis que necesitamos.

Para la demostración vamos a suponer que conocemos la escala σ_0. Sea

$$\begin{aligned}
\mathbf{L}_n(\boldsymbol{\beta}) &= \frac{\sigma_0}{n}\sum_{i=1}^{n} \psi\left(\frac{r_i - \mathbf{z}_i'\boldsymbol{\beta}}{\sigma_0}\right) w(\|\mathbf{z}_i\|)\,\mathbf{z}_i \\
\widehat{\mathbf{L}}_n(\boldsymbol{\beta}) &= \frac{\sigma_0}{n}\sum_{i=1}^{n} \psi\left(\frac{\widehat{r}_i - \widehat{\mathbf{z}}_i'\boldsymbol{\beta}}{\sigma_0}\right) w(\|\widehat{\mathbf{z}}_i\|)\,\widehat{\mathbf{z}}_i\,.
\end{aligned}$$

Haciendo un desarrollo de Taylor alrededor de $\widehat{\boldsymbol{\beta}}$, tenemos que

$$\widehat{\mathbf{L}}_n(\boldsymbol{\beta}_0) = \frac{\sigma_0}{n}\sum_{i=1}^{n} \psi\left(\frac{\widehat{r}_i - \widehat{\mathbf{z}}_i'\widehat{\boldsymbol{\beta}}}{\sigma_0}\right) w(\|\widehat{\mathbf{z}}_i\|)\,\widehat{\mathbf{z}}_i + \frac{1}{n}\sum_{i=1}^{n} \psi'\left(\frac{\widehat{r}_i - \widehat{\mathbf{z}}_i'\widetilde{\boldsymbol{\beta}}}{\sigma_0}\right) w(\|\widehat{\mathbf{z}}_i\|)\,\widehat{\mathbf{z}}_i\widehat{\mathbf{z}}_i'(\widehat{\boldsymbol{\beta}} - \boldsymbol{\beta}_0)\,,$$

con $\widetilde{\boldsymbol{\beta}}$ un punto intermedio entre $\widehat{\boldsymbol{\beta}}$ y $\boldsymbol{\beta}_0$. Entonces

$$\widehat{\mathbf{L}}_n(\boldsymbol{\beta}_0) = 0 + \frac{1}{n}\sum_{i=1}^{n} \psi'\left(\frac{\widehat{r}_i - \widehat{\mathbf{z}}_i'\widetilde{\boldsymbol{\beta}}}{\sigma_0}\right) w(\|\widehat{\mathbf{z}}_i\|)\,\widehat{\mathbf{z}}_i\widehat{\mathbf{z}}_i'(\widehat{\boldsymbol{\beta}} - \boldsymbol{\beta}_0)$$

y luego tenemos que $(\widehat{\boldsymbol{\beta}} - \boldsymbol{\beta}_0) = A_n^{-1}\widehat{\mathbf{L}}_n(\boldsymbol{\beta}_0)$ con $A_n = \dfrac{1}{n}\sum_{i=1}^{n} \psi'\left(\dfrac{\widehat{r}_i - \widehat{\mathbf{z}}_i'\widetilde{\boldsymbol{\beta}}}{\sigma_0}\right) w(\|\widehat{\mathbf{z}}_i\|)\,\widehat{\mathbf{z}}_i\widehat{\mathbf{z}}_i'$.
se puede ver que $A_n \xrightarrow{p} A$. Entonces si vemos que

a) $n^{\frac{1}{2}}\mathbf{L}_n(\boldsymbol{\beta}_0) \xrightarrow{D} N(\mathbf{0}, \boldsymbol{\Sigma})$.

b) $n^{\frac{1}{2}}\left[\widehat{\mathbf{L}}_n(\boldsymbol{\beta}_0) - \mathbf{L}_n(\boldsymbol{\beta}_0)\right] \xrightarrow{p} 0$

tendríamos probada la distribución asintótica de $\widehat{\boldsymbol{\beta}}$. a) Se sigue directamente del Teorema Central del Límite. Lo díficil entonces es probar b).

b)Sea ξ_i un punto intermedio entre $r_i - \mathbf{z}_i'\widetilde{\boldsymbol{\beta}}$ y $\widehat{r}_i - \widehat{\mathbf{z}}_i'\widetilde{\boldsymbol{\beta}}$ y $\widehat{\eta}_j(t) = \widehat{\phi}_j(t) - \phi_j(t)$ para $0 \le j \le p$, y $\widehat{\boldsymbol{\eta}} = (\widehat{\eta}_1(t), \ldots, \widehat{\eta}_p(t))'$. Usando un desarrollo de Taylor tenemos que $\widehat{\mathbf{L}}_n(\boldsymbol{\beta}_0) = \mathbf{L}_n(\boldsymbol{\beta}_0) + \widehat{\mathbf{L}}_{n,1} + \widehat{\mathbf{L}}_{n,2} + \widehat{\mathbf{L}}_{n,3} + \widehat{\mathbf{L}}_{n,4} + \widehat{\mathbf{L}}_{n,5}$, donde

$$
\begin{aligned}
\widehat{\mathbf{L}}_{n,1} &= \frac{1}{n}\sum_{i=1}^{n}\psi'\left(\frac{r_i - \mathbf{z}_i'\boldsymbol{\beta}_0}{\sigma_0}\right)\left[\widehat{\boldsymbol{\eta}}'(t_i)\boldsymbol{\beta}_0 - \widehat{\eta}_0(t_i)\right] w\left(\|\mathbf{z}_i\|\right)\mathbf{z}_i \\
\widehat{\mathbf{L}}_{n,2} &= \frac{\sigma_0}{n}\sum_{i=1}^{n}\psi\left(\frac{r_i - \mathbf{z}_i'\boldsymbol{\beta}_0}{\sigma_0}\right)\left[w\left(\|\widehat{\mathbf{z}}_i\|\right)\widehat{\mathbf{z}}_i - w\left(\|\mathbf{z}_i\|\right)\mathbf{z}_i\right] \\
\widehat{\mathbf{L}}_{n,3} &= \frac{\sigma_0}{n}\sum_{i=1}^{n}\left[\psi\left(\frac{\widehat{r}_i - \widehat{\mathbf{z}}_i'\boldsymbol{\beta}_0}{\sigma_0}\right) - \psi\left(\frac{r_i - \mathbf{z}_i'\boldsymbol{\beta}_0}{\sigma_0}\right)\right] w\left(\|\widehat{\mathbf{z}}_i\|\right)\left(\widehat{\mathbf{z}}_i - \mathbf{z}_i\right) \\
\widehat{\mathbf{L}}_{n,4} &= \frac{1}{2\,\sigma_0}\frac{1}{n}\sum_{i=1}^{n}\psi''\left(\frac{\xi_i}{\sigma_0}\right)\left[\widehat{\boldsymbol{\eta}}'(t_i)\boldsymbol{\beta}_0 - \widehat{\eta}_0(t_i)\right]^2 w\left(\|\widehat{\mathbf{z}}_i\|\right)\mathbf{z}_i \\
\widehat{\mathbf{L}}_{n,5} &= \frac{1}{n}\sum_{i=1}^{n}\psi'\left(\frac{r_i - \mathbf{z}_i'\boldsymbol{\beta}_0}{\sigma_0}\right)\left[\widehat{\boldsymbol{\eta}}'(t_i)\boldsymbol{\beta}_0 - \widehat{\eta}_0(t_i)\right]\left[w\left(\|\widehat{\mathbf{z}}_i\|\right) - w\left(\|\mathbf{z}_i\|\right)\right]\mathbf{z}_i\ .
\end{aligned}
$$

Pidiendo condiciones a w, se puede ver que

$$
\begin{aligned}
n^{\frac{1}{2}}\|\widehat{\mathbf{L}}_{n,3}\| &\le p\,\|w\|_\infty\|\psi'\|_\infty n^{\frac{1}{2}}\left[\max_{1\le j\le p}\sup_{t\in[0,1]}|\widehat{\eta}_j(t)|\right]^2(1 + p\,\|\boldsymbol{\beta}_0\|) \\
n^{\frac{1}{2}}\|\widehat{\mathbf{L}}_{n,4}\| &\le \frac{1}{2}\frac{1}{\sigma_0}\|\psi''\|_\infty n^{\frac{1}{2}}\left[\max_{1\le j\le p}\sup_{t\in[0,1]}|\widehat{\eta}_j(t)|\right]^2(1 + p\,\|\boldsymbol{\beta}_0\|)^2\left(\|\psi\|_\infty + p\,\|w\|_\infty\max_{1\le j\le p}\sup_{t\in[0,1]}|\widehat{\eta}_j(t)|\right) \\
n^{\frac{1}{2}}\|\widehat{\mathbf{L}}_{n,5}\| &\le p\,C\|\psi'\|_\infty(1 + p\,\|\boldsymbol{\beta}_0\|)\,n^{\frac{1}{2}}\left[\max_{1\le j\le p}\sup_{t\in[0,1]}|\widehat{\eta}_j(t)|\right]^2\ ,
\end{aligned}
$$

y usando estimadores para las componentes no paramétricas que sean consistentes y tengan tasa $n^{1/4}$ se tiene que $3 \le j \le 5$, $n^{\frac{1}{2}}\|\widehat{\mathbf{L}}_{n,j}\| \xrightarrow{p} 0$.

Entonces lo que habría que mostar es $n^{\frac{1}{2}}\widehat{\mathbf{L}}_{n,j} \xrightarrow{p} 0$ para $j = 1, 2$, esto es,

$$
n^{\frac{1}{2}}\frac{\sigma_0}{n}\sum_{i=1}^{n}\psi'\left(\frac{r_i - \mathbf{z}_i'\boldsymbol{\beta}_0}{\sigma_0}\right)\widehat{\eta}_\ell(t_i)\,w\left(\|\mathbf{z}_i\|\right)\mathbf{z}_i \xrightarrow{p} 0 \qquad 0 \le \ell \le p \tag{8}
$$

$$
n^{\frac{1}{2}}\frac{\sigma_0}{n}\sum_{i=1}^{n}\psi\left(\frac{r_i - \mathbf{z}_i'\boldsymbol{\beta}_0}{\sigma_0}\right)\left[w\left(\|\widehat{\mathbf{z}}_i\|\right)\widehat{\mathbf{z}}_i - w\left(\|\mathbf{z}_i\|\right)\mathbf{z}_i\right] \xrightarrow{p} 0\ . \tag{9}
$$

Aquí es en donde usaremos la desigualdad maximal para el número de cubrimiento, luego es necesario definir las siguientes clases de funciones que necesitaremos que satisgan la condición de entropía uniforme.

Consideremos para j, $1 \leq j \leq p$, una función h y $\mathbf{h}(t) = (h_1(t), \ldots, h_p(t))'$ si $z_{i,j}$ es la $j-$esima coordenada de $\mathbf{z}_i$, definamos

$$\begin{aligned} J_{n,1}(h) &= n^{\frac{1}{2}} \frac{\sigma_0}{n} \sum_{i=1}^{n} \psi' \left(\frac{r_i - \mathbf{z}_i' \boldsymbol{\beta}_0}{\sigma_0} \right) h(t_i)\, w\left(\|\mathbf{z}_i\|\right)\, z_{i,j} \\ J_{n,2}(\mathbf{h}) &= n^{\frac{1}{2}} \frac{\sigma_0}{n} \sum_{i=1}^{n} \psi \left(\frac{r_i - \mathbf{z}_i' \boldsymbol{\beta}_0}{\sigma_0} \right) \left[w\left(\|\mathbf{z}_i + \mathbf{h}(t_i)\|\right) (z_{i,j} + h_j(t_i)) - w\left(\|\mathbf{z}_i\|\right) z_{i,j} \right], \end{aligned}$$

Sea $\mathcal{H} = \{h \in \mathcal{C}^1[0,1] : \|h\|_\infty \leq 1 \quad \|h'\|_\infty \leq 1\}$ notar que para una medida de probabilidad $\mathcal{Q}$, el número bracketing $N_{[\,]}\left(\epsilon, \mathcal{H}, L^2(\mathcal{Q})\right)$, y por lo tanto el número de cubrimiento $N\left(\epsilon, \mathcal{H}, L^2(\mathcal{Q})\right)$, satisfacen

$$\log N\left(\frac{\epsilon}{2}, \mathcal{H}, L^2(\mathcal{Q})\right) \leq \log N_{[\,]}\left(\epsilon, \mathcal{H}, L^2(\mathcal{Q})\right) \leq K\epsilon^{-1},$$

para $0 < \epsilon < 2$, donde K es independiente de $\mathcal{Q}$.

Consideremos las clases de funciones

$$\begin{aligned} \mathcal{F}_1 &= \left\{ f_{1,h}(r, \mathbf{z}, t) = \sigma_0 \psi' \left(\frac{r - \mathbf{z}' \boldsymbol{\beta}_0}{\sigma_0} \right) w\left(\|\mathbf{z}\|\right) z_j\, h(t), \quad h \in \mathcal{H} \right\} \\ \mathcal{F}_2 &= \left\{ f_{2,\mathbf{h}}(r, \mathbf{z}, t) = \sigma_0 \psi \left(\frac{r - \mathbf{z}' \boldsymbol{\beta}_0}{\sigma_0} \right) \left[w\left(\|\mathbf{z} + \mathbf{h}(t)\|\right) (z_j + h_j(t)) - w\left(\|\mathbf{z}\|\right) z_j \right], \right. \\ &\qquad \left. \mathbf{h}(t) = (h_1(t), \ldots, h_p(t))' \quad h_\ell \in \mathcal{H} \right\}, \end{aligned}$$

Ambas clases $\mathcal{F}_1$ y $\mathcal{F}_2$ tiene cápsula A_1 y A_2, respectivamente. Además, la independencia de entre los errores $\epsilon_i = r_i - \mathbf{z}_i \boldsymbol{\beta}_0$ y $(X_i', t_i)'$ y la elección de la función ψ implica que, si $f \in \mathcal{F}_1$, $E\, f(r_i, \mathbf{z}_i, t_i) = 0$ y por la elección de la función w tenemos que $E\, f(r_i, \mathbf{z}_i, t_i) = 0$ si $f \in \mathcal{F}_2$, (ψ impar y los errores simétricos).

Sea $\|f\|_{\mathcal{Q},2} = \left(E_{\mathcal{Q}}(f^2)\right)^{\frac{1}{2}}$, es fácil ver que si $h \in \mathcal{H}$, $0 < \epsilon < 2$, y $\|h_s - h\|_{\mathcal{Q},2} < \epsilon$ tenemos que

$$\|f_{1,h_s} - f_{1,h}\|_{\mathcal{Q},2} \leq B_1\, \epsilon$$

y entonces,

$$N\left(\epsilon\, B, \mathcal{F}_1, L^2(\mathcal{Q})\right) \leq N\left(\epsilon, \mathcal{H}, L^2(\mathcal{Q})\right).$$

Y análogamente $\mathbf{h} = (h_1, \ldots, h_p)'$ con $h_j \in \mathcal{H}$, y $0 < \epsilon < 2$, $\mathbf{h}_s = (h_{s,1}, \ldots, h_{s,p})'$ con $\|h_{s,j} - h_j\|_{\mathcal{Q},2} < \epsilon$ para $0 \leq j \leq p$, tenemos que

$$\|f_{2,\mathbf{h}_s} - f_{2,\mathbf{h}}\|_{\mathcal{Q},2} \leq B_2\, \epsilon,$$

que implica

$$N\left(\epsilon\, B_2, \mathcal{F}_2, L^2(\mathcal{Q})\right) \leq N\left(\epsilon, \mathcal{H}, L^2(\mathcal{Q})\right)^p.$$

Por consiguiente las clases de funciones $\mathcal{F}_1$ y $\mathcal{F}_2$ satisfacen la condiciones de entropía uniforme.

Para la clase $\mathcal{F}$, define the integral

$$\mathcal{J}(\delta, \mathcal{F}) = \sup_{\mathcal{Q}} \int_0^\delta \sqrt{1 + \log\left(N\left(\epsilon\, \|F\|_{\mathcal{Q},2}, \mathcal{F}, L^2(\mathcal{Q})\right)\right)}\, d\epsilon$$

donde el supremo es sobre las probabilidades discretas con $\|F\|_{\mathcal{Q},2} > 0$ y F una cápsula de $\mathcal{F}$.

Luego $\mathcal{J}$ es decreciente, $\mathcal{J}(0,\mathcal{F}) = 0$ y $\mathcal{J}(1,\mathcal{F}) < \infty$ y $\mathcal{J}(\delta,\mathcal{F}) \to 0$ si $\delta \to 0$ para la clase de funciones que satisfacen la condición de entropía uniforme. Más aún si $\mathcal{F}_0 \subset \mathcal{F}$ se tiene que $\mathcal{J}(\delta,\mathcal{F}_0) \leq \mathcal{J}(\delta,\mathcal{F})$.

Considetemos las siguiente subclases para $0 < \delta < 1$,

$$\begin{aligned}
\mathcal{F}_{1,\delta} &= \{f_{1,\sigma,h}(r,\mathbf{z},t) \in \mathcal{F}_1 \text{ with } \|h\|_\infty < \delta\} \subset \mathcal{F}_1 \\
\mathcal{F}_{2,\delta} &= \left\{f_{2,\sigma,\mathbf{h}}(r,\mathbf{z},t) \in \mathcal{F}_2 \text{ with } \mathbf{h}(t) = (h_1(t),\ldots,h_p(t))' \text{ and } \|h_\ell\|_\infty < \delta\,,\ 1 \leq \ell \leq p\right\} \subset \mathcal{F}_2\,,
\end{aligned}$$

Dado $\varepsilon > 0$ y $\delta > 0$, sea n suficientemente grande, tal que $P\left(\widehat{\eta}_j \in \mathcal{H} \text{ y } \|\widehat{\eta}_j\|_\infty < \delta\right) > 1 - \dfrac{\delta}{2}$, para $0 \leq j \leq p$. Se puede ver que existen constantes A_1 y A_2 tales que

$$\begin{aligned}
\sup_{f\in\mathcal{F}_{1,\delta}} \frac{1}{n}\sum_{i=1}^n f^2(r_i,\mathbf{z}_i,t_i) &\leq A_1^2\delta \\
\sup_{f\in\mathcal{F}_{2,\delta}} \frac{1}{n}\sum_{i=1}^n f^2(r_i,\mathbf{z}_i,t_i) &\leq A_2^2\,\delta\,.
\end{aligned}$$

Entonces usando la desigualdad máximal para el número de cubrimiento tenemos que para $0 \leq \ell \leq p$,

$$\begin{aligned}
P\left(|J_{n,1}\left(\widehat{\eta}_\ell\right)| > \epsilon\right) &\leq P\left(|J_{n,1}\left(\widehat{\eta}_\ell\right)| > \epsilon\,,\ \widehat{\eta}_\ell \in \mathcal{H} \text{ and } \|\widehat{\eta}_\ell\|_\infty < \delta\right) + \delta \\
&\leq P\left(\sup_{f\in\mathcal{F}_{1,\delta}} |n^{\frac{1}{2}}\frac{1}{n}\sum_{i=1}^n f(r_i,\mathbf{z}_i,t_i)| > \epsilon\right) + \delta \\
&\leq \frac{1}{\epsilon}E\left(\sup_{f\in\mathcal{F}_{1,\delta}} |n^{\frac{1}{2}}\frac{1}{n}\sum_{i=1}^n f(r_i,\mathbf{z}_i,t_i)|\right) + \delta \leq \frac{1}{\epsilon}D_1\,A_1\,\mathcal{J}\left(\delta,\mathcal{F}_1\right) + \delta\,,
\end{aligned}$$

donde D_1 es una constante independiente de n. Analogamente para $\mathcal{F}_2$, $P\left(|J_{n,2}\left(\widehat{\boldsymbol{\eta}}\right)| > \epsilon\right) \leq \frac{1}{\epsilon}D_2\,A_2\,\mathcal{J}\left(\delta,\mathcal{F}_2\right) + \delta$.

Y como $\lim_{\delta\to 0}\mathcal{J}\left(\delta,\mathcal{F}_1\right) = 0$ y $\lim_{\delta\to 0}\mathcal{J}\left(\delta,\mathcal{F}_2\right) = 0$, ya que las clases $\mathcal{F}_1$ y$\mathcal{F}_2$ satisfacen la condición de entropía uniforme.

11 Posibles Extensiones

Todo los resultados anteriores fueron para una muestra aleatoria i.i.d, pero estos resultados han sido extendidos y mejorados en varias direcciónes.

Para U-procesos. Nolan y Pollard (1987, 1988), De la Peña y Giné (1999)

Para datos dependientes. Andrew y Pollard (1994), Doukhan, Massart y Río (1995)

Para resultados bootstrap. van der Vaart y Wellner (1996)

Bibliografía

Andrews, D. W. K. , and Pollard, D. (1994). An introduction to functional central limit theorems for dependent stochastic processes. International Statistical Review 62, 119 - 132.

Bianco, A y Boente, G. (2000). Robust estimatores in semiparametric partly linear regression models.

de la Pena, V. H., and Gine, E. Decoupling. From dependence to independence. Springer- Verlag, New York, 1999.

Doukhan, P., Massart, P., and Rio, E. (1995). Invariance principles for absolutely regular empirical processes. Ann. Inst. H. Poincare Probab. Statist. 31, 393 - 427.

Dudley, R. M. (1978). Central limit theorems for empirical measures. Ann. Probab. 6, 899-929.

Gine, E. and Zinn, J. (1984). Some limit theorems for empirical processes. Ann. Probab. 12, 929-989.

Gine, E. and Zinn, J. (1986). Lectures on the central limit theorem for empirical processes. Lecture Notes in Mathematics 1221, 50-113. Springer-Verlag, Berlin.

Gine, E. and Zinn, J. (1984). Some limit theorems for empirical processes. Ann. Probab. 12, 929-989.

Nolan, D. and Pollard, D. (1987). U-processes: rates of convergence. Ann. Statist. 15, 780 - 799.

Nolan, D. and Pollard, D. (1988). Functional limit theorems for U-processes. Ann. Probab. 16, 1291 - 1298.

Pollard, D. (1984) . Convergence of Stochastic Processes. Springer - Verlag. New York. http://www.stat.yale.edu/ pollard/

Pollard, D. (1985). New ways to prove central limit theorems. Econometric Theory 1, 295 - 314.

Pollard, D. (1987). Rates of uniform almost-sure convergence for empirical processes xindexed by unbounded classes of functions. Preprint.

Pollard, D. (1990). Empirical Processes: Theory and Applications. NSF-CBMS Regional Conference Series in Probability and Statistics 2, Institute of Mathematical Statistics.

Pollard, D. (1995). Uniform ratio limit theorems for empirical processes. Scand. J. Statist. 22, 271 - 278.

Van der Vaart, A. W. and Wellner, J. A. (1996). Weak Convergence and Empirical Processes. Springer-Verlag, New York.

Van der Vaart, A. W. and Wellner, J. A. (2000). Preservation theorems for Glivenko-Cantelli and uniform Glivenko-Cantelli classes, pp. 115 - 134 In High Dimensional Probability II, Evarist Gine, David Mason, and Jon A. Wellner, editors, Birkhauser, Boston.

Vapnik, V. N. and Chervonenkis, A. Ya. (1968) On the uniform convergence of relative frequencies of events to their probabilities. Theory of Probability and Its Applications 16, 264 - 280.

Varadhan. Notas sobre convergencia débil.
http://math.nyu.edu/faculty/varadhan/course/PROB.ch2.pdf

Apendice: Un ejemplo de clase VC.

Una forma de obtener cotas para el número de cubrimiento, es a traves de argumentos combinatorios, a menudo llamado el método VC. Para entender un poco veamos un ejempo concreto.

Considere la clase $\mathcal{G}$ de todos los semi-espacios cerrados en R^2. Sea F un conjunto de n puntos de R^2. Cuántos subconjuntos distintos se pueden formar de la forma $H \cap F$ con $H \in \mathcal{G}$?. Claramente puede haber a lo sumo 2^n. Denotemos por $F_{\mathcal{G}}$ la clase de conjuntos formada por estos concuntos $\{H \cap F : H \in \mathcal{G}\}$. Veamos que

$$\#F_{\mathcal{G}} \leq p(n) = 1 + 4n(n-1)$$

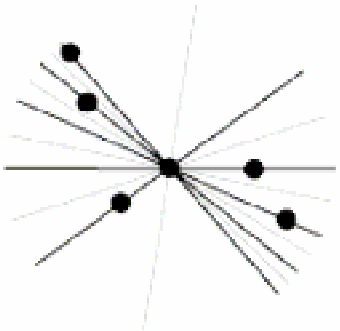

Consideremos un subconjunto no vacío F_0 de F elegido por un semi-espacio H_0 particular. Podemos suponer que hay por lo menos un x_0 en L_0, el borde de H_0. Los otros $n-1$ puntos de F quedan todos en alguna resta que los une a x_0, sea $\mathcal{L}(x_0)$ este conjunto de a lo sumo $n-1$ de estas rectas. Consideremos $\mathcal{L}'(x_0)$ otro conjunto de a lo sumo $n-1$ rectas formado por las líneas que pasan por x_0 y por el medio de los angulos de las lienas anteriores. Ahora el conjunto $\mathcal{L}(x_0) \cup \mathcal{L}'(x_0)$ produce a lo sumo $4(n-1)$ semi-espacios donde x_0 está en la frontera. Y el conjunto $\cup_{x_0 \in F} \mathcal{L}(x_0) \cup \mathcal{L}'(x_0)$ genera todos los posibles semi-espacios no vacíos que la clase $\mathcal{G}$ puede elegir de F. El 1 en $p(n)$ es porque falta considerar el vació. Se pueden mostrar cotas mas finas $(n^2 + n)$, pero no nos importa.

Lo importante es que de una cota exponencial como la de 2^n como la que teniamos en principio, tenemos una cota de orden $O(n^2)$ y esto tiene una consecuencia inesperado a la hora de calcular el número de cubrimiento de la clase $\mathcal{G}$ provista con métrica de L^1. La

distancia de $L^1(P)$ entre dos conjuntos B y B' es $P|B - B'|$ es decir la probabilidad de la diferencia simétrica. $D(\varepsilon, \mathcal{G}, \|\cdot\|_{1,P})$ es el máximo número de puntos ε-separados de $\mathcal{G}$.

Lo que haremos ahora es ver que la cota para el cardinal de $F_{\mathcal{G}}$ obtenida antes sirve para dar un cota superior de $D(\varepsilon, \mathcal{G}, \|\cdot\|_{1,P})$. Es decir, sea $N = D(\varepsilon, \mathcal{G}, \|\cdot\|_{1,P})$ entonces existen $H_1, H_2, \ldots, H_N$ tales que $P|H_i - H_j| > \varepsilon$ para $i \neq j$. Supongamos que tenemos un F con cardinal igual a $m = [2\log N/\varepsilon]$ donde cada H_i intersecado con F da N diferentes conjuntos. Entonces $\mathcal{G}$ elegirá al menos a N subconjuntos de F luego

$$N \leq p(m) = 1 + 4([2\log N/\varepsilon] - 1)([2\log N/\varepsilon]) \leq 8(\log N/\varepsilon)^2$$

Acotando $\log(N) \leq CteN^{1/4}$ nos queda $N \leq O(1/\varepsilon^4)$. Uno prodría acotar con más cuidado y obtener cota más finas pero lo importante es que tenemos una cota polinómica en $1/\varepsilon$ y no importa mucho el grado del polinomio.

Como hacemos ahora para a garantizar que existe $F = \{x_1, \ldots, x_m\}$ tales que $H_1, H_2, \ldots, H_N$ elijan N diferentes subconjuntos de F?

Primera observación necesitamos garantizar que haya al menos un punto en de F en cada una de las $\binom{N}{2}$ diferencias simétricas entre H_i y H_j. Esto parece dificil pero aca la teoría de probabilidad ayuda. Generamos F como una muestra aleatoria de tamaño m de P. Si $m \geq 2\log N/\varepsilon$, entonces hay probabilidad estrictamente positiva que la muestra tiene la propiedad deseada. De hecho, para i fijo $i \neq j$,

$$\begin{aligned} P\{H_i \text{ y } H_j \text{ elijan los mismos puntos de } F\} &= P\{\text{no haya puntos de la muestra en } H_i \Delta H_j\} \\ &= (1 - PH_i\Delta H_j)^m \\ &\leq (1-\varepsilon)^m \leq e^{-m\varepsilon} \end{aligned}$$

Entonces $P\{$ cualquier parH_i y H_j elijan los mismos puntos de $F\} \leq \binom{N}{2}e^{-m\varepsilon} \leq 1$ si $m \geq 2\log N/\varepsilon$, entonces estamos.

Ejemplos fáciles:

1. si $\mathcal{C} = \{(-\infty, t] : t \in I\!R\}$ es VC porque $V(\mathcal{C}) = 2$, pues $\{x_1, x_2\}$ no es shatteado por $\mathcal{C}$ ya que si $x_1 < x_2$ entonces $\mathcal{C}$ nunca puede elegir solo al x_2.

2. sea $\mathcal{G}$ la clase de semi-espacios, si tomamod $F = \{x_1, x_2, x_3\}$ (no todos en la misma recta) es fácil ver que $\mathcal{G}$ shattea a F. Notar que no todos los conjuntos de 3 elementos pueden ser shatteados pero eso no importa, alcanza con que uno lo sea.

   Pero como vimos que $\#F \leq p(n) = 1 + 4n(n-1)$ entonces si $n \geq 8$ tenemos que $p(n) < 2^n$ entonces $V(\mathcal{G}) \leq 8$. En particular en esta clase se puede ver que $V(\mathcal{G}) = 4$