Estimadores de mínima distancia y detección de outliers en datos direccionales.

Daniela Rodriguez

trabajo conjunto con Mercedes Fernandez Sau.

Datos direccionales

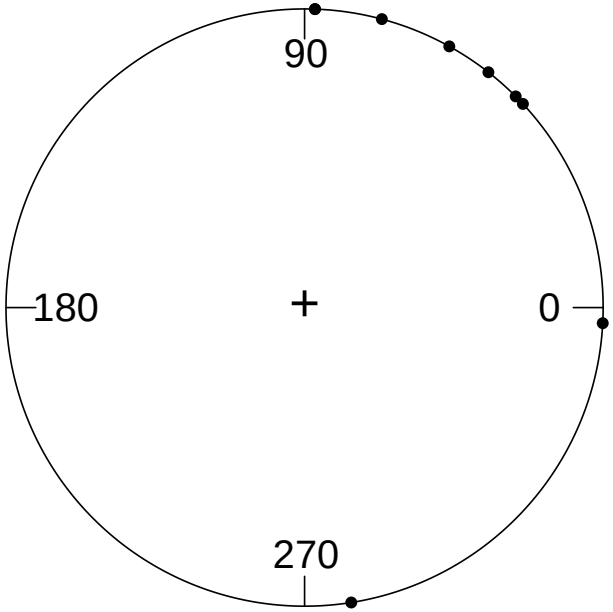

Datos direccionales

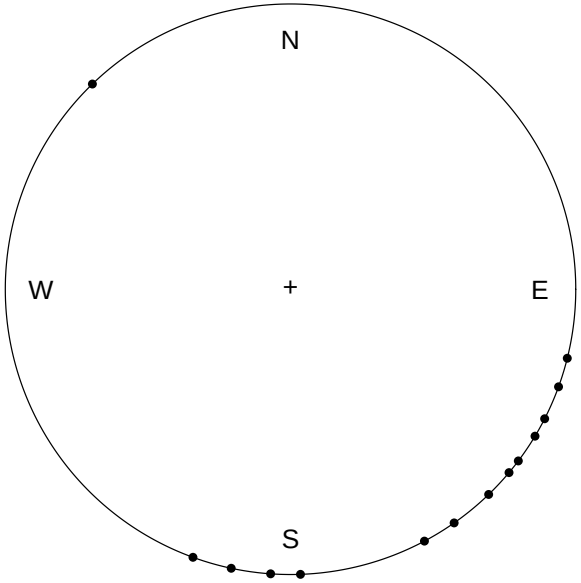

Ferguson (1967) llevó a cabo un experimento para investigar la habilidad de orientación de una especie de ranas.

Datos direccionales

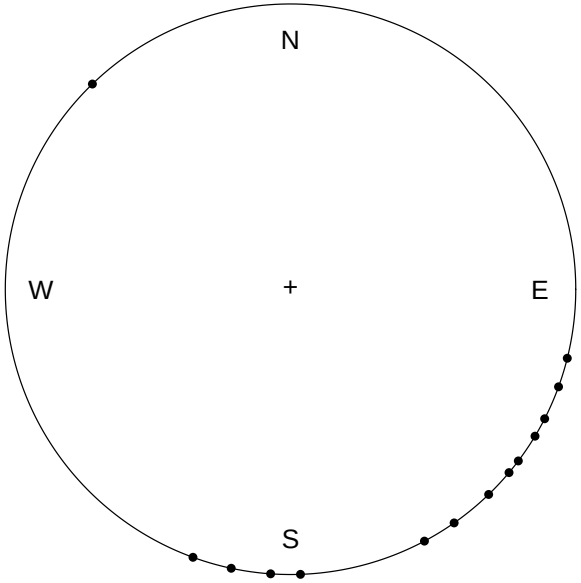

Ferguson (1967) llevó a cabo un experimento para investigar la habilidad de orientación de una especie de ranas.
Dirección elegida por 14 ranas despues de 30 horas de recogidas de un pantano Mississippi en los Estados Unidos.

Datos direccionales

17 mediciones de remanencia magnética a partir de muestras recogidas del Paleozoico.

Datos direccionales

17 mediciones de remanencia magnética a partir de muestras recogidas del Paleozoico.
El objetivo del estudio era determinar el origen de la magnetización natural.

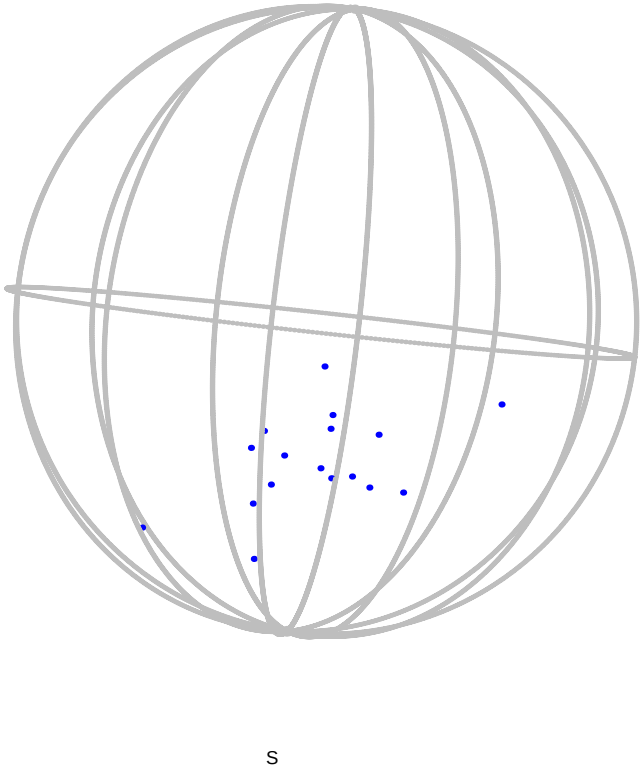

Datos direccionales

$\mathbf{x}_1, ..., \mathbf{x}_n$ muestra aleatoria independiente de una variable $\mathbf{x}$ que toma valores en la esfera de dimensión d, $\mathcal{S}_d$ en $\mathbb{R}^{d+1}$.

Datos direccionales

$\mathbf{x}_1, ..., \mathbf{x}_n$ muestra aleatoria independiente de una variable $\mathbf{x}$ que toma valores en la esfera de dimensión d, $\mathcal{S}_d$ en $\mathbb{R}^{d+1}$.

Tenemos $f : \mathcal{S}_d \to \mathbb{R}$ su función de densidad, $\int_{\mathcal{S}_d} f(\mathbf{x})\, \omega_d(d\mathbf{x}) = 1$ donde ω_d es la medida de Lebesgue en la esfera.

Datos direccionales

$\mathbf{x}_1, ..., \mathbf{x}_n$ muestra aleatoria independiente de una variable $\mathbf{x}$ que toma valores en la esfera de dimensión d, $\mathcal{S}_d$ en $\mathbb{R}^{d+1}$.

Tenemos $f : \mathcal{S}_d \to \mathbb{R}$ su función de densidad, $\int_{\mathcal{S}_d} f(\mathbf{x})\, \omega_d(d\mathbf{x}) = 1$ donde ω_d es la medida de Lebesgue en la esfera.

Modelos paramétricos

Distribución Wrapped

Si X es una variable aleatoria en la recta, la correspondiente variable aleatoria X_ω viene dada por

$$X_\omega = X\,(mod\ 2\pi)$$

En particular, si la variable aleatoria X tiene función de densidad f, la correspondiente función de densidad f_ω de X_ω es

$$f_\omega(\theta) = \sum_{k=-\infty}^{\infty} f(\theta + 2\pi k)$$

Distribución Uniforme

$$f(\theta) = \frac{1}{2\pi} I_{(0,2\pi)}(\theta)$$

Modelos paramétricos

Distribución Von Mises-Fisher $VM(\mu, \kappa)$.

$$f_p(\mathbf{x}; \mu, \kappa) = C_p(\kappa) \exp\left(\kappa \mu^T \mathbf{x}\right)$$

donde $\kappa \geq 0$, $\|\mu\| = 1$ y la constante de normalización $C_p(\kappa)$ es igual a

$$C_p(\kappa) = \frac{\kappa^{p/2-1}}{(2\pi)^{p/2} I_{p/2-1}(\kappa)}.$$

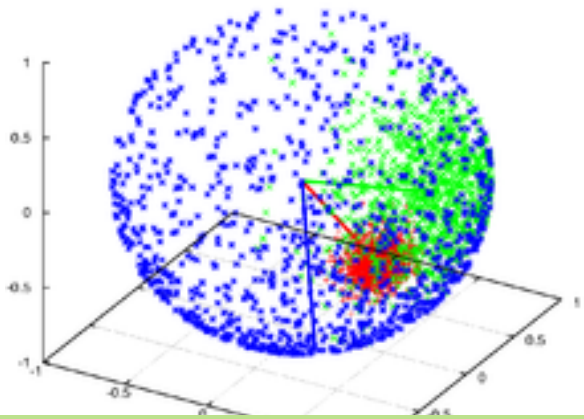

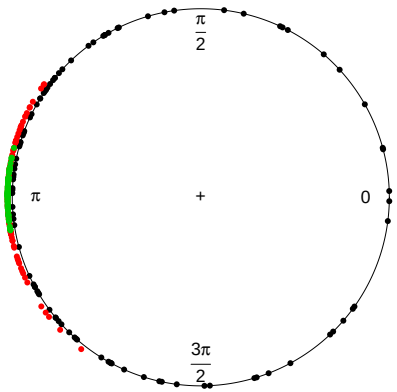

Modelos paramétricos

Distribucíon de Kent.

$$f(\mathbf{x}) = \frac{1}{\mathrm{c}(\kappa,\beta)} \exp\{\kappa\gamma_1 \cdot \mathbf{x} + \beta[(\gamma_2 \cdot \mathbf{x})^2 - (\gamma_3 \cdot \mathbf{x})^2]\}$$

donde

$$c(\kappa,\beta) = 2\pi \sum_{j=0}^{\infty} \frac{\Gamma(j+\frac{1}{2})}{\Gamma(j+1)} \beta^{2j} \left(\frac{1}{2}\kappa\right)^{-2j-\frac{1}{2}} I_{2j+\frac{1}{2}}(\kappa)$$

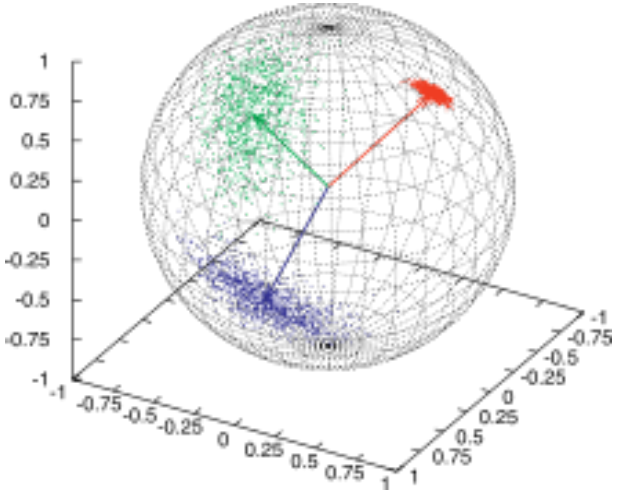

Estimación por núcleos de la densidad para datos lineales

Rosemblatt (1956)- Parzen (1962)

$$\hat{f}_n(x) = \frac{1}{n}\sum_{i=1}^{n}\frac{1}{h}K\left(\frac{x-x_i}{h}\right)$$

donde

- $h = h_n$ es llamado *parámetro de suavizado* o *ancho de ventana* y satisface $h_n \to 0$ si $n \to \infty$
- K, no negativa y que verifique la condición $\int K(t)\,dt = 1$

Estimación por núcleos de la densidad para datos lineales

Algunos núcleos posibles

- Núcleo Rectangular

$$K(t) = \frac{1}{2} I_{(-1,1](t)}$$

- Núcleo triangular

$$K(t) = (1 - |t|) I_{(-1,1](t)}$$

- Núcleo Gaussiano

$$K(t) = e^{-\frac{1}{2}t^2}$$

- Núcleo de Epanechnikov

$$K(t) = \frac{3}{4}(1 - t^2) I_{(-1,1](t)}$$

Estimación por núcleos de la densidad para datos lineales

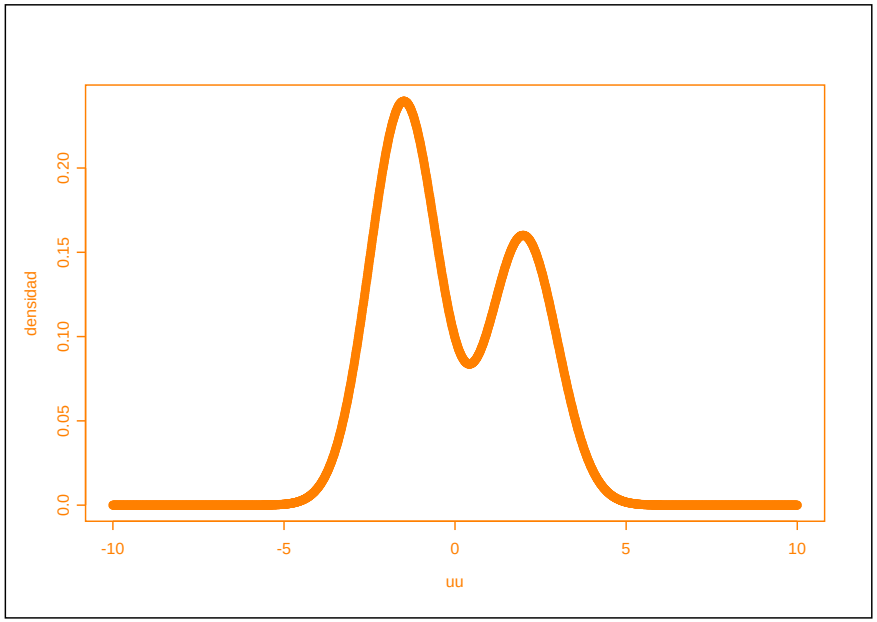

Densidad de una combinación convexa de normales
$f(x) = 0.6\mathcal{N}(.1.5, 1) + 0.4\mathcal{N}(2, 1)$

Estimación por núcleos de la densidad para datos lineales

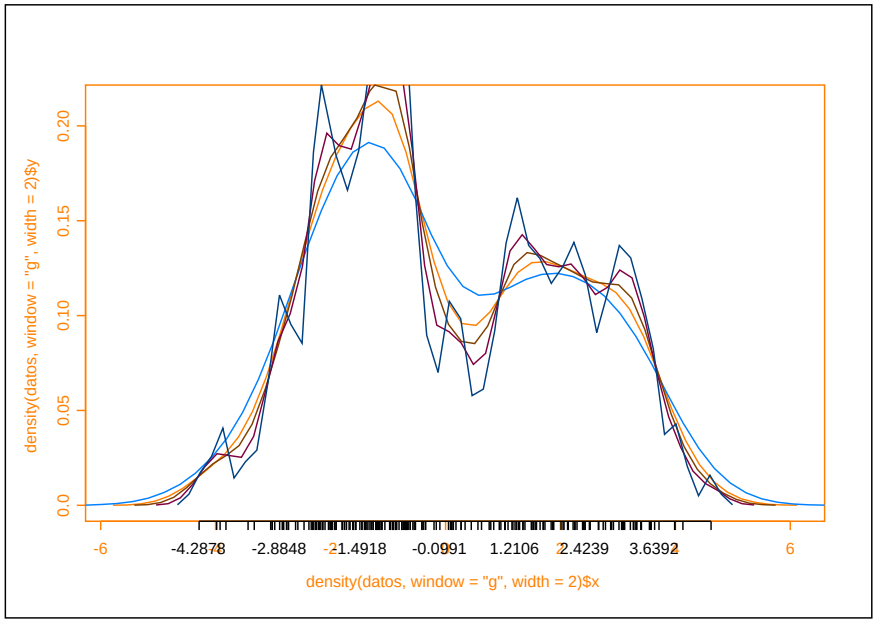

Estimación de la densidad por núcleo de Epanechnikov para diferentes ventanas $h = 3$(celeste) $h = 2$ (naranja) $h = 1.5$ (marron) $h = 1$ (rojo) $h = 0.5$ (azul).

Estimación por núcleos de la densidad para datos lineales

Si $\mathbf{x}_1, \ldots, \mathbf{x}_n$ son vectores aleatorios d-dimensionales, el estimador de Rosemblatt-Parzen se escribe como

$$\hat{f}_n(\mathbf{x}) = \frac{1}{nh^d} \sum_{i=1}^{n} K[(\mathbf{x} - \mathbf{x}_i)/h], \qquad \mathbf{x} \in \mathbb{R}^d$$

Como se puede extender el estimador de densidad basado en núcleos cuando tenemos datos direccionales?

Estimación por núcleos de la densidad para datos direccionales

- Hall, Watson y Cabrera (1987) $\hat{f}_n(\mathbf{x}) = \frac{1}{n}\, c_0(\kappa) \sum_{i=1}^{n} K(\kappa\, \mathbf{x}^T \mathbf{x}_i)$
- Bai, Rao y Zhao (1988) $\hat{f}_n(\mathbf{x}) = \frac{1}{nh^d}\, C(h) \sum_{i=1}^{n} K[(1 - \mathbf{x}^T \mathbf{x}_i)/h^2]$
- Zhao and Wu (2001) $f_h(\mathbf{x}) = \frac{c(h)}{n} \sum_{i=1}^{n} K\left(\frac{1-\mathbf{x}^T \mathbf{x}_i}{h^2}\right)$

κ y h son los paramétros de suavizados, $c_0(\kappa)$, $c(h)$ y $C(h)$ para que el estimador $\hat{f}_n$ integre 1.

Estimadores de mínima distancia

Supondremos que $\mathbf{x}_1, ..., \mathbf{x}_n$ independientes en $\mathbb{R}^{d+1}$ con densidad $f(\mathbf{x})$ en $\mathcal{S}_d$.

Estimadores de mínima distancia

Supondremos que $\mathbf{x}_1, ..., \mathbf{x}_n$ independientes en $\mathbb{R}^{d+1}$ con densidad $f(\mathbf{x})$ en $\mathcal{S}_d$. Donde $f(\mathbf{x}) \in \{f_\theta(\mathbf{x}) \text{ con } \theta \in \Theta\}$, es decir $f = f_{\theta_0}$ para algún θ_0.

Estimadores de mínima distancia

Supondremos que $\mathbf{x}_1, ..., \mathbf{x}_n$ independientes en $\mathbb{R}^{d+1}$ con densidad $f(\mathbf{x})$ en $\mathcal{S}_d$. Donde $f(\mathbf{x}) \in \{f_\theta(\mathbf{x}) \text{ con } \theta \in \Theta\}$, es decir $f = f_{\theta_0}$ para algún θ_0.

Estimador de mínima distancia θ_n:

$$\widehat{\theta} = arg \min_{\theta} D(f_n, f_\theta). \tag{1}$$

donde f_n es un estimador no paramétrico de la densidad y D es una distancia entre funciones de densidad.

Estimadores de mínima distancia

Supondremos que $\mathbf{x}_1, ..., \mathbf{x}_n$ independientes en $\mathbb{R}^{d+1}$ con densidad $f(\mathbf{x})$ en $\mathcal{S}_d$. Donde $f(\mathbf{x}) \in \{f_\theta(\mathbf{x}) \text{ con } \theta \in \Theta\}$, es decir $f = f_{\theta_0}$ para algún θ_0.

Estimador de mínima distancia θ_n:

$$\widehat{\theta} = arg \min_{\theta} D(f_n, f_\theta). \tag{1}$$

donde f_n es un estimador no paramétrico de la densidad y D es una distancia entre funciones de densidad.
Esta propuesta extiende el caso Euclideo dada en Cao et.al. (1995)

Estimadores de mínima distancia

D es una distancia entre funciones de densidad, por ejemplo,

- $D_p(\hat{f}_n, f) = \int |\hat{f}_n - f|^p$
- $D_\infty(\hat{f}_n, f) = \sup_t |\hat{f}_n(t) - f(t)|$
- $D_H(f_h, f_\theta) = \int (\sqrt{f_h(\mathbf{x})} - \sqrt{f_\theta(\mathbf{x})})^2 \, \omega_d(d\mathbf{x})$

También se podrían considerar medidas de discrepancia o divergencia, no necesariamente una distancia.

Estimadores de mínima distancia

Como estimador no paramétrico usaremos

$$f_h(\mathbf{x}) = \frac{c(h)}{n} \sum_{i=1}^{n} K\left(\frac{1 - \mathbf{x}^T \mathbf{x}_i}{h^2}\right)$$

que requiere de la elección de h y K.

Estimadores de mínima distancia

Como estimador no paramétrico usaremos

$$f_h(\mathbf{x}) = \frac{c(h)}{n} \sum_{i=1}^{n} K\left(\frac{1 - \mathbf{x}^T \mathbf{x}_i}{h^2}\right)$$

que requiere de la elección de h y K.

$$\begin{aligned} c(h)^{-1} &= \int_{\mathcal{S}_d} K((1 - \mathbf{x}^T \mathbf{y})/h^2)\, \omega_d(d\mathbf{y}) \\ &\simeq \frac{h^d}{\Gamma(d/2)} (2\pi)^{d/2} \int_0^\infty K(r) r^{d/2-1}\, dr \end{aligned}$$

Estimadores de mínima distancia

Selección del paramétro de suavizado h:

- criterio de cross-validation criterion - Hall et al. (1987)

Estimadores de mínima distancia

Selección del paramétro de suavizado h:

- criterio de cross-validation criterion - Hall et al. (1987)
- propuesta plug-in - Taylor (2008).

Estimadores de mínima distancia

Selección del paramétro de suavizado h:

- criterio de cross-validation criterion - Hall et al. (1987)
- propuesta plug-in - Taylor (2008).
- García-Portugués (2013) 3 propuestas que requieren estimar una von Mises densidad.

Estimadores de mínima distancia

Selección del paramétro de suavizado h:

- criterio de cross-validation criterion - Hall et al. (1987)
- propuesta plug-in - Taylor (2008).
- García-Portugués (2013) 3 propuestas que requieren estimar una von Mises densidad.

Estimadores de mínima distancia

Selección del paramétro de suavizado h:

- criterio de cross-validation criterion - Hall et al. (1987)
- propuesta plug-in - Taylor (2008).
- García-Portugués (2013) 3 propuestas que requieren estimar una von Mises densidad.

Como en Cao et.al. (1995) se puede incorporar la selección del parámetro de suavizado en la definición del estimador

$$(\widetilde{\theta}, \widetilde{h}) = arg \min_{\theta, h} D(f_h, f_\theta)$$

Propiedades

Bajo ciertas condiciones se puede probar el estimador θ_n resulta

- Fuertemente consistente $\theta_n \xrightarrow{a.s.} \theta_0$

Propiedades

Bajo ciertas condiciones se puede probar el estimador θ_n resulta

- Fuertemente consistente $\theta_n \xrightarrow{a.s.} \theta_0$

- Asintóticamente normal

$$\sqrt{n}(\widehat{\theta} - \theta_0) \xrightarrow{\mathcal{D}} N(0, A^{-1}\Sigma A^{-1})$$

donde Σ y A dependen del núcleo y de la densidad.

Propiedades

Bajo ciertas condiciones se puede probar el estimador θ_n resulta

- Fuertemente consistente $\theta_n \xrightarrow{a.s.} \theta_0$

- Asintóticamente normal

$$\sqrt{n}(\widehat{\theta} - \theta_0) \xrightarrow{\mathcal{D}} N(0, A^{-1}\Sigma A^{-1})$$

  donde Σ y A dependen del núcleo y de la densidad.

- Robusto (cualitativamente robusto en el sentido de Hampel)
  T_n es cualitativamente robusto en F si para todo $\varepsilon > 0$, existe $\delta > 0$ tal que si $\pi(F, G) < \delta$ entonces $\pi(\mathcal{L}_F(T_n), \mathcal{L}_G(T_n)) < \varepsilon$ donde π es la distancia de Prokhorov y $\mathcal{L}_F(T_n)$ la distribución de T_n bajo F.

Detección de outliers

Una α- región de outlieres con respecto a una distribución von Mises es definida como

$$out(\mu, \alpha) = \{\mathbf{x} : \|\mathbf{x} - \mu\|^2 > v_{1-\alpha}\},$$

donde v_q es el $q-$quantil respecto a la distribución de $W = \|\mathbf{x} - \mu\|^2$.

Detección de outliers

Una α- región de outlieres con respecto a una distribución von Mises es definida como

$$out(\mu, \alpha) = \{\mathbf{x} : \|\mathbf{x} - \mu\|^2 > v_{1-\alpha}\},$$

donde v_q es el $q-$quantil respecto a la distribución de $W = \|\mathbf{x} - \mu\|^2$. Entonces una observación $\mathbf{x}$ será un α-outlier respecto a la distribución von Mises si $\mathbf{x} \in out(\mu, \alpha)$.

Detección de outliers

Una α- región de outlieres con respecto a una distribución von Mises es definida como

$$out(\mu, \alpha) = \{\mathbf{x} : \|\mathbf{x} - \mu\|^2 > v_{1-\alpha}\},$$

donde v_q es el $q-$quantil respecto a la distribución de $W = \|\mathbf{x} - \mu\|^2$. Entonces una observación $\mathbf{x}$ será un α-outlier respecto a la distribución von Mises si $\mathbf{x} \in out(\mu, \alpha)$.
La distribución de W se puede calcular de forma explícita,

Detección de outliers

Una α- región de outlieres con respecto a una distribución von Mises es definida como

$$out(\mu, \alpha) = \{\mathbf{x} : \|\mathbf{x} - \mu\|^2 > v_{1-\alpha}\},$$

donde v_q es el $q-$quantil respecto a la distribución de $W = \|\mathbf{x} - \mu\|^2$. Entonces una observación $\mathbf{x}$ será un α-outlier respecto a la distribución von Mises si $\mathbf{x} \in out(\mu, \alpha)$.
La distribución de W se puede calcular de forma explícita, $f_W(w) = f_U\left((2-w)/2\right)/2$ donde

$$f_U(u) = \frac{\left(\frac{\kappa}{2}\right)^{\frac{d-1}{2}}}{\sqrt{\pi}\Gamma(d/2) I_{\frac{d-1}{2}}(\kappa)} e^{\kappa u}(1-u^2)^{d/2-1}.$$

Detección de outliers

La α- región de outlieres se define de la misma manera para cualquier distribución simétrica y unimodal.

Detección de outliers

La α- región de outlieres se define de la misma manera para cualquier distribución simétrica y unimodal.
En particular, si f tiene densidad rotacionalemente simétrica

$$f(\mathbf{x}) = \frac{1}{\omega_{d-1}(1-(\mu^T\mathbf{x})^2)^{\frac{d}{2}-1}} g_\nu(\mu^T\mathbf{x})$$

donde ω_q es el área de la esfera q-dimensional y g_ν es una densidad en $(-1,1)$ con $\nu \in \mathbb{R}^p$.

Detección de outliers

La α- región de outlieres se define de la misma manera para cualquier distribución simétrica y unimodal.
En particular, si f tiene densidad rotacionalemente simétrica

$$f(\mathbf{x}) = \frac{1}{\omega_{d-1}(1-(\mu^T\mathbf{x})^2)^{\frac{d}{2}-1}} g_\nu(\mu^T\mathbf{x})$$

donde ω_q es el área de la esfera q-dimensional y g_ν es una densidad en $(-1,1)$ con $\nu \in \mathbb{R}^p$.

Se puede ver que si $W = \|\mathbf{x}-\mu\|^2$ entonces $f_W(w) g_\nu\left((2-w)/2\right)/2$.

Entonces, $\mathbf{x}$ es un outlier si $\mathbf{x} \in out(\mu,\alpha) = \{\mathbf{x} : \|\mathbf{x}-\mu\|^2 > v_{1-\alpha}\}$, pero v_q es el $q-$cuantil calculado con la densidad $g_\nu\left((2-w)/2\right)/2$.

Simulación

Modelo 1: $\mathbf{x}_i \in \mathcal{S}_3$ con $1 \leq i \leq 200$.

- $C_0 : \mathbf{x}_i \sim VM((0,1,0),1)$
- $C_1 : \mathbf{x}_i \sim 0.9VM((0,1,0),1) + 0.1VM((0,-1,1),15)$.

Simulación

Modelo 1: $\mathbf{x}_i \in \mathcal{S}_3$ con $1 \leq i \leq 200$.

- $C_0 : \mathbf{x}_i \sim VM((0,1,0),1)$
- $C_1 : \mathbf{x}_i \sim 0.9VM((0,1,0),1) + 0.1VM((0,-1,1),15)$.

Modelo 2: $\mathbf{x}_i \in \mathcal{S}_2$ con $1 \leq i \leq 100$.

- $C_0 : \mathbf{x}_i \sim VM((0,1),5)$
- $C_1 : \mathbf{x}_i \sim 0.9VM((0,1),5) + 0.1VM((-1,0),20)$.

Simulación

Modelo 1: $\mathbf{x}_i \in \mathcal{S}_3$ con $1 \leq i \leq 200$.

- $C_0 : \mathbf{x}_i \sim VM((0,1,0),1)$
- $C_1 : \mathbf{x}_i \sim 0.9VM((0,1,0),1) + 0.1VM((0,-1,1),15)$.

Modelo 2: $\mathbf{x}_i \in \mathcal{S}_2$ con $1 \leq i \leq 100$.

- $C_0 : \mathbf{x}_i \sim VM((0,1),5)$
- $C_1 : \mathbf{x}_i \sim 0.9VM((0,1),5) + 0.1VM((-1,0),20)$.

Modelo 3: $\mathbf{x}_i \in \mathcal{S}_2$ con $1 \leq i \leq 100$ tiene densidad rotacionalmente simétrica $RT(a,b,\mu)$ donde n

$$f(\mathbf{x}) = \frac{1}{\omega_{d-1}(1-(\mu^T\mathbf{x})^2)^{\frac{d}{2}-1}} g_\nu(\mu^T\mathbf{x})$$

con $g_\nu(t) = \frac{1}{2}\widetilde{g}_{a,b}\left(\frac{t+1}{2}\right)$ y $\widetilde{g}_{a,b}$ una densidad Beta de parámetros a y b.

- $C_0 : \mathbf{x}_i \sim RT(0.5,3,(0,1))$
- $C_1 : \mathbf{x}_i \sim 0.9RT(0.5,3,(0,1)) + 0.1RT(0.5,3,(0,-1))$.
- $C_2 : \mathbf{x}_i \sim 0.9RT(0.5,3,(0,1)) + 0.1VM((0,1),5)$.

Simulación

- Para los tres modelos el objetivo fue estimar μ.

Simulación

- Para los tres modelos el objetivo fue estimar μ.
- Núcle de Epanechnikov $K(t) = 1.5(1 - t^2)I(0 < t < 1)$

Simulación

- Para los tres modelos el objetivo fue estimar μ.
- Núcle de Epanechnikov $K(t) = 1.5(1 - t^2)I(0 < t < 1)$
- Modelo 1 consideramos una grilla de ventanas entre 0.2 y 1.4 de tamaño 10.

Simulación

- Para los tres modelos el objetivo fue estimar μ.
- Núcle de Epanechnikov $K(t) = 1.5(1 - t^2)I(0 < t < 1)$
- Modelo 1 consideramos una grilla de ventanas entre 0.2 y 1.4 de tamaño 10.
- En los Modelos 2 y 3 calculamos la ventana automática.

Simulación

- Para los tres modelos el objetivo fue estimar μ.
- Núcle de Epanechnikov $K(t) = 1.5(1 - t^2)I(0 < t < 1)$
- Modelo 1 consideramos una grilla de ventanas entre 0.2 y 1.4 de tamaño 10.
- En los Modelos 2 y 3 calculamos la ventana automática.
- Como medidas de la simulación consideramos el error cuadrático medio (MSE) y el porcentaje de clasificación de outliers (PC) con $\alpha = 0.05$.

$$\mathrm{MSE}(\widehat{\mu}) = \frac{1}{N}\sum_{i=1}^{N}\|\mu - \widehat{\mu}_i\|^2 \quad \text{y} \quad \mathrm{PC}(\widehat{\mu}) = \frac{1}{N}\sum_{i=1}^{N}\sum_{j=1}^{n} I_{\{\|\mathbf{x}_j - \widehat{\mu}_i\|^2 > v_{1-\alpha}\}}$$

donde $\widehat{\mu}_i$ es el estimado de μ en la replicación i.

Simulación

- MD estimador de mínima distancia con distancia L^2.
- MD_{l^1} estimador de mínima distancia con distancia L^1.
- MD_H estimador de mínima distancia con distancia de Hellinger.
- ML estimador de máxima verosimilitud.
- MD_{ag} estimador considerado en Agostinelli (2007).

Simulación

MODELO 1

- $C_0 : \mathbf{x}_i \sim VM((0,1,0),1)$
- $C_1 : \mathbf{x}_i \sim 0.9VM((0,1,0),1) + 0.1VM((0,-1,1),15)$.

	MD							*ML*
	bandwidth							
	0.200	0.600	0.733	0.867	1.000	1.133	1.400	
	$\mathrm{MSE}(\widehat{\mu})$							
C_0	0.046	0.033	0.031	0.029	0.027	0.025	0.018	0.031
C_1	0.052	0.040	0.039	0.039	0.041	0.042	0.038	0.155
	$\mathrm{PC}(\widehat{\mu})$							
C_0	0.050	0.050	0.049	0.049	0.049	0.049	0.049	0.052
C_1	0.141	0.141	0.141	0.140	0.140	0.140	0.139	0.061

Simulación

MODELO 2

- $C_0 : \mathbf{x}_i \sim VM((0,1),5)$
- $C_1 : \mathbf{x}_i \sim 0.9VM((0,1),5) + 0.1VM((-1,0),20)$.

		ML	MD	MD_{l^1}	MD_{he}	MD_{ag}
$\mathrm{MSE}(\widehat{\mu})$	C_0	0.0024	0.0033	0.0034	0.0024	0.0024
	C_1	0.0193	0.0039	0.0041	0.0108	0.0097
$\mathrm{PC}(\widehat{\mu})$	C_0	0.0489	0.0616	0.0618	0.0600	0.0656
	C_1	0.0009	0.1232	0.1227	0.1198	0.1188
$\widehat{h}$	C_0	-	0.2427	0.2368	0.2745	-
	C_1	-	0.3209	0.3050	0.3765	-

Simulación

MODELO 3

- $C_0 : \mathbf{x}_i \sim RT(0.5, 3, (0, 1))$
- $C_1 : \mathbf{x}_i \sim 0.9RT(0.5, 3, (0, 1)) + 0.1RT(0.5, 3, (0, -1))$.
- $C_2 : \mathbf{x}_i \sim 0.9RT(0.5, 3, (0, 1)) + 0.1VM((0, 1), 5)$.

		ML	MD	MD_{l^1}	MD_{he}
$\mathrm{MSE}(\widehat{\mu})$	C_0	0.0066	0.0097	0.0103	0.0066
	C_1	0.0874	0.0123	0.0128	0.0122
	C_2	0.3882	0.0119	0.0110	0.0085
$\mathrm{PC}(\widehat{\mu})$	C_0	0.0500	0.0512	0.0505	0.0503
	C_1	0.0426	0.1458	0.1445	0.1447
	C_2	0.0353	0.1456	0.1450	0.1449
$\widehat{h}$	C_0	-	0.5146	0.5004	0.4571
	C_1	-	0.4562	0.4157	0.4130
	C_2	-	0.4396	0.4032	0.3654

Ejemplo de las Ranas

Ferguson (1967) llevó a cabo un experimento para investigar la habilidad de orientación de una especie de ranas.

Ejemplo de las Ranas

Ferguson (1967) llevó a cabo un experimento para investigar la habilidad de orientación de una especie de ranas.
Recogió 14 ranas de un pantano Mississippi en los Estados Unidos.
Después de 30 horas, las ranas fueron puestos en libertad.

Ejemplo de las Ranas

Ferguson (1967) llevó a cabo un experimento para investigar la habilidad de orientación de una especie de ranas.
Recogió 14 ranas de un pantano Mississippi en los Estados Unidos.
Después de 30 horas, las ranas fueron puestos en libertad.
Se registraron las direcciones tomadas por las ranas.

Ejemplo de las Ranas

Ferguson (1967) llevó a cabo un experimento para investigar la habilidad de orientación de una especie de ranas.
Recogió 14 ranas de un pantano Mississippi en los Estados Unidos.
Después de 30 horas, las ranas fueron puestos en libertad.
Se registraron las direcciones tomadas por las ranas.
Los resultados se expresan en radianes, donde el punto 0 corresponde a norte.

Ejemplo de las Ranas

Ferguson (1967) llevó a cabo un experimento para investigar la habilidad de orientación de una especie de ranas.
Recogió 14 ranas de un pantano Mississippi en los Estados Unidos.
Después de 30 horas, las ranas fueron puestos en libertad.
Se registraron las direcciones tomadas por las ranas.
Los resultados se expresan en radianes, donde el punto 0 corresponde a norte.

Ejemplo de las Ranas

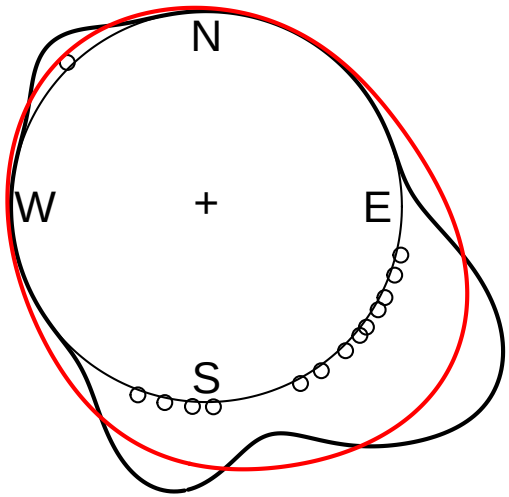

El estimador no parametrico con dos ventanas diferentes.

Ejemplo de las Ranas

En Collett (1980) y Agostinelli (2007) analizan este conjunto de datos con el modelo de Von Mises y concluyen que la observación 14 podría ser un outlier

Ejemplo de las Ranas

En Collett (1980) y Agostinelli (2007) analizan este conjunto de datos con el modelo de Von Mises y concluyen que la observación 14 podría ser un outlier

- $\widehat{\mu} = (-0.7857, 0.6185065)$
- $\widehat{\kappa} = 2.399$ (Ko (1992))
- $\widehat{h} = 0.599129$

Ejemplo de las Ranas

En Collett (1980) y Agostinelli (2007) analizan este conjunto de datos con el modelo de Von Mises y concluyen que la observación 14 podría ser un outlier

- $\widehat{\mu} = (-0.7857, 0.6185065)$
- $\widehat{\kappa} = 2.399$ (Ko (1992))
- $\widehat{h} = 0.599129$
- Detectamos la observación 14 con $\alpha = 0.01$ y 0.05.

Ejemplo de las Ranas

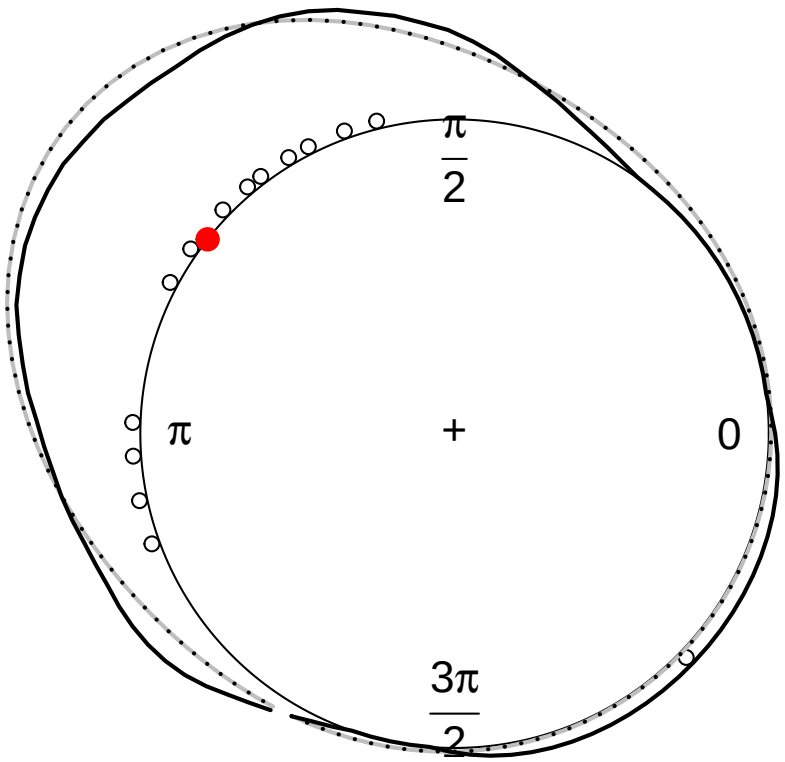

Ejemplo de las Ranas

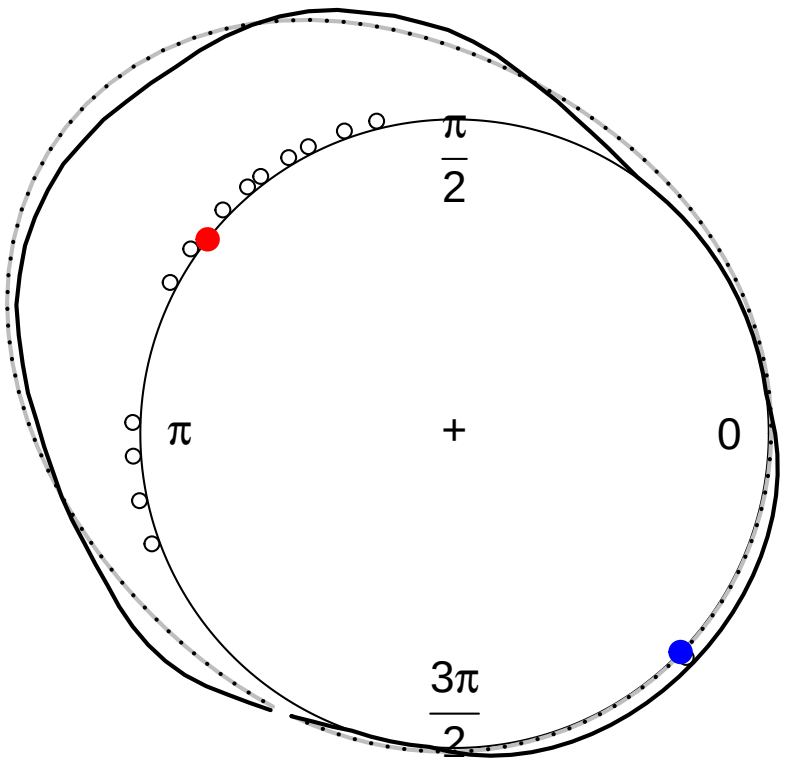

Ejemplo de mamgnetismo

17 mediciones de remanencia magnética a partir de muestras recogidas del Paleozoico.

Ejemplo de mamgnetismo

17 mediciones de remanencia magnética a partir de muestras recogidas del Paleozoico.
El objetivo del estudio era determinar el origen de la magnetización natural.

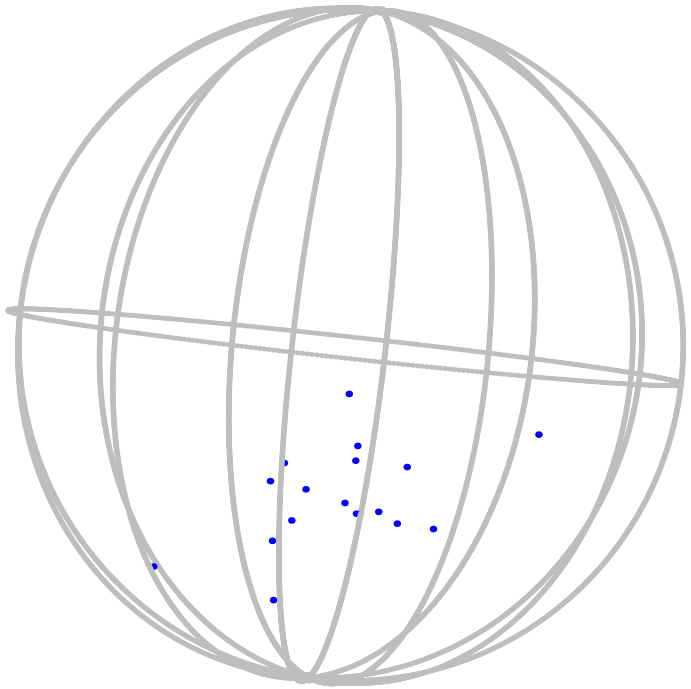

Ejemplo de mamgnetismo

Fischer, et al. (1993) consideraron la distribución de von Mises-Fisher se detectaron dos observaciones (obs 6 y 7) que se pueden consideran como valores atípicos.

Ejemplo de mamgnetismo

Fischer, et al. (1993) consideraron la distribución de von Mises-Fisher se detectaron dos observaciones (obs 6 y 7) que se pueden consideran como valores atípicos.
Concluyeron que la distribución Fisher
podría no ser un modelo apropiado para las 15 observaciones restantes.

Ejemplo de mamgnetismo

Fischer, et al. (1993) consideraron la distribución de von Mises-Fisher se detectaron dos observaciones (obs 6 y 7) que se pueden consideran como valores atípicos.
Concluyeron que la distribución Fisher
podría no ser un modelo apropiado para las 15 observaciones restantes.

Al aplicar nuestro procedimiento obtuvimos

- $\widehat{\mu} = (0.3580, 0.7875, -0.5015)$
- $\widehat{\kappa} = 34.6574$
- para nivel de confiaza $\alpha = 0,01, 0,05$ se detectaron tres posibles valores atípicos, las observaciones 5, 6 y 7.

Ejemplo de mamgnetismo

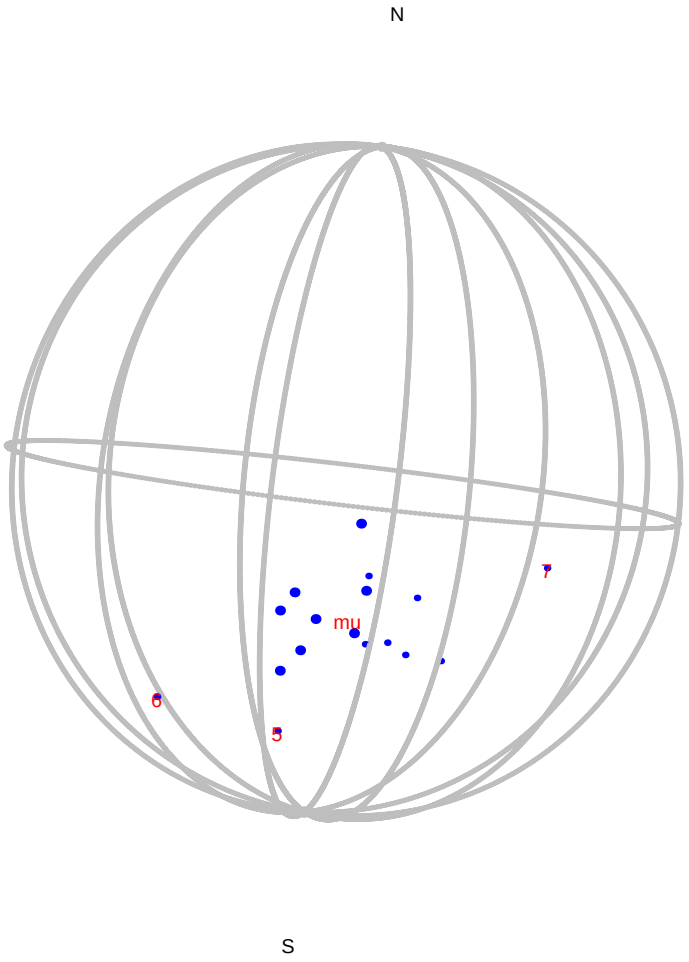

Muchas Gracias!